



Universidad Politécnica
de Madrid

Escuela Técnica Superior de
Ingenieros Informáticos

Grado en Ciencia de Datos e Inteligencia Artificial

Trabajo de Fin de Grado

Aplicación de técnicas de aprendizaje automático al análisis deportivo: estudio exploratorio del salto de longitud

Autor: Laura Chapado Cruz

Tutor: ANGEL MARIO GARCIA PEDRERO

Cotutor: FRANCISCO NAVEROS ARRABAL

Madrid, junio 2026

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado
Grado en Ciencia de Datos e Inteligencia Artificial
Título: Aplicación de técnicas de aprendizaje automático al análisis deportivo: estudio exploratorio del salto de longitud

Junio 2026
Autor: Laura Chapado Cruz

Tutor:
Ángel Mario García Pedrero
Departamento de Arquitectura y Tecnología de Sistemas Informáticos
ETSI Informáticos
Universidad Politécnica de Madrid

Cotutor:
Francisco Naveros Arrabal
Departamento de Arquitectura y Tecnología de Sistemas Informáticos
ETSI Informáticos
Universidad Politécnica de Madrid

Resumen

El salto de longitud es una prueba técnicamente compleja en la que el rendimiento no depende únicamente de la distancia alcanzada, sino también de la carrera de aproximación, la organización de los últimos apoyos, la batida y la precisión con la que el atleta llega a la tabla. En contexto competitivo, la validez o nulidad del intento constituye además una dimensión relevante del análisis técnico, ya que puede estar relacionada con la gestión de la carrera final y con la ejecución del apoyo de batida.

En este contexto, el presente Trabajo Fin de Grado desarrolla un estudio exploratorio sobre la aplicación de técnicas de visión por computador y aprendizaje automático al análisis deportivo del salto de longitud a partir de vídeos bidimensionales de competición. Para ello, se construye un flujo completo de trabajo que incluye la organización del material audiovisual, la asociación de cada vídeo con los resultados oficiales, la extracción semiautomática de variables biomecánicas, la construcción de un conjunto de datos tabular y la evaluación de distintos modelos de clasificación y regresión.

La metodología se centra principalmente en la fase final de la carrera de aproximación, los últimos apoyos previos a la tabla, la batida y un instante postbatida controlado. A partir de los vídeos se obtienen variables espaciales, temporales, angulares y de velocidad, relacionadas con la distancia a la tabla, la longitud de los apoyos, los tiempos entre contactos, la velocidad de aproximación y determinadas configuraciones posturales del atleta. Además, se incorpora una referencia individual de nivel, calculada a partir de resultados previos en pista cubierta, con el objetivo de analizar el rendimiento no solo en términos absolutos, sino también en relación con el nivel esperado de cada deportista.

Sobre esta base se plantean tres tareas principales de aprendizaje automático: la clasificación de intentos válidos y nulos, la predicción de la marca absoluta del salto y la estimación del rendimiento relativo respecto al nivel individual del atleta. Los resultados muestran que las variables extraídas desde vídeo contienen información útil para diferenciar intentos válidos y nulos, especialmente cuando se utilizan variables temporales y espaciales. En la predicción de la marca absoluta, los modelos obtienen una mejora moderada respecto a un modelo de referencia, aunque con una capacidad explicativa limitada. En el análisis del rendimiento relativo, las variables de velocidad muestran una señal relevante, si bien la presencia de valores extremos condiciona el error de los modelos. El análisis de sensibilidad sin estos casos extremos mejora el error medio y vuelve a destacar la importancia de las variables temporales y espaciales.

Aunque el estudio presenta limitaciones derivadas del tamaño reducido de la muestra, del uso de una única cámara lateral, de la estimación automática de pose y de la ausencia de un conjunto de test externo, la metodología propuesta demuestra que es posible construir un pipeline completo, reproducible e interpretable a partir de vídeo real de competición. El trabajo no pretende ofrecer un sistema predictivo definitivo, sino una primera aproximación sólida al uso combinado de visión por computador, variables biomecánicas y aprendizaje automático en el análisis técnico del salto de longitud.

Abstract

Long jump is a technically complex event in which performance does not depend solely on the achieved distance, but also on the approach run, the organization of the final steps, the take-off and the accuracy with which the athlete reaches the board. In a competitive context, whether an attempt is valid or foul is also a relevant dimension of technical analysis, as it may be related to the regulation of the final approach and the execution of the take-off contact.

Within this context, this Final Degree Project develops an exploratory study on the application of computer vision and machine learning techniques to the sports analysis of long jump using two-dimensional competition videos. To this end, a complete workflow is built, including the organization of the audiovisual material, the association of each video with official competition results, the semi-automatic extraction of biomechanical variables, the construction of a tabular dataset and the evaluation of different classification and regression models.

The methodology focuses mainly on the final phase of the approach run, the last foot contacts before the board, the take-off and a controlled post-take-off frame. From the videos, spatial, temporal, angular and velocity-related variables are obtained, including distance to the board, step lengths, contact timing, approach velocity and selected postural features. In addition, an individual performance reference is incorporated, calculated from previous indoor results, in order to analyze performance not only in absolute terms, but also in relation to the expected level of each athlete.

Based on this dataset, three main machine learning tasks are proposed: the classification of valid and foul attempts, the prediction of the absolute jump distance, and the estimation of relative performance with respect to the athlete's individual level. The results show that the variables extracted from video contain useful information to distinguish between valid and foul attempts, especially when temporal and spatial variables are used. In the prediction of absolute jump distance, the models achieve a moderate improvement over a baseline model, although their explanatory capacity remains limited. In the analysis of relative performance, velocity-related variables provide a relevant signal, although the presence of extreme values affects model error. The sensitivity analysis excluding these extreme cases improves the mean error and again highlights the importance of temporal and spatial variables.

Although the study presents limitations related to the small sample size, the use of a single lateral camera, automatic pose estimation and the absence of an external test set, the proposed methodology shows that it is possible to build a complete, reproducible and interpretable pipeline from real competition video. The aim of the work is not to provide a definitive predictive system, but rather to offer a solid first approach to the combined use of computer vision, biomechanical variables and machine learning in the technical analysis of long jump.

Tabla de contenido

Resumen i
Abstract ii
Índice de figuras vi
Índice de tablas vii

1. Introducción 1

2. Estado del arte 5
2.1. Fundamentos biomecánicos del salto de longitud 5
2.2. Aproximación final, últimos apoyos y precisión en tabla 6
2.3. Análisis del salto de longitud en contexto de competición 7
2.4. Análisis por vídeo bidimensional: utilidad y limitaciones 8
2.5. Visión por computador y análisis de datos aplicados al deporte 9
2.6. Planteamiento del trabajo a partir del estado del arte 12

2.6.1. Clasificación de saltos válidos y nulos 12
2.6.2. Estimación de la marca absoluta 12
2.6.3. Rendimiento relativo respecto al nivel individual 13

3. Materiales y conjunto de datos 14
3.1. Contexto competitivo y material disponible 14
3.2. Hoja de resultados y asociación con los vídeos 16
3.3. Información histórica de los atletas 17
3.4. Unidad de análisis 19
3.5. Construcción de la base de datos final 20

4. Metodología de extracción y construcción de variables 21
4.1. Flujo general del proceso de extracción 21
4.2. Calibración espacial de los vídeos 22
4.3. Estimación de pose con MediaPipe Pose 24
4.4. Estimación inicial de la pose y problemas detectados 24
4.5. Seguimiento del atleta, recorte y reconstrucción de coordenadas 25
4.6. Control de calidad y filtrado de pose estimada 27
4.7. Cálculo de ángulos corporales e inclinación del tronco 28
4.8. Detección de apoyos y generación de fotogramas clave 30
4.9. Extracción de variables espaciales, temporales y angulares por evento 31
4.10. Cálculo de velocidades 32

4.10.1. Velocidad de entrada y estimación inicial de velocidad postbatida 32
4.10.2. Velocidad postbatida y frame común 33

4.11. Construcción de la base final de variables 35
4.12. Resumen de decisiones metodológicas principales del extractor 35

5. Preparación del dataset, limpieza y modelado 38
5.1. Construcción del dataset final 38
5.1.1. Decisión de utilizar cuatro apoyos previos 40
5.2. Limpieza y control de calidad del dataset 40
5.3. Calidad del dato y tratamiento de valores ausentes 43
5.4. Análisis de correlación y redundancia entre variables 45
5.5. Criterio agnóstico de preparación de datos 45
5.6. Definición de las tareas de modelado 46
5.7. Paquetes de variables utilizados 47
5.8. Modelos, pipelines y criterios de evaluación 48
5.8.1. Modelos de clasificación 48
5.8.2. Modelos de regresión 50
5.8.3. Interpretación de los hiperparámetros utilizados 52
5.8.4. Criterios de evaluación 53
5.8.5. Resumen de las métricas de evaluación 54

6. Resultados y Discusión 57
6.1. Clasificación de saltos válidos y nulos 57
6.2. Interpretabilidad del modelo de clasificación 60
6.3. Regresión de la marca absoluta 62
6.4. Construcción e interpretación del rendimiento relativo respecto al nivel individual 64
6.5. Regresión del rendimiento relativo 65
6.6. Análisis de sensibilidad sin valores extremos 68
6.7. Interpretabilidad en la regresión sin extremos 70
6.8. Análisis de errores 72
6.9. Comparación con la literatura y coherencia biomecánica 72
6.10. Discusión general 73

7. Conclusiones 75
7.1. Conclusiones principales 75
7.2. Cumplimiento de los objetivos 77
7.3. Aportaciones del trabajo 78
7.4. Limitaciones del estudio 78
7.5. Trabajo futuro 79
7.6. Conclusión final 80

8. Análisis de Impacto 82
8.1. Impacto deportivo 82
8.2. Impacto tecnológico 82
8.3. Impacto académico y formativo 83
8.4. Impacto económico y accesibilidad 83
8.5. Relación con los Objetivos de Desarrollo Sostenible 83

9. Bibliografía 84

Listado de figuras

Figura 1. Fases principales del salto de longitud: aproximación final, batida, vuelo y caída 1
Figura 2. Ejemplo de la perspectiva lateral utilizada en los vídeos de salto de longitud 15
Figura 3. Ejemplo del proceso de asociación entre material audiovisual y hoja oficial de resultados 16
Figura 4. Esquema general de construcción del conjunto de datos a partir del material audiovisual, la hoja de resultados de la competición y el histórico federativo de los atletas 20
Figura 5. Flujo específico de extracción de variables desde vídeo 22
Figura 6. Explicación del uso de la referencia utilizada para la calibración espacial de los vídeos 23
Figura 7. Ejemplo de detección incorrecta de pose al trabajar sobre el frame completo del vídeo 25
Figura 8. Ejemplo de recorte del atleta utilizado para aplicar la estimación de pose sobre una región centrada en el saltador 26
Figura 9. Representación de los ángulos de rodilla, cadera e inclinación del tronco calculados a partir de los puntos corporales detectados 29
Figura 10. Generación de fotogramas clave a partir de la secuencia de apoyos 31
Figura 11. Distribución de valores ausentes por variable en el dataset final de modelado 43
Figura 12. Comparación de los principales modelos de clasificación según F1-score de la clase nulo y balanced accuracy 57
Figura 13. Matriz de confusión del mejor modelo de clasificación válido/nulo 58
Figura 14. Importancia por permutación de las variables de la Regresión Logística con variables temporales y espaciales 59
Figura 15. Relación entre marca real y marca predicha en el mejor modelo de regresión de marca absoluta 61
Figura 16. Distribución de la variable marca_vs_nivel_cm, con identificación de los valores más alejados del nivel individual del atleta 64
Figura 17. Comparación del MAE en la regresión del rendimiento relativo con el dataset completo y sin valores extremos 67
Figura 18. Importancia de variables del modelo Random Forest en la regresión del rendimiento relativo sin valores extremos 69

Listado de tablas

Tabla 1. Composición del material audiovisual y competitivo analizado 14
Tabla 2. Ejemplo de histórico federativo limpio utilizado para calcular el nivel previo de un atleta 17
Tabla 3. Decisiones metodológicas principales del sistema de extracción 35
Tabla 4. Resumen del dataset final utilizado para modelado 39
Tabla 5. Resumen de la limpieza y control de calidad del dataset 41
Tabla 6. Valores ausentes en el dataset final 43
Tabla 7. Paquetes de variables utilizados en el modelado 46
Tabla 8. Modelos e hiperparámetros evaluados en la tarea de clasificación 49
Tabla 9. Modelos e hiperparámetros evaluados en las tareas de regresión 50
Tabla 10. Métricas utilizadas en la tarea de clasificación 53
Tabla 11. Métricas utilizadas en las tareas de regresión 53
Tabla 12. Mejor modelo de clasificación válido/nulo 56
Tabla 13. Variables relevantes en el mejor modelo de clasificación 59
Tabla 14. Descripción de la variable objetivo en la regresión de marca absoluta 60
Tabla 15. Mejores configuraciones obtenidas en la regresión de marca absoluta, ordenadas por MAE 61
Tabla 16. Descripción de la variable marca_vs_nivel_cm 63
Tabla 17. Mejores configuraciones obtenidas en la regresión del rendimiento relativo, ordenadas por MAE 64
Tabla 18. Valores extremos detectados en marca_vs_nivel_cm 66
Tabla 19. Comparación entre regresión completa y regresión sin extremos 66

1 Introducción

El salto de longitud es una prueba técnicamente compleja en la que el resultado final depende de varias fases que tienen que funcionar de forma coordinada: la carrera de aproximación, la batida, el vuelo y la caída. La carrera de aproximación permite al atleta generar velocidad antes de llegar a la tabla de batida, mientras que la batida corresponde al último contacto con el suelo antes de iniciar el vuelo. Después se produce la fase aérea y, finalmente, la caída en el foso, que determina la huella desde la que se mide la marca oficial. Desde el punto de vista reglamentario, la precisión en la tabla de batida resulta decisiva, ya que el intento puede considerarse nulo si el atleta sobrepasa la línea de batida con la parte delantera del pie o de la zapatilla durante la acción de salto[1].

Aunque en competición estas fases forman parte de un gesto continuo, su diferenciación resulta útil desde el punto de vista analítico, ya que permite organizar el estudio técnico del salto y situar con mayor claridad las variables que intervienen en cada momento. Esta secuencia puede observarse en la Figura 1, elaborada a partir de fotogramas extraídos de uno de los vídeos empleados en el trabajo, y sirve como referencia inicial para situar visualmente las fases del gesto que se analizan a lo largo de la memoria.



Figura 1: Fases principales del salto de longitud: aproximación final, batida, vuelo y caída. Fuente: elaboración propia a partir de fotogramas extraídos de material audiovisual cedido por la Real Federación Española de Atletismo para fines académicos.

Esta estructura explica por qué el salto no puede entenderse únicamente como una distancia final. Desde el punto de vista biomecánico, la distancia conseguida no se entiende bien si se analiza solo a partir de una variable aislada. Más bien, es el resultado de la combinación de distintos factores mecánicos y técnicos que intervienen a lo largo de todo el salto [2]. Por eso, para estudiar esta prueba tiene sentido adoptar una visión global del gesto, en la que el rendimiento se interprete en función de cómo se ejecuta técnicamente cada intento [3].

Una de las variables más estudiadas en la literatura es la velocidad de aproximación, ya que se considera un elemento muy importante para el rendimiento [3]. Aun así, distintos trabajos han señalado que su papel no debe interpretarse por separado. Correr más rápido solo resulta útil si el atleta es capaz de mantener el control del gesto y convertir esa velocidad en una batida eficaz [4]. Algo parecido ocurre con el ángulo de despegue, que tampoco puede entenderse como una variable aislada, sino dentro de una relación más amplia entre la velocidad horizontal de llegada, la componente vertical generada en la batida y las condiciones mecánicas de la batida [5]. En definitiva, la evidencia disponible sugiere que el rendimiento en salto de longitud depende de varios factores biomecánicos que actúan de forma conjunta y que, por tanto, conviene analizar en relación unos con otros [2].

Dentro de esta complejidad, la fase final de la carrera de aproximación tiene una importancia especial. Se ha observado que los últimos apoyos previos a la tabla, y en particular la organización del penúltimo y del último paso, condicionan directamente la forma en que el atleta llega a la batida y, por tanto, el resultado final del salto [6]. Además, la aproximación no debe entenderse como una secuencia rígida, sino como un proceso de regulación progresiva en el que el atleta ajusta su patrón de zancada para alcanzar la tabla con precisión [7]. Esta idea ha sido reforzada posteriormente por estudios que muestran que los deportistas de mayor nivel presentan patrones de ajuste más eficaces en la fase final de carrera [8]. Desde esta perspectiva, el estudio de los apoyos finales no solo resulta relevante para analizar la distancia alcanzada, sino también para comprender mejor la precisión técnica del intento [9].

Esta cuestión adquiere todavía más interés en contexto competitivo. La precisión en la aproximación y en la llegada a la tabla de batida no constituye un aspecto secundario del rendimiento, ya que la validez o nulidad del intento también depende de cómo se regula la carrera final y de cómo se ejecuta la llegada a la batida [9]. En este sentido, el análisis técnico del salto puede resultar de interés no solo para estudiar la distancia conseguida, sino también para explorar qué factores pueden estar relacionados con la diferencia entre saltos válidos y nulos [10].

La relevancia competitiva de este problema se refleja también en el debate reciente sobre posibles cambios reglamentarios en la prueba. En 2024, World Athletics llegó a plantear la prueba de una zona de batida alternativa con el objetivo de reducir el número de intentos nulos en salto de longitud [11]. Este debate refuerza la idea de que la nulidad del intento no es una cuestión marginal, sino un aspecto técnico y reglamentario con impacto directo en el desarrollo de la competición.

Tradicionalmente, muchas de las variables biomecánicas del salto de longitud se han estudiado mediante procedimientos instrumentados o análisis de vídeo desarrollados en condiciones controladas [2]. Sin embargo, en contextos aplicados de entrenamiento o competición este tipo de análisis no siempre resulta fácil de trasladar, ya sea por la necesidad de equipamiento específico o por el tiempo que exige revisar de forma manual cada intento. En este escenario, el vídeo aparece como una herramienta especialmente útil, ya que permite registrar ejecuciones reales y conservar información visual suficiente para analizar distintos aspectos técnicos del gesto. Aun así, la literatura también advierte de que el análisis bidimensional presenta limitaciones importantes, especialmente en términos de validez y fiabilidad, que dependen del tipo de variable estudiada y del protocolo utilizado [12]. Por ello, cuando se trabaja con vídeo no instrumentado, resulta especialmente importante seleccionar variables robustas y medibles de forma consistente [13].

Junto a ello, el desarrollo reciente de la visión por computador y de los sistemas de estimación de pose ha abierto nuevas posibilidades para el análisis del movimiento humano a partir de vídeo. Estas herramientas permiten detectar puntos anatómicos de manera automatizada y ofrecen un apoyo potencialmente valioso para el estudio biomecánico en contextos deportivos [14]. No obstante, la investigación más reciente también señala que su aplicación práctica sigue presentando dificultades importantes, especialmente en situaciones reales de competición, donde aparecen oclusiones, variabilidad en la calidad de imagen y cambios posturales rápidos [15]. Del mismo modo, las revisiones sobre inteligencia artificial aplicada a biomecánica deportiva muestran un campo en expansión y con resultados prometedores, pero subrayan también la necesidad de mantener una perspectiva crítica sobre la calidad de los datos, la reproducibilidad de los procedimientos y la interpretación de los modelos [16].

En esta misma línea, algunos trabajos recientes han comenzado a explorar de forma más específica la aplicación de algoritmos de aprendizaje automático al salto de longitud. En particular, se han propuesto modelos para la predicción de la distancia en saltadores masculinos [17]. También se han planteado marcos de trabajo apoyados en reconocimiento de acciones para el análisis técnico y el entrenamiento en salto de longitud [18]. Aunque este tipo de enfoques sigue siendo limitado y heterogéneo, refuerza el interés por estudiar hasta qué punto las herramientas de análisis de datos pueden aportar información útil en esta prueba [17].

En este contexto se sitúa el presente Trabajo Fin de Grado, que plantea un estudio exploratorio sobre la relación entre variables técnicas del salto de longitud y el rendimiento del intento, considerando tanto la distancia alcanzada como la validez o nulidad del salto. El trabajo adopta una perspectiva aplicada: no pretende reproducir un análisis biomecánico de laboratorio altamente instrumentado, sino estudiar hasta qué punto un conjunto de variables con sentido biomecánico, obtenidas de forma controlada a partir de vídeo, puede aportar información útil en un contexto real de competición.

El objetivo general de este TFG es desarrollar una metodología reproducible para extraer, organizar y analizar variables biomecánicas del salto de longitud a partir de vídeos laterales de competición, y evaluar su utilidad para caracterizar técnicamente cada intento y estudiar su relación con el

rendimiento deportivo.

De forma específica, el trabajo persigue los siguientes objetivos:

- Diseñar un flujo de procesamiento de vídeo que permita trabajar de forma ordenada con material audiovisual procedente de competición real.

- Asociar cada vídeo con la información competitiva disponible, incluyendo atleta, intento, marca oficial y condición de salto válido o nulo.

- Extraer variables espaciales, temporales, angulares y de velocidad relacionadas con los últimos apoyos, la batida y los primeros instantes posteriores a la batida.

- Construir un conjunto de datos integrado a nivel de intento, combinando información técnica extraída del vídeo con resultados oficiales y referencias individuales de rendimiento.

- Revisar la calidad de las variables generadas y documentar las limitaciones derivadas del uso de vídeo bidimensional no instrumentado. Analizar si las variables extraídas permiten diferenciar entre saltos válidos y nulos.

- Evaluar la capacidad de dichas variables para estimar tanto la marca absoluta del salto como el rendimiento relativo respecto al nivel individual del atleta.

- Interpretar los resultados obtenidos mediante métricas de evaluación, análisis de errores e importancia de variables.

A partir de estos objetivos, el trabajo se desarrolla como un flujo completo de análisis: primero se organiza el material audiovisual y se construye la base de registro; después se extraen y revisan las variables biomecánicas; y, finalmente, se comparan distintos modelos de aprendizaje automático para valorar qué información aportan estas variables al estudio del rendimiento. De este modo, los modelos se utilizan como una herramienta de análisis e interpretación, siempre vinculada al problema técnico planteado y a las limitaciones del material disponible.

2 Estado del arte

2.1 Fundamentos biomecánicos del salto de longitud

El salto de longitud es una prueba en la que el rendimiento final depende de la interacción entre varias fases del gesto: la carrera de aproximación, la batida, el vuelo y la caída [2]. Aunque el resultado se expresa en una única medida, la distancia alcanzada, la literatura biomecánica ha mostrado desde hace décadas que esa distancia no puede explicarse a partir de un solo factor, sino como consecuencia de la coordinación entre distintos elementos técnicos y mecánicos que actúan de forma conjunta durante la ejecución del salto. En este sentido, los trabajos clásicos de Hay constituyen una referencia fundamental, ya que plantean el salto de longitud como una acción compleja en la que el rendimiento surge de la relación entre velocidad, postura, control corporal y estrategia técnica [2].

Dentro de esta perspectiva, la velocidad de aproximación ha sido señalada de forma reiterada como uno de los principales determinantes del rendimiento [3]. Sin embargo, la evidencia disponible también indica que su influencia no debe interpretarse de manera aislada. Una velocidad elevada solo resulta verdaderamente útil si el atleta es capaz de mantener el control del gesto y transformar de manera eficaz parte de esa velocidad horizontal en una batida favorable [4]. Por ello, la bibliografía ha insistido en que el rendimiento no depende simplemente de correr más rápido, sino de llegar a la tabla en condiciones que permitan ejecutar un take-off técnicamente eficiente.

En relación con esta idea, el ángulo de despegue ha sido otra de las variables más estudiadas en la biomecánica del salto de longitud [5]. No obstante, los trabajos posteriores han mostrado que no debe entenderse como un parámetro independiente, sino como el resultado de una relación más amplia entre la velocidad horizontal de llegada, la componente vertical generada durante la batida y las limitaciones mecánicas propias de una acción realizada a gran velocidad [5]. Esta interpretación resulta especialmente importante porque evita simplificar el rendimiento a una única variable y obliga a considerar el salto como un proceso integrado [2].

Además de estas variables globales, la literatura biomecánica también ha prestado mucha atención a los momentos inmediatamente previos a la batida. El estudio de Hay y Nohara mostró que la preparación del despegue depende en gran parte de cómo se organiza la fase final de la aproximación [6]. En esa misma línea, Lees y colaboradores subrayaron que el último apoyo, el *touchdown* y el *take-off* son momentos biomecánicamente decisivos, ya que condicionan directamente las condiciones con las que el atleta entra en la batida y, por tanto, la distancia conseguida [19]. Esta línea de investigación resulta especialmente relevante para el presente trabajo, ya que justifica el interés por variables asociadas a la fase final de carrera y a la organización de los apoyos previos a la tabla.

A partir de estas aportaciones, el salto de longitud puede entenderse como una acción en la que ninguna variable explica por sí sola el rendimiento. La velocidad de aproximación, las condiciones de la batida y la organización de los apoyos finales actúan de forma relacionada, de modo que el análisis técnico debe atender a la coordinación entre fases y no únicamente a la marca final [3]. Esta interpretación resulta especialmente útil para este trabajo, ya que orienta la selección de variables hacia elementos observables en la fase final de la carrera y en el momento de la batida, siempre dentro de las posibilidades que ofrece el material de vídeo disponible.

2.2 Aproximación final, últimos apoyos y precisión en tabla

Una de las líneas más consolidadas dentro del estudio biomecánico del salto de longitud es la relacionada con la regulación de la carrera de aproximación. Los trabajos clásicos sobre este tema mostraron que la aproximación no debe entenderse como una secuencia fija, sino como un proceso en el que el atleta ajusta progresivamente la longitud de zancada para llegar con precisión a la tabla [7]. Esta regulación suele describirse como una combinación de una fase inicial más estable y una fase final de ajuste, en la que se corrigen pequeños errores acumulados durante la carrera [7].

Posteriormente, se observó además que los atletas con mayor experiencia presentan patrones de regulación más eficaces, lo que sugiere que la capacidad de ajuste constituye una parte relevante del rendimiento técnico [8]. Desde esta perspectiva, la precisión de llegada a la tabla no puede considerarse solo una exigencia reglamentaria, sino una dimensión funcional del gesto, ya que condiciona la forma en que el atleta entra en la batida y, en consecuencia, las posibilidades reales de ejecutar un buen salto [8].

Dentro de este marco, varios estudios han prestado especial atención a los últimos apoyos previos a la batida. Hay y Nohara señalaron que la preparación del *take-off* se apoya en una organización específica de los pasos finales [6]. De forma complementaria, Lees y colaboradores mostraron que las características del último apoyo, el *touchdown* y la batida son biomecánicamente relevantes para explicar el rendimiento [19]. De este modo, la literatura ha ido consolidando la idea de que la estructura de los apoyos finales no es un detalle secundario, sino una dimensión central para comprender el salto.

La relevancia de esta fase final también ha sido analizada desde la perspectiva del ajuste de zancada y de la precisión de batida. En este ámbito, Makaruk y colaboradores estudiaron la relación entre el ajuste de la longitud de zancada, la precisión en el *take-off* y la velocidad de aproximación, mostrando que estos factores deben interpretarse de manera conjunta y no como aspectos independientes [9]. Sus resultados refuerzan la idea de que la precisión en tabla no es solo una cuestión reglamentaria, sino una dimensión técnica directamente relacionada con la organización de la aproximación final.

En una línea similar, el estudio sobre el uso de *check-marks* mostró que ciertas ayudas externas pueden modificar la forma en que el atleta regula los pasos finales, lo que vuelve a poner de relieve la importancia del ajuste de zancada en la llegada a la tabla [20]. Aunque esta referencia ocupa un papel más secundario dentro del bloque, resulta útil para reforzar que la aproximación final no es un proceso puramente automático, sino una fase sensible al control perceptivo y técnico del gesto.

En conjunto, esta literatura justifica de forma sólida el interés por analizar la aproximación final, los últimos apoyos y la precisión en tabla como variables especialmente relevantes tanto para la distancia conseguida como para la calidad técnica del intento. Esta base es especialmente importante en el presente trabajo, ya que una parte sustancial de las variables seleccionadas se sitúa precisamente en ese tramo final de la carrera.

2.3 Análisis del salto de longitud en contexto de competición

La relevancia de la aproximación final y de la precisión en tabla adquiere un valor todavía mayor cuando el salto se estudia en contexto competitivo real. En este tipo de situaciones, el gesto no se produce en un entorno controlado de laboratorio, sino bajo restricciones propias de la competición que pueden condicionar la organización técnica del salto. Por ello, varios trabajos han defendido que el análisis del comportamiento en competición permite identificar factores relevantes que no siempre aparecen con la misma claridad en estudios más experimentales.

En esta línea, McCosker y colaboradores analizaron el salto de longitud desde una perspectiva centrada en el comportamiento competitivo, defendiendo que la carrera final y la colocación del pie respecto a la tabla constituyen restricciones clave del rendimiento técnico [21]. Este enfoque resulta especialmente útil para un trabajo como el presente, ya que el material analizado también procede de competición y, por tanto, se sitúa más cerca de ese contexto aplicado que de un entorno completamente controlado .

Del mismo modo, los estudios biomecánicos desarrollados a partir de competiciones reales han seguido identificando como elementos decisivos la velocidad de aproximación, la fase final de carrera y las características del despegue. El análisis de la campeona del Europeo indoor de 2017, por ejemplo, confirma la importancia de estas variables en una situación competitiva de alto nivel[22]. Aunque se trata de un estudio de caso, resulta útil porque muestra que incluso en contextos muy concretos siguen apareciendo como centrales los mismos factores biomecánicos que señala la literatura clásica.

Junto a ello, la referencia institucional de World Athletics sobre la frecuencia histórica de intentos nulos en salto de longitud y triple salto también ayuda a contextualizar la relevancia competitiva de la precisión en tabla [10]. Aunque no se trata de una fuente científica comparable a las anteriores, sí resulta útil como apoyo para justificar que la validez o nulidad del intento tiene una importancia real dentro de la prueba y no constituye una cuestión marginal .

Por tanto, estudiar el salto de longitud en competición permite desplazar el análisis desde una visión puramente ideal del gesto hacia una interpretación más aplicada. En este contexto, la distancia alcanzada sigue siendo el indicador principal del rendimiento, pero no el único aspecto relevante. La forma en que el atleta llega a la tabla, ajusta los últimos apoyos y consigue que el intento sea válido introduce una dimensión técnica adicional que resulta especialmente pertinente para el presente estudio, basado precisamente en vídeos procedentes de competición real.

2.4 Análisis por vídeo bidimensional: utilidad y limitaciones

Desde el punto de vista metodológico, el vídeo se ha consolidado como una herramienta de gran utilidad para el análisis del movimiento humano y del rendimiento deportivo. Su principal ventaja radica en que permite registrar ejecuciones reales de forma relativamente accesible y conservar información visual suficiente para estudiar aspectos técnicos del gesto. En deportes como el atletismo, esta posibilidad resulta especialmente valiosa cuando no se dispone de sistemas instrumentados complejos o cuando se trabaja con material recogido en situaciones reales de entrenamiento o competición.

Sin embargo, la literatura también advierte de que el análisis bidimensional presenta limitaciones importantes, especialmente cuando se pretende obtener medidas finas a partir de material no instrumentado. La revisión sistemática de Hensley y colaboradores mostró una amplia variabilidad en los métodos empleados para el análisis 2D de tareas de carrera, así como diferencias importantes en la fiabilidad y validez según la variable medida y el protocolo utilizado [12]. Esto sugiere que el valor del vídeo 2D no depende solo del dispositivo de grabación, sino también de la definición operativa de las variables y del control metodológico del procedimiento.

De forma complementaria, Leporace y colaboradores concluyeron que los sistemas de análisis bidimensional pueden ser fiables para medir algunas variables, pero que su validez frente a sistemas tridimensionales sigue siendo limitada en numerosos casos [13]. En particular, los autores advierten que la aplicación de estos sistemas debe realizarse con cautela, sobre todo cuando se pretende estudiar parámetros complejos o movimientos que no se ajustan claramente al plano de grabación [13]. Esta idea resulta especialmente relevante para el presente trabajo, ya que justifica la decisión de priorizar variables robustas, observables y definidas con criterios consistentes.

Dentro de este bloque metodológico puede mencionarse también, como referencia secundaria, el trabajo de Zhuang sobre análisis estructural del vídeo de salto de longitud y extracción de características visuales. Aunque este estudio no se orienta al análisis biomecánico fino del gesto, sí muestra que el material audiovisual de esta prueba puede abordarse mediante procedimientos más sistemáticos de procesamiento y extracción de rasgos [23]. Su interés para este trabajo es, por tanto, más metodológico que interpretativo.

Estas limitaciones no invalidan el uso del vídeo bidimensional, pero sí obligan a definir con cuidado qué se pretende medir y con qué nivel de precisión. En lugar de asumir que cualquier variable extraída del vídeo tiene valor biomecánico, resulta necesario priorizar aquellas que puedan identificarse de forma estable y que mantengan una relación clara con el gesto técnico. Esta consideración metodológica

condiciona directamente el diseño del presente trabajo, en el que el vídeo se utiliza como una fuente accesible de información, pero siempre sometida a revisión, filtrado y control de calidad.

2.5 Visión por computador y análisis de datos aplicados al deporte

En los últimos años, la visión por computador ha ampliado de forma notable las posibilidades del análisis por vídeo en el ámbito deportivo. En particular, los sistemas de estimación de pose basados en cámara permiten detectar puntos anatómicos de manera automatizada y ofrecen nuevas opciones para estudiar el movimiento humano sin necesidad de recurrir a sistemas tridimensionales instrumentados. La literatura reciente muestra que este tipo de herramientas se está aplicando cada vez más en deporte y ejercicio físico, especialmente en contextos en los que no se dispone de equipamiento complejo, aunque su utilidad real sigue dependiendo en gran medida del tipo de tarea, de la calidad del material y de las condiciones de grabación [14].

A pesar de ese potencial, también se han señalado limitaciones importantes. Entre ellas destacan la calidad de imagen, la oclusión de segmentos corporales, la variabilidad del entorno y la dificultad de transformar los puntos detectados en variables biomecánicas realmente interpretables. Esta cuestión resulta especialmente relevante en pruebas como el salto de longitud, donde la velocidad del gesto, los cambios posturales rápidos y la perspectiva de grabación pueden dificultar una extracción automática suficientemente robusta [14]. En esta misma línea, las revisiones más recientes sobre estimación de pose basada en deep learning coinciden en que se trata de un campo en expansión y con posibilidades interesantes para automatizar parte del análisis técnico, pero también insisten en problemas que siguen siendo relevantes, como la dependencia de conjuntos de datos no siempre accesibles, la escasa reproducibilidad de algunos enfoques, la dificultad para transferir modelos entre contextos distintos y la pérdida de robustez cuando estas herramientas se aplican fuera de condiciones controladas [15].

Desde una perspectiva más amplia, el crecimiento del uso de inteligencia artificial en biomecánica deportiva refuerza la idea de que estas herramientas pueden aportar valor al análisis del movimiento, a la interpretación del rendimiento y a la detección de patrones complejos. Sin embargo, la utilidad real de estos enfoques sigue dependiendo de la calidad de los datos, de la claridad metodológica del proceso y de la capacidad de interpretar los resultados de forma útil desde un punto de vista aplicado [16]. En un trabajo como el presente, esta idea resulta especialmente importante, ya que el aprendizaje automático no se plantea como un fin en sí mismo, sino como una herramienta complementaria dentro de un proceso más amplio de medición, estructuración y análisis.

Además de las revisiones generales, en los últimos años han empezado a aparecer trabajos más específicos en atletismo que permiten valorar mejor el potencial real de estas herramientas en condiciones menos idealizadas. Algunos estudios desarrollados en competiciones reales muestran que el interés por el análisis markerless es evidente, pero también que la calidad y la estabilidad de los datos obtenidos todavía no siempre son suficientes para sustituir un análisis manual detallado cuando se exige una precisión elevada [24]. Al mismo tiempo, están apareciendo enfoques más sofisticados que no se limitan a detectar puntos corporales, sino que intentan incorporar también información espacial del entorno para mejorar la reconstrucción del movimiento [25]. Todo ello sugiere que el campo está evolucionando hacia planteamientos más adaptados al contexto deportivo real, en los que no basta con aplicar modelos generales, sino que es necesario considerar las particularidades técnicas de cada disciplina.

En el caso concreto de las pruebas de salto, esta necesidad de mayor precisión se aprecia todavía más. Algunos trabajos recientes han puesto de manifiesto que los esquemas de *keypoints* habituales en los modelos genéricos pueden resultar insuficientes para estudios técnicos finos y han propuesto la detección de puntos corporales más específicos en disciplinas como el salto de longitud, el triple salto o el salto de altura [26]. Esta observación resulta especialmente relevante para el presente trabajo, porque ayuda a justificar por qué no siempre basta con aplicar directamente herramientas generales de visión por computador al análisis técnico del gesto.

Junto a la visión por computador, también han comenzado a desarrollarse enfoques más claramente orientados al análisis de datos y a la predicción del rendimiento. En el caso del salto de longitud, ya existen trabajos que han comparado algoritmos de aprendizaje automático para predecir la distancia a partir de variables relativamente sencillas, lo que muestra que este tipo de planteamientos ha empezado a aplicarse de forma específica en la disciplina [17]. En una línea próxima, también se han propuesto modelos de predicción de la distancia a partir de saltos con aproximación corta, lo que refuerza la idea de que la literatura no solo ha descrito biomecánicamente el gesto, sino que también ha comenzado a desarrollar modelos capaces de anticipar o explicar el rendimiento a partir de información observada [27].

De forma más reciente, algunos trabajos han reforzado esta línea mediante el uso de visión por computador, aprendizaje automático e inteligencia artificial explicable en pruebas de salto. En el caso específico del salto de longitud, se ha analizado el impacto de distintas variables biomecánicas en saltos de élite mediante Quantile Random Forest y técnicas de interpretación como SHAP, PDP e ICE [28]. Este enfoque resulta especialmente relevante para la presente memoria, ya que no se limita a predecir el rendimiento, sino que también busca interpretar qué variables técnicas contribuyen en mayor medida al resultado del salto.

En una línea complementaria, revisiones recientes han estudiado los avances de la visión por computador y el aprendizaje automático aplicados a pruebas de salto, destacando su potencial para transformar información procedente de vídeo en datos útiles para el análisis deportivo [29]. Además, trabajos centrados en el análisis del movimiento deportivo a partir de vídeos de competición refuerzan el interés por construir interpretaciones basadas en datos a partir de material audiovisual real [30]. En conjunto, estas referencias muestran que el uso de vídeo, variables biomecánicas y modelos de aprendizaje automático en pruebas de salto constituye una línea reciente y en crecimiento.

A ello se suman algunos trabajos orientados más al apoyo técnico que a la predicción directa. En el salto de longitud se han propuesto marcos de trabajo basados en visión por computador y reconocimiento de acciones para capturar, analizar y transferir conocimiento técnico sobre las distintas fases del salto [18]. De forma complementaria, también existen propuestas centradas en el procesamiento estructural del vídeo de salto de longitud y en la extracción de características visuales, que aunque no se orientan directamente a la interpretación biomecánica fina, sí muestran que el material audiovisual de esta prueba puede abordarse de manera más sistemática [23].

Por último, pueden mencionarse algunas líneas próximas, aunque no totalmente equivalentes al presente estudio. Existen trabajos que han aplicado aprendizaje automático a la estimación del rendimiento en *standing long jump* a partir de sensores inerciales [31]. Del mismo modo, las revisiones más generales sobre métodos markerless muestran que estas herramientas ofrecen posibilidades interesantes, pero todavía presentan limitaciones importantes en precisión, robustez y validez según la tarea analizada [32]. Aunque estas referencias no son directamente comparables con el salto de longitud de competición con carrera y batida, sí ayudan a situar el problema dentro de una tendencia más amplia hacia la automatización del análisis del movimiento y del rendimiento en pruebas de salto.

La revisión de estos trabajos muestra un campo en expansión, pero también todavía abierto. Las herramientas de visión por computador y aprendizaje automático ofrecen nuevas posibilidades para transformar el vídeo deportivo en datos analizables, aunque su utilidad depende de cómo se construya el proceso completo: calidad del material, elección de variables, control de errores e interpretación posterior. En el caso del salto de longitud, esta cautela es especialmente importante, porque el gesto es rápido, técnico y sensible a pequeños cambios en la aproximación y la batida. Por ello, el presente trabajo se sitúa en una posición aplicada y prudente: utilizar estas herramientas como apoyo al análisis técnico, no como sustituto automático de la interpretación biomecánica.

2.6 Planteamiento del trabajo a partir del estado del arte

A partir del estado del arte revisado, el trabajo se organiza en tres análisis principales. Esta división no responde solo a una decisión metodológica, sino a la propia forma en que la literatura entiende el rendimiento en salto de longitud. Por una parte, los trabajos biomecánicos clásicos muestran que la distancia final depende de la interacción entre distintas fases del gesto, y no de una única variable aislada [2]. Por otra, los estudios sobre la aproximación final señalan que la regulación de los últimos apoyos es clave para llegar con precisión a la tabla de batida [7]. Esta precisión resulta especialmente importante porque afecta tanto a la calidad técnica de la batida como a la validez del intento [9].

El trabajo se apoya además en vídeo lateral de competición, por lo que el análisis debe plantearse con cierta prudencia. La literatura sobre análisis bidimensional advierte de que este tipo de medición puede ser útil en contextos aplicados, pero también presenta limitaciones de validez y fiabilidad según la variable estudiada y el protocolo utilizado [12]. Por ello, en esta memoria no se pretende sustituir un análisis biomecánico de laboratorio, sino comprobar si variables extraídas de forma controlada a partir de vídeo real pueden aportar información útil sobre tres problemas concretos: la diferencia entre saltos válidos y nulos, la estimación de la marca absoluta y el rendimiento relativo respecto al nivel individual del atleta.

2.6.1. Clasificación de saltos válidos y nulos

El primer análisis se centra en distinguir entre intentos válidos y nulos. En salto de longitud, un intento nulo tiene una consecuencia directa: la marca no cuenta. Por eso, aunque la nulidad se define reglamentariamente, evitarla forma parte del rendimiento real del atleta en competición. No basta con saltar lejos; el salto debe ejecutarse de forma que permita aprovechar esa marca dentro de los límites de la prueba.

Esta tarea se relaciona con los estudios sobre la regulación de la carrera de aproximación, que explican que el atleta ajusta progresivamente su zancada para llegar con precisión a la tabla de batida [7]. También se ha observado que los atletas de mayor nivel suelen presentar ajustes más eficaces en los últimos apoyos antes de la batida [8]. En este sentido, la validez del intento depende en gran parte de cómo el atleta organiza la parte final de la carrera y llega al momento de la batida.

A partir de esta idea, el trabajo plantea una tarea de clasificación para comprobar si las variables extraídas del vídeo permiten diferenciar entre saltos válidos y nulos. No se pretende reducir la nulidad a una sola causa, porque cada intento puede depender de varios factores. Lo que se busca es analizar si existen diferencias observables en la fase final de la carrera, en la llegada a la tabla de batida o en las características de los últimos apoyos que ayuden a distinguir ambos tipos de salto.

2.6.2. Estimación de la marca absoluta

El segundo análisis se centra en estimar la marca absoluta del salto, es decir, la distancia oficial alcanzada en los intentos válidos. Este análisis parte de una idea

básica de la biomecánica del salto de longitud: la marca final no depende de una sola variable, sino de cómo se combinan distintos elementos técnicos durante la carrera, la batida y el inicio del vuelo [2].

Dentro de esos elementos, la velocidad de aproximación ha sido una de las variables más estudiadas, porque está muy relacionada con la distancia alcanzada [3]. Sin embargo, correr más rápido no garantiza por sí solo un mejor salto. Esa velocidad tiene que llegar controlada a la tabla de batida y transformarse en una batida eficaz [4]. También el ángulo de despegue debe entenderse dentro de esa relación entre velocidad horizontal, componente vertical y condiciones mecánicas de la batida [5].

Por eso, en este trabajo se plantea un análisis de regresión para comprobar si las variables extraídas desde vídeo permiten aproximarse a la marca oficial del salto. No se trata de sustituir la medición real de la competición, sino de valorar si las variables espaciales, temporales, angulares y de velocidad contienen información suficiente para explicar parte de la distancia conseguida. Este análisis sirve para comprobar si el flujo de extracción de variables consigue captar información útil del gesto deportivo, aunque el material proceda de vídeo lateral y no de un sistema biomecánico de laboratorio.

2.6.3. Rendimiento relativo respecto al nivel individual

El tercer análisis se centra en el rendimiento relativo respecto al nivel individual de cada atleta. Esta parte surge de una limitación clara de la marca absoluta: una misma distancia no significa lo mismo para todos los deportistas, porque cada atleta parte de un nivel físico, técnico y competitivo diferente. Por ejemplo, un salto de 6,80 m puede estar muy cerca del mejor rendimiento habitual de un atleta y, en cambio, quedar lejos de lo esperable para otro deportista con mayor capacidad de salto.

Por tanto, si solo se analiza la marca en metros, el modelo puede acabar reflejando sobre todo las diferencias de nivel entre atletas. Es decir, puede aprender quién salta más, pero no necesariamente si un intento concreto ha sido bueno o malo para ese atleta. Para evitar esta interpretación demasiado limitada, el trabajo incorpora una referencia individual de rendimiento.

Esta referencia se calcula a partir de resultados previos de pista cubierta. Primero se priorizan los resultados anteriores de la temporada actual; si existen tres o más marcas actuales, se utiliza la media de las tres mejores; si hay menos resultados actuales, se emplean los disponibles; y si no hay información suficiente de esa temporada, se recurre al histórico previo del atleta.

A partir de ese nivel de referencia, se crea la variable marca_vs_nivel_cm, que expresa en centímetros la diferencia entre la marca conseguida en el intento analizado y el nivel previo estimado para ese atleta. Esta variable se añade al conjunto de datos como objetivo principal del modelo de regresión de rendimiento relativo.

Con este análisis, el trabajo no estudia solo cuánto ha saltado el atleta, sino si ese salto está por encima o por debajo de lo esperable según su propio nivel. Esto permite interpretar el rendimiento de forma más justa y contextualizada, especialmente en un conjunto de datos formado por atletas con capacidades y trayectorias diferentes.

3 Materiales y conjunto de datos

En este capítulo se describen los materiales utilizados para el desarrollo del trabajo y el proceso seguido para transformar la información disponible en una base de datos organizada. A diferencia de otros estudios que parten de un conjunto de datos ya preparado, este trabajo se inició a partir de material real de competición, por lo que fue necesario construir una base de registro propia antes de poder aplicar técnicas de extracción de variables y aprendizaje automático.

El conjunto de datos del trabajo se construyó a partir de tres fuentes principales. En primer lugar, se utilizaron vídeos laterales de intentos de salto de longitud facilitados por la Real Federación Española de Atletismo. En segundo lugar, se empleó la hoja oficial de resultados de la competición, que permitió identificar los atletas participantes, los intentos realizados, las marcas obtenidas y la condición de salto válido o nulo. En tercer lugar, se incorporó información histórica de rendimiento de los atletas, obtenida a partir de perfiles federativos públicos, con el objetivo de calcular una referencia individual de nivel para cada deportista.

La combinación de estas fuentes permitió construir una base de datos a nivel de intento, en la que cada fila representa un salto individual y cada columna recoge información identificativa, competitiva, histórica o técnica. Este planteamiento fue necesario porque los vídeos, los resultados oficiales y los históricos de los atletas no se encontraban inicialmente integrados en una única tabla.

3.1 Contexto competitivo y material disponible

El material utilizado en este trabajo procede de la prueba masculina de salto de longitud del Campeonato de España Absoluto Short Track 2025, celebrado en el Centro Deportivo Municipal Gallur, en Madrid. Todos los intentos analizados pertenecen a esa misma competición, por lo que el contexto de grabación es común para todos los vídeos.

El material audiovisual está formado por vídeos individuales de intentos de salto de longitud masculino. Cada archivo recoge un intento concreto o una secuencia a partir de la cual fue posible aislar el salto analizado. En total, se trabajó con 66 intentos, correspondientes a 66 vídeos individuales. Tras asociarlos con la hoja oficial de resultados, 42 intentos fueron identificados como saltos válidos y 24 como saltos nulos.

La Tabla 1 recoge las características principales del material audiovisual y competitivo utilizado en el trabajo.

Tabla 1: Composición del material audiovisual y competitivo analizado.

Elemento	**Valor**
Competición	Campeonato de España Absoluto *Short Track* 2025
Instalación	Centro Deportivo Municipal Gallur, Madrid
Prueba analizada	Salto de longitud masculino
Vídeos / intentos analizados	66
Saltos válidos	42
Saltos nulos	24
Perspectiva de grabación	Lateral
Frecuencia de vídeo utilizada	240 fps
Unidad de análisis	Intento de salto
Distancia de referencia para calibración	3 m

La perspectiva disponible es lateral, lo que permite observar especialmente la fase final de la carrera de aproximación, la llegada a la tabla de batida, la batida y parte del vuelo y la caída. Esta vista resulta adecuada para estudiar variables relacionadas con la progresión horizontal del atleta, la distancia a la tabla, la longitud de los últimos apoyos, los tiempos entre contactos y algunas variables angulares observables en el plano principal del movimiento.

La Figura 2 muestra un ejemplo de la perspectiva lateral utilizada en los vídeos analizados. Esta imagen ayuda a entender el tipo de material disponible y las fases del salto que pueden observarse con mayor claridad desde esta vista.



Figura 2: Ejemplo de la perspectiva lateral utilizada en los vídeos de salto de longitud. Fuente: elaboración propia a partir de material audiovisual cedido o autorizado por la Real Federación Española de Atletismo para fines académicos.

Al tratarse de vídeos procedentes de una competición real, el material no tiene las mismas condiciones que una grabación preparada específicamente para un análisis biomecánico. En las imágenes pueden aparecer jueces, personas próximas a la zona de salto, material de medición, elementos del foso o rótulos de la competición. Estos elementos son normales en una prueba oficial, pero en algunos momentos pueden tapar parcialmente al atleta o dificultar la detección automática de la pose.

Teniendo en cuenta estas características del material, el trabajo no se plantea como una reconstrucción completa de todas las fases del salto. La toma lateral permite analizar con más consistencia la parte final de la carrera, los últimos apoyos, la batida y los primeros instantes posteriores, pero limita el estudio de movimientos tridimensionales o de fases con más oclusiones, como la caída. Esta delimitación permite trabajar con variables más fiables y evita interpretar con demasiada precisión información que el vídeo no permite medir con seguridad.

Los vídeos se analizaron tomando como referencia una frecuencia de 240 fotogramas por segundo. Además, el material ofrecía una referencia espacial útil para el análisis posterior: la distancia conocida de 3 metros entre la tabla de batida y una referencia del foso. Esta referencia se utilizó más adelante para convertir medidas en píxeles a unidades reales durante el proceso de extracción de variables.

Los vídeos utilizados en este TFG fueron cedidos por la Real Federación Española de Atletismo exclusivamente con fines académicos y no comerciales. Asimismo, las capturas de pantalla de este material incluidas en la memoria, se identifican como “elaboración propia a partir de material audiovisual cedido ”.

3.2 Hoja de resultados y asociación con los vídeos

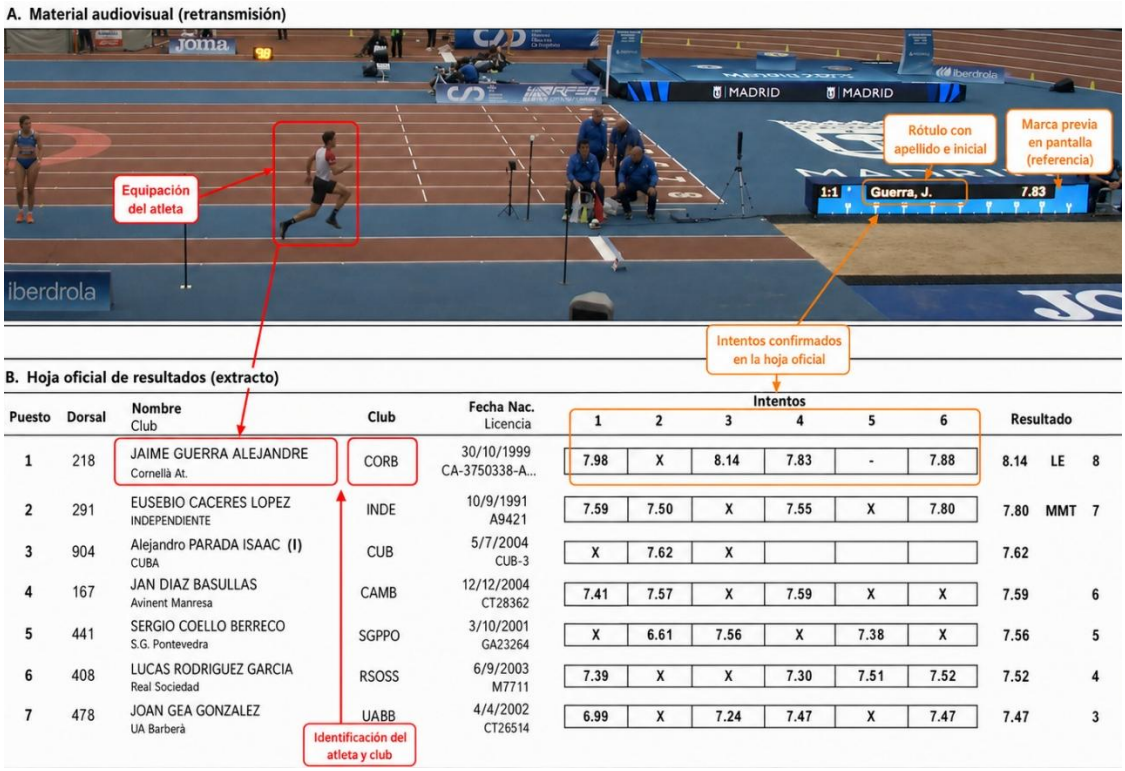
Además del material audiovisual, se utilizó la hoja oficial de resultados de la competición. Esta hoja permitió identificar los atletas participantes, el orden de intentos, las marcas obtenidas y la condición de salto válido o nulo. En este trabajo, esta información fue necesaria para vincular cada vídeo con su intento correspondiente.

Los vídeos no venían acompañados de una tabla que indicara directamente qué atleta aparecía en cada archivo, qué número de intento era o cuál había sido el resultado. Por ello, fue necesario realizar una asociación manual y supervisada entre los vídeos disponibles y la hoja oficial de resultados. Para hacer esta correspondencia se revisaron distintos elementos: el orden de participación, los rótulos visibles en la retransmisión, la equipación de los atletas, el número de intento y el resultado mostrado cuando aparecía en pantalla.

Este proceso permitió asignar a cada vídeo un atleta, un intento y una etiqueta de resultado. En los saltos válidos se incorporó la marca oficial en metros, mientras que los intentos nulos se identificaron mediante una variable binaria. Esta información fue la base para plantear después dos líneas de análisis: la clasificación entre saltos válidos y nulos, y los modelos de rendimiento aplicados únicamente a los saltos válidos con marca oficial disponible.

La Figura 3 muestra un ejemplo del proceso de asociación entre el material audiovisual y la hoja oficial de resultados. Su objetivo es ilustrar cómo se contrastó

la información visible en el vídeo con el registro oficial de la competición.



Puesto	Dorsal	Nombre / Club	Club	Fecha Nac. / Licencia	Intentos 1	2	3	4	5	6	Resultado		
1	218	JAIME GUERRA ALEJANDRE Cornellà At.	CORB	30/10/1999 CA-3750338-A...	7.98	X	8.14	7.83	-	7.88	8.14	LE	8
2	291	EUSEBIO CACERES LOPEZ INDEPENDIENTE	INDE	10/9/1991 A9421	7.59	7.50	X	7.55	X	7.80	7.80	MMT	7
3	904	Alejandro PARADA ISAAC (I) CUBA	CUB	5/7/2004 CUB-3	X	7.62	X				7.62		
4	167	JAN DIAZ BASULLAS Avinent Manresa	CAMB	12/12/2004 CT28362	7.41	7.57	X	7.59	X	X	7.59		6
5	441	SERGIO COELLO BERRECO S.G. Pontevedra	SGPPO	3/10/2001 GA23264	X	6.61	7.56	X	7.38	X	7.56		5
6	408	LUCAS RODRIGUEZ GARCIA Real Sociedad	RSOSS	6/9/2003 M7711	7.39	X	X	7.30	7.51	7.52	7.52		4
7	478	JOAN GEA GONZALEZ UA Barberà	UABB	4/4/2002 CT26514	6.99	X	7.24	7.47	X	7.47	7.47		3

Figura 3: Ejemplo del proceso de asociación entre material audiovisual y hoja oficial de resultados.

3.3 Información histórica de los atletas

Además de los vídeos y de la hoja oficial de resultados, se incorporó información histórica de los atletas. Esta parte era necesaria porque el trabajo no solo analiza la marca conseguida en metros, sino también si esa marca está cerca o lejos del nivel habitual del propio deportista.

Los resultados históricos se obtuvieron a partir de perfiles federativos públicos de los atletas identificados en la competición. A partir de esa información se construyó una base individual para cada atleta, pero no se utilizaron todos los registros disponibles sin filtrar. Primero fue necesario revisar los resultados y conservar únicamente aquellos que fueran comparables con el contexto del estudio.

En concreto, se mantuvieron los registros correspondientes a salto de longitud en *Short Track* y se eliminaron los resultados posteriores a la competición analizada. Esta decisión era importante porque el objetivo era estimar el nivel previo del atleta, por lo que no tenía sentido utilizar marcas conseguidas después de la prueba objeto de análisis. Tampoco se utilizaron resultados de otras pruebas ni marcas de aire libre, ya que podían responder a condiciones distintas.

La Tabla 2 muestra un ejemplo de histórico limpio para uno de los atletas incluidos en la competición. No se incluye como resultado del análisis, sino como ejemplo del

tipo de información que se utilizó para calcular después el nivel de referencia individual.

Tabla 2: Ejemplo de histórico federativo limpio utilizado para calcular el nivel previo de un atleta.

Fecha	Prueba	Marca	Categoría	Lugar
2024-01-13	Longitud	7.14	Sub 23	San Sebastián (i)
2024-01-20	Longitud	7.02	Absoluta	Zaragoza (i)
2024-01-27	Longitud	6.94	Sub 18	Zizur Mayor (i)
2024-02-10	Longitud	6.95	Sub 18	Zaragoza (i)
2024-02-24	Longitud	6.95	Absoluta	Sabadell (i)
2024-12-13	Longitud	7.13	Absoluta	Zizur Mayor (i)
2024-12-21	Longitud	7.20	Sub 20	San Sebastián (i)
2025-01-11	Longitud	7.36	Absoluta	Zizur Mayor (i)
2025-02-15	Longitud	7.03	Absoluta	Valencia (i)

El objetivo de esta limpieza no fue reconstruir toda la trayectoria deportiva de cada atleta, sino obtener una referencia reciente y coherente de su nivel en salto de longitud. Esta referencia era necesaria porque los atletas de la competición no partían del mismo nivel competitivo. Por ello, una misma marca puede tener una interpretación distinta según el deportista: para uno puede estar cerca de su rendimiento habitual, mientras que para otro puede quedar por debajo de lo esperable.

A partir de los históricos limpios se calculó una referencia individual de nivel para cada atleta. Esta referencia no pretende representar el mejor resultado histórico del deportista, sino una estimación sencilla de su rendimiento reciente en condiciones comparables. Para ello, se seleccionaron las mejores marcas previas disponibles en salto de longitud *Short Track*, dando prioridad a los registros más cercanos a la competición analizada.

De forma general, para cada atleta se ordenaron sus marcas previas de mayor a menor y se tomó como referencia la media de sus mejores resultados disponibles. Cuando el atleta tenía tres o más marcas previas comparables, se utilizaron sus tres mejores registros. Si tenía menos de tres marcas disponibles, se calculó la referencia con las marcas existentes.

Matemáticamente, si para un atleta i se dispone de un conjunto de marcas previas comparables M_i , ordenadas de mayor a menor, el nivel de referencia se calculó como:

$$\text{Nivel_referencia}_i = (1 / k) \cdot \Sigma_{j=1}{}^{k} M_{ij}$$

donde M_{ij} representa una de las mejores marcas previas del atleta i, y k es el número de marcas utilizadas, con un máximo de tres:

$$k = \min(3, n_i)$$

siendo n_i , el número total de marcas previas comparables disponibles para ese atleta.

A partir de este nivel de referencia se calculó una segunda variable, denominada rendimiento relativo, que mide la diferencia entre la marca conseguida en el intento analizado y el nivel previo estimado del atleta. Esta diferencia se expresó en centímetros para facilitar su interpretación:

$$\text{Rendimiento_relativo}_{ij} = (\text{Marca}_{ij} - \text{Nivel_referencia}_i) \cdot 100$$

donde Marca_{ij} es la marca oficial, en metros, del intento j del atleta i, y $\text{Nivel_referencia}_i$, es su nivel previo estimado, también en metros.

De esta forma, un valor positivo indica que el atleta saltó por encima de su nivel de referencia, mientras que un valor negativo indica que el intento quedó por debajo de ese nivel. Esta variable permitió analizar el rendimiento de una forma más contextualizada, ya que no todos los atletas partían del mismo nivel competitivo.

3.4 Unidad de análisis

La unidad de análisis del trabajo se definió a nivel de intento. Esto significa que cada fila de la base de datos representa un salto concreto, no un atleta completo, una competición o un vídeo entendido como archivo independiente. Esta decisión responde al enfoque del estudio, ya que el objetivo es analizar qué ocurre en cada ejecución y cómo sus características se relacionan con la validez del salto y con el rendimiento obtenido.

Cada intento quedó vinculado a un código de vídeo. Este código permitió mantener la trazabilidad con el archivo audiovisual original y con las salidas generadas durante el procesamiento. Además, se conservaron variables identificativas como el nombre del atleta, la competición y el número de intento cuando esta información estaba disponible. Estas variables no se utilizaron como predictores en los modelos, pero sí fueron necesarias para revisar posibles errores, comprobar asociaciones y entender mejor los resultados obtenidos.

La base de datos incorpora también el nivel de referencia individual y la diferencia entre la marca oficial y ese nivel, calculados a partir de los históricos federativos descritos en el apartado anterior. De esta manera, cada intento válido puede analizarse tanto por su marca absoluta como por su rendimiento relativo respecto al nivel previo del atleta.

Definir el intento como unidad de análisis permitió trabajar con distintos objetivos a partir de una misma estructura. En unos análisis se utilizó la condición de salto válido o nulo; en otros, la marca oficial de los saltos válidos; y en otros, la diferencia entre la marca conseguida y el nivel previo estimado del atleta. Por tanto, aunque todas las filas parten de la misma unidad básica, cada experimento utiliza únicamente las variables y registros adecuados para su objetivo.

3.5 Construcción de la base de datos final

Una vez definida la unidad de análisis, se construyó la base de datos final uniendo la información procedente de las distintas fuentes del trabajo. El objetivo era que cada intento quedara descrito con la información necesaria para el análisis: el vídeo correspondiente, el resultado oficial de la competición, el nivel previo del atleta y las variables técnicas extraídas posteriormente del vídeo.

En primer lugar, cada vídeo se asoció con la hoja oficial de resultados para identificar el atleta, el número de intento, la marca oficial y la condición de salto válido o nulo. En segundo lugar, a cada atleta se le incorporó la información procedente de su histórico federativo, previamente depurado, para calcular una referencia individual de nivel. Por último, sobre esa misma base se añadieron las variables técnicas obtenidas mediante el procesamiento de los vídeos.

La Figura 4 resume este proceso de construcción de la base de datos final. En ella se muestra cómo las tres fuentes principales aportan información diferente, pero complementaria: los vídeos permiten extraer variables técnicas, la hoja oficial de resultados aporta el resultado competitivo y los históricos federativos permiten contextualizar el rendimiento de cada atleta.

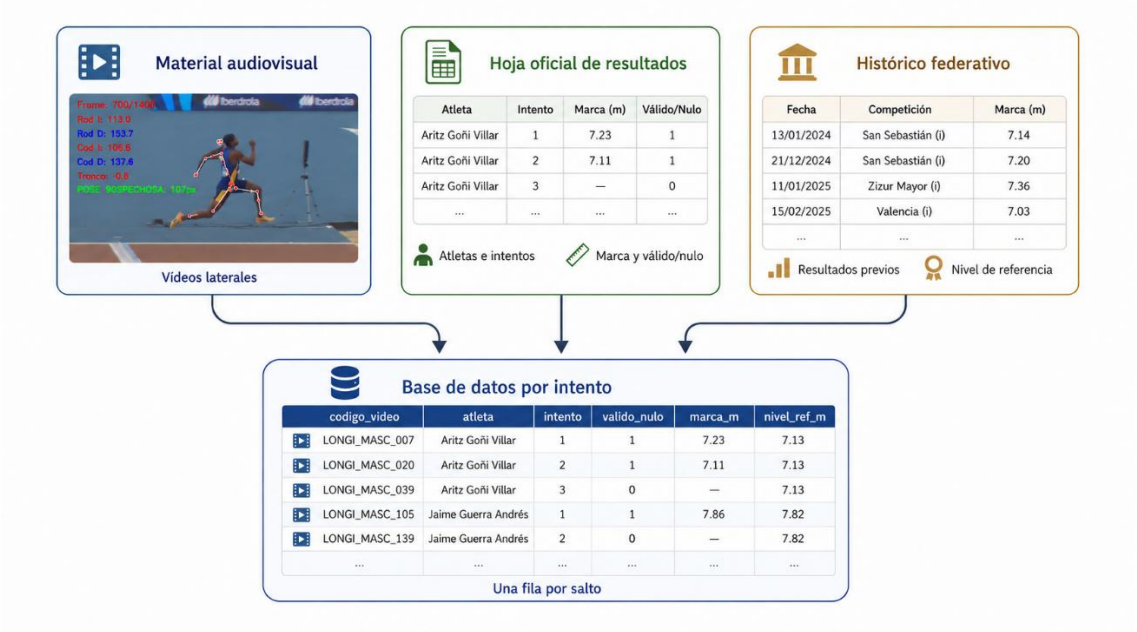


Figura 4 : Esquema general de construcción del conjunto de datos a partir del material audiovisual, la hoja de resultados de la competición y el histórico federativo de los atletas.

Esta integración fue necesaria para que cada salto quedara descrito desde varias perspectivas complementarias. La información competitiva permite saber qué ocurrió en el intento; la información histórica permite contextualizar el

rendimiento del atleta; y la información extraída del vídeo permite analizar técnicamente la ejecución. De esta forma, el dataset no se limita a recoger marcas finales, sino que incorpora información útil para estudiar la relación entre técnica, validez del intento y rendimiento.

4 Metodología de extracción y construcción de variables

En este capítulo se describe el procedimiento seguido para transformar los vídeos de competición en variables técnicas analizables. A diferencia de una base de datos ya preparada, el material de partida eran vídeos laterales reales de salto de longitud, por lo que fue necesario construir un proceso propio de extracción antes de poder aplicar cualquier análisis posterior.

La metodología se centró en obtener variables comparables entre intentos a partir de una misma lógica de trabajo: calibrar espacialmente los vídeos, localizar al atleta, estimar su pose, corregir errores de detección, identificar los apoyos y la batida, y calcular variables espaciales, temporales, angulares y de velocidad. Todo este proceso se desarrolló teniendo en cuenta que los vídeos procedían de una competición real y no de una grabación controlada de laboratorio.

El objetivo no fue reconstruir el salto de longitud en tres dimensiones ni medir con precisión absoluta todas sus fases, sino extraer información técnica útil desde una perspectiva lateral. Por ello, la metodología se delimitó a las fases que podían observarse con mayor consistencia en el material disponible: la fase final de la carrera de aproximación, los últimos apoyos, la batida y un tramo postbatida controlado. La fase aérea completa y la caída no se analizaron de forma detallada, ya que con una única toma lateral presentaban mayores problemas de oclusión, superposición de segmentos corporales y pérdida parcial de puntos anatómicos.

Las variables obtenidas en este capítulo constituyen la base técnica que se utilizará posteriormente para la preparación de la base de datos y el modelado. Por tanto, este apartado no se centra todavía en evaluar resultados predictivos, sino en explicar cómo se obtuvieron las variables que después se emplearon en los análisis.

4.1. Flujo general del proceso de extracción

El proceso de extracción se diseñó como una cadena de trabajo progresiva. En primer lugar, se partió del vídeo lateral de cada intento. Después, se aplicó una calibración espacial común para poder convertir medidas en píxeles a unidades reales. A continuación, se localizó al atleta dentro de la imagen y se utilizó un recorte de la zona de interés para mejorar la estimación de pose y reducir la interferencia de otros elementos presentes en la escena.

Una vez obtenida la pose del atleta, las coordenadas detectadas se reconstruyeron en el sistema del vídeo original. Este paso fue necesario porque las coordenadas calculadas dentro del recorte no podían utilizarse directamente para medir distancias sobre el vídeo completo. A partir de esas coordenadas corregidas se calcularon ángulos corporales, posiciones relevantes y señales temporales asociadas al movimiento del atleta.

Posteriormente, se identificaron los eventos principales del salto: los últimos

apoyos de la carrera, la batida y un *frame* común posterior al despegue. Estos eventos sirvieron como referencia para calcular las variables finales, entre ellas distancias a la tabla de batida, longitudes entre apoyos, tiempos entre contactos, velocidades medias, ángulos de rodilla y cadera, e inclinación del tronco.

La Figura 5 resume el flujo general seguido en esta fase de extracción. Su finalidad es mostrar, de forma esquemática, cómo el vídeo original se transforma progresivamente en variables técnicas utilizables para el análisis.

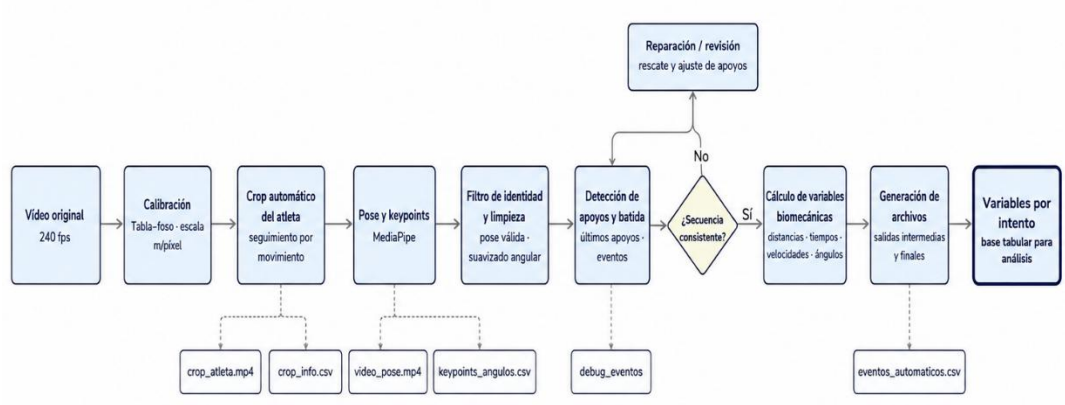


Figura 5 :. Flujo específico de extracción de variables desde vídeo

4.2 Calibración espacial de los vídeos

Para poder calcular distancias y velocidades a partir de los vídeos, primero fue necesario transformar las medidas obtenidas en píxeles a unidades reales. Como el material procedía de una toma lateral, las distancias medidas directamente sobre la imagen estaban expresadas en píxeles, por lo que no podían interpretarse todavía como metros.

La referencia utilizada fue la distancia conocida de 3 metros entre la tabla de batida y una referencia situada al inicio del foso. Esta distancia era visible en los vídeos y permitió establecer una relación entre una medida real y su equivalencia dentro de la imagen.

En una primera fase, la calibración se realizó de forma manual para cada vídeo. Para ello, se marcaron sobre la imagen los puntos de referencia necesarios: la posición de la tabla de batida y la referencia del foso situada a 3 metros. Esta comprobación inicial era necesaria porque, aunque todos los vídeos procedían de la misma competición y de una perspectiva muy similar, no se podía asumir sin verificar que la cámara no hubiera sufrido pequeños desplazamientos o cambios de encuadre entre intentos.

Tras revisar las calibraciones individuales, se observó que las diferencias entre vídeos eran mínimas. Las posiciones marcadas variaban solo unos pocos píxeles entre intentos, dentro de un margen muy reducido. Por ello, en lugar de mantener una escala distinta para cada vídeo, se decidió utilizar una calibración común basada en el valor medio de las mediciones realizadas.

La Figura 6 muestra visualmente la referencia utilizada para esta calibración. En ella se señala la distancia real conocida entre la tabla de batida y el inicio del foso, así como su equivalencia en píxeles dentro del vídeo. Esta referencia

permitió aplicar un mismo criterio de conversión a todos los intentos analizados



Figura 6 :. Explicación del uso de la referencia utilizada para la calibración espacial de los vídeos

La escala se definió mediante la siguiente expresión:

$$\text{escala} = \frac{d_{\text{real}}}{d_{\text{pixeles}}}$$

donde d_{real} representa la distancia real conocida en metros y d_{pixeles} la distancia equivalente medida en la imagen. En la configuración final se utilizó una distancia real de 3 metros y una distancia de 238 píxeles entre la tabla y la referencia del foso:

$$\text{escala} = \frac{3.0}{238}$$

Es decir, cada píxel en el eje horizontal equivale aproximadamente a 0,0126 metros. A partir de esta escala, cualquier distancia horizontal medida en píxeles se transformó a metros mediante:

De forma general, una distancia horizontal medida en la imagen se transformó mediante:

$$d_m = d_{imagen} \cdot \text{escala}$$

donde d_{imagen} representa cualquier distancia medida en píxeles sobre el vídeo.

Esta conversión se utilizó para calcular variables como la distancia del apoyo a la tabla de batida, la longitud entre apoyos consecutivos y los desplazamientos horizontales del atleta. También fue necesaria para estimar velocidades, ya que estas se obtienen a partir de desplazamientos expresados en metros y tiempos calculados a partir del número de fotogramas.

La decisión de utilizar una calibración común tuvo como objetivo mantener un criterio homogéneo en todos los intentos. Si se hubiera mantenido una calibración distinta para cada vídeo, pequeñas diferencias debidas al marcado manual podrían haber introducido variaciones artificiales en las distancias y velocidades. En cambio, al utilizar una escala común, todos los vídeos quedan sujetos al mismo criterio de conversión y el posible error se mantiene de forma uniforme.

Esta calibración se utilizó como una referencia común para todos los vídeos, no como una medición biomecánica exacta. Como el objetivo era comparar intentos entre sí, tenía más sentido aplicar el mismo criterio de conversión a todos los saltos que introducir pequeñas diferencias de escala entre vídeos que, en la práctica, eran muy similares.

4.3 Estimación de pose con MediaPipe Pose

Una vez definida la calibración espacial, el siguiente paso fue obtener información corporal del atleta en cada vídeo. Para ello se utilizó MediaPipe Pose[33], una herramienta de visión por computador que permite detectar automáticamente puntos del cuerpo humano en imágenes o vídeos. Estos puntos, conocidos como *landmarks*, representan zonas como hombros, caderas, rodillas, tobillos o pies. Además, esta decisión se alineaba con estudios recientes que han utilizado estimación de pose para extraer características biomecánicas del salto de longitud a partir de vídeo [34].

De forma resumida, MediaPipe Pose analiza cada fotograma del vídeo y devuelve las coordenadas de esos puntos corporales. En este trabajo, esas coordenadas fueron necesarias para calcular variables técnicas del salto. Por ejemplo, la posición de los pies permitió estudiar los apoyos de la carrera final, mientras que la posición de caderas, rodillas y tobillos permitió calcular ángulos articulares. La posición de hombros y caderas también permitió estimar la inclinación del tronco.

Se utilizó MediaPipe Pose porque ofrecía una forma directa y accesible de obtener puntos corporales a partir de vídeos reales, sin tener que entrenar un modelo propio ni etiquetar manualmente todos los fotogramas. Además, MediaPipe es un *framework* utilizado para construir procesos de percepción visual reproducibles, y su solución de pose se basa en modelos como BlazePose, diseñados para estimar puntos corporales de forma eficiente desde imagen o vídeo monocular.

En este trabajo no se realizó una comparación completa entre detectores de pose. Aunque existen alternativas como OpenPose, DeepLabCut o modelos basados en YOLO-pose, MediaPipe Pose se consideró suficiente para el objetivo del proyecto: construir un procedimiento que permitiera pasar de vídeos laterales de competición a variables numéricas interpretables.

No obstante, MediaPipe Pose no funcionaba de forma perfecta en todos los fotogramas. Al trabajar con vídeos reales de competición, podían aparecer problemas como pérdida de puntos corporales, detecciones incompletas, oclusiones, movimientos rápidos o presencia de otras personas en la escena. Por este motivo, sus salidas no se utilizaron directamente sin revisión, sino que se integraron dentro de un proceso con recorte del atleta, reconstrucción de coordenadas, filtrado y comprobación visual de los fotogramas clave.

4.4 Estimación inicial de la pose y problemas detectado

En una primera aproximación, MediaPipe Pose se aplicó directamente sobre el *frame* completo del vídeo. Esta opción permitía analizar la imagen original sin realizar recortes previos, pero en la práctica generó varios problemas. Al tratarse de vídeos reales de competición, en la escena no aparecía únicamente el atleta, sino también jueces, personas próximas a la zona de salto, material de medición, carteles, trípodes y otros elementos del entorno competitivo.

La presencia de estos elementos podía afectar a la estimación automática de la pose. En algunos momentos, el sistema detectaba correctamente al saltador,

pero a lo largo del vídeo podía perder parte del cuerpo, generar una pose incompleta o confundir al atleta con otra persona presente en la imagen. Estos errores eran especialmente problemáticos en momentos cercanos a la batida y al inicio del vuelo, donde el movimiento del atleta es rápido y pueden producirse oclusiones o cambios bruscos de postura.

La Figura 7 muestra un ejemplo de este problema. En ella se observa cómo, al analizar el *frame* completo, la detección comienza identificando al atleta, pero posteriormente se desplaza hacia otra persona presente en la escena. Este tipo de fallo justificó la necesidad de introducir una fase posterior de recorte del atleta antes de aplicar la estimación de pose



Figura 7 :. Ejemplo de detección incorrecta de pose al trabajar sobre el frame completo del vídeo

Esta revisión inicial permitió comprobar que no bastaba con aplicar directamente el modelo de pose sobre toda la imagen. Era necesario reducir la zona de análisis para centrar el procesamiento en el atleta y disminuir la interferencia del entorno. Por ello, el procedimiento evolucionó hacia una estrategia basada en recortes del saltador, que se describe en el apartado siguiente.

4.5 Seguimiento del atleta, recorte y reconstrucción de coordenadas

Para reducir los problemas detectados al aplicar MediaPipe Pose sobre el *frame* completo, se incorporó una fase previa de seguimiento del atleta y recorte de la zona de interés. El objetivo fue centrar el análisis en la región donde se encontraba el saltador y reducir la influencia de otros elementos presentes en la escena, como jueces, material de medición, carteles o personas cercanas a la zona de salto.

El recorte no se realizó de forma manual *frame* a *frame*. El procedimiento se basó en detectar la zona de mayor movimiento dentro de la imagen, ya que el atleta era el elemento que se desplazaba de forma principal durante la ejecución del salto. A partir de esa detección se generó una ventana alrededor del saltador, añadiendo un margen para no perder partes del cuerpo durante la carrera, la batida o el inicio del vuelo. De esta forma, el sistema producía una versión recortada del vídeo centrada en el atleta.

Este paso funcionaba, por tanto, como una forma de seguimiento automático del saltador. No se trataba de modificar el contenido del vídeo, sino de seleccionar

en cada fotograma la zona más útil para aplicar la estimación de pose. Al trabajar sobre esa región, MediaPipe Pose recibía una imagen más limpia y centrada, con menos información irrelevante del entorno. Esto reducía el riesgo de que el modelo detectara puntos corporales de jueces u otras personas presentes en la escena.

La Figura 8 muestra un ejemplo de este proceso. En ella se observa cómo el recorte permite aislar mejor al atleta dentro de la imagen y preparar una zona de análisis más adecuada para la estimación de pose.

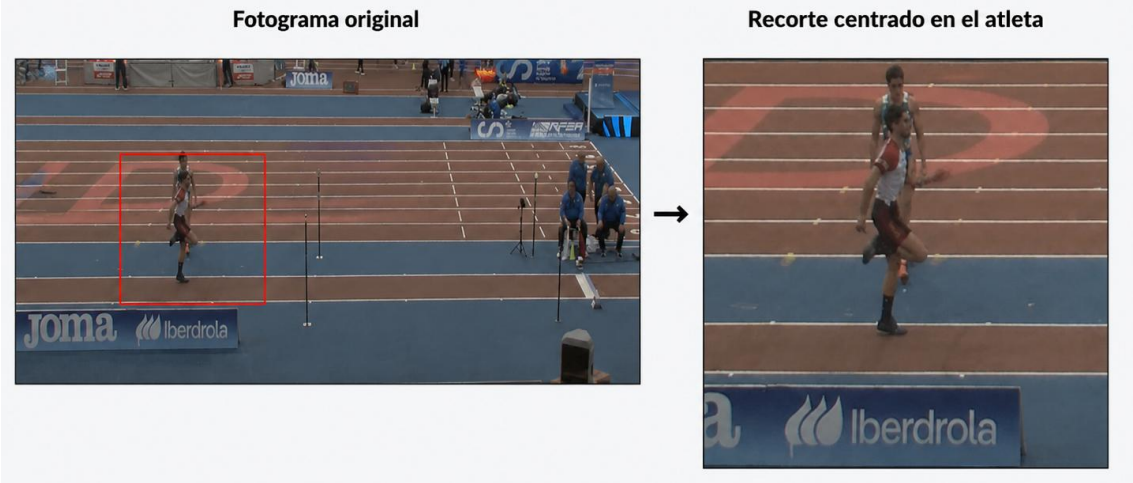


Figura 8 :. Ejemplo de recorte del atleta utilizado para aplicar la estimación de pose sobre una región centrada en el saltador

Trabajar con recortes mejoró la detección, pero también introdujo una dificultad técnica. Las coordenadas obtenidas dentro del recorte no coincidían directamente con las coordenadas del vídeo original. Esto se debe a dos motivos. En primer lugar, el recorte tiene un origen propio dentro del *frame* completo. En segundo lugar, la región recortada se redimensionaba antes de aplicar MediaPipe Pose, por lo que las coordenadas detectadas dentro del recorte procesado debían ajustarse de nuevo al tamaño real de la región original.

Por este motivo, después de aplicar MediaPipe Pose sobre el recorte fue necesario reconstruir las coordenadas para devolverlas al sistema de referencia del vídeo completo. De forma general, si un punto se detectaba en el recorte con coordenadas (x_{crop}, y_{crop}) su posición en el vídeo original se calculó como:

$$x_{orig} = x_{0,crop} + x_{crop} \cdot s_x$$

$$y_{orig} = y_{0,crop} + y_{crop} \cdot s_y$$

donde x_{0crop} e $y_{0,crop}$ representan la posición del origen del recorte dentro del vídeo original. Es decir, indican en qué punto del *frame* completo empieza la ventana recortada. Por su parte, s_x y s_y son los factores de escala horizontal y vertical entre el recorte procesado por MediaPipe y el tamaño real de esa región en el vídeo original.

Estos factores se calcularon dividiendo el tamaño original del recorte entre el tamaño con el que ese recorte fue procesado. Así, s_x indica cuántos píxeles del recorte original equivale cada píxel horizontal del recorte procesado, y s_y cumple la misma función en el eje vertical:

$$s_x = \text{ancho}_{\text{recorte original}} / \text{ancho}_{\text{recorte procesado}}$$

$$s_y = \text{alto}_{\text{recorte original}} / \text{alto}_{\text{recorte procesado}}$$

De forma sencilla, estos factores permiten corregir el cambio de tamaño del recorte. Si el recorte se hubiera procesado con el mismo tamaño que tenía en el vídeo original, entonces $s_x = 1$ y $s_y = 1$. En cambio, si el recorte se redimensiona antes de aplicar MediaPipe, estos factores permiten transformar las coordenadas detectadas para que vuelvan a estar expresadas en el sistema del vídeo completo.

Esta reconstrucción fue necesaria para mantener la coherencia espacial del análisis. Sin ella, las posiciones de tobillos, caderas, rodillas u hombros no serían comparables entre fotogramas, porque cada recorte podía estar situado en una zona distinta de la imagen. Al devolver todas las coordenadas al sistema del vídeo completo, fue posible calcular distancias, desplazamientos y velocidades de forma coherente con la calibración espacial descrita anteriormente.

4.6 Control de calidad y filtrado de pose estimada

Después de aplicar MediaPipe Pose sobre el recorte del atleta, fue necesario comprobar la calidad de las detecciones. Aunque el recorte ayudaba a centrar el análisis en el saltador, no garantizaba que todas las poses detectadas fueran correctas. En algunos fotogramas, MediaPipe podía no detectar ninguna pose, detectar una pose incompleta o confundirse con otra persona cercana.

Por este motivo, primero se comprobó si existía una pose detectada en cada fotograma. Cuando no se detectaba ninguna pose, ese fotograma se marcaba como no válido para el cálculo posterior de variables corporales.

Después se aplicó un filtro para comprobar si la pose detectada pertenecía probablemente al atleta. Este paso era necesario porque MediaPipe podía perder al saltador y detectar a un juez, a otro atleta o a una persona situada cerca de la zona de salto. Para evitarlo, se utilizó la posición media de la cadera, ya reconstruida en coordenadas del vídeo original, y se comparó con el centro del recorte automático generado a partir del movimiento del saltador.

La lógica fue sencilla: si el recorte seguía al atleta, la cadera media detectada por MediaPipe debía quedar cerca del centro de ese recorte. En este trabajo se consideró válida la pose cuando la distancia entre la cadera media detectada y el centro del recorte era igual o inferior a 50 píxeles. Si esa distancia era mayor, la pose se consideraba sospechosa y no se utilizaba.

Además de esa distancia al recorte, se comprobó la continuidad temporal de la cadera. Si la cadera detectada presentaba un salto brusco respecto a la última posición válida, también se descartaba la pose. En concreto, se rechazaban saltos de cadera superiores a 180 píxeles cuando se producían dentro de una ventana corta de 20 fotogramas. Este criterio permitió evitar cambios repentinos de identidad, por ejemplo cuando MediaPipe pasaba de detectar al saltador a detectar otra persona de la escena.

Las poses no válidas no se utilizaron en el cálculo posterior de variables. Esto fue especialmente importante en el caso de la cadera, porque su posición se empleaba después para estimar desplazamientos y velocidades. Si una pose

incorrecta se hubiera mantenido, podía introducir valores erróneos en varias variables del análisis.

Una vez validada la pose del atleta, se aplicó un segundo control sobre los puntos corporales concretos. MediaPipe asigna a cada punto un valor de visibilidad, que indica la confianza de la detección. En este trabajo se utilizó un umbral mínimo de visibilidad de 0,55 para calcular variables angulares. Por ejemplo, para calcular un ángulo de rodilla era necesario que la cadera, la rodilla y el tobillo correspondientes tuvieran una visibilidad igual o superior a 0,55. Si alguno de esos puntos no alcanzaba ese valor, el ángulo no se consideraba válido.

También se filtraron los ángulos con cambios demasiado bruscos entre fotogramas consecutivos. En este caso, se eliminaron valores cuando el cambio superaba los 35 grados, ya que era más probable que se tratara de un error de detección que de un movimiento real del atleta. Después, las series angulares se suavizaron ligeramente mediante una ventana de 5 fotogramas, para reducir pequeñas oscilaciones propias de la estimación automática de pose.

A partir de este filtrado, las coordenadas y ángulos utilizados en los apartados siguientes procedían únicamente de fotogramas en los que la pose cumplía unos criterios mínimos de coherencia y fiabilidad.

4.7 Cálculo de ángulos corporales e inclinación del tronco

A partir de los puntos corporales detectados por MediaPipe Pose se calcularon los ángulos de rodilla, los ángulos de cadera y la inclinación del tronco. Para ello se utilizaron las coordenadas de hombros, caderas, rodillas y tobillos, ya reconstruidas en el sistema de coordenadas del vídeo original.

Los ángulos de rodilla se calcularon utilizando tres puntos de la misma pierna: cadera, rodilla y tobillo. En este caso, la rodilla actuaba como vértice del ángulo. Los ángulos de cadera se calcularon de forma similar, utilizando hombro, cadera y rodilla, siendo la cadera el vértice articular.

De forma general, el ángulo definido por tres puntos (A), (B) y (C), donde (B) es el vértice articular, se realizó mediante el producto escalar entre los vectores ($\overrightarrow{BA}$) y ($\overrightarrow{BC}$):

$$\theta = \arccos\left(\frac{\overrightarrow{BA} \cdot \overrightarrow{BC}}{\left|\overrightarrow{BA}\right|\left|\overrightarrow{BC}\right|}\right)$$

El resultado se expresó en grados:

$$\theta_{grados} = \theta \cdot \frac{180}{\pi}$$

En el caso de la rodilla, los puntos utilizados fueron:

A=cadera ,B=rodilla ,C=tobillo

En el caso de la cadera, los puntos utilizados fueron:

A=hombro ,B=cadera ,C=rodilla

Además de los ángulos articulares, se calculó la inclinación del tronco. Para ello se utilizó el segmento definido por el punto medio de los hombros y el punto medio de las caderas. La inclinación se midió respecto a la vertical mediante el desplazamiento horizontal y vertical entre ambos puntos:

$$\alpha = \arctan2(\Delta x, \Delta y)$$

La Figura 9 muestra de forma esquemática los ángulos considerados en el análisis. En ella se representan los ángulos de rodilla y cadera en ambos lados del cuerpo, así como la inclinación del tronco respecto a la vertical.

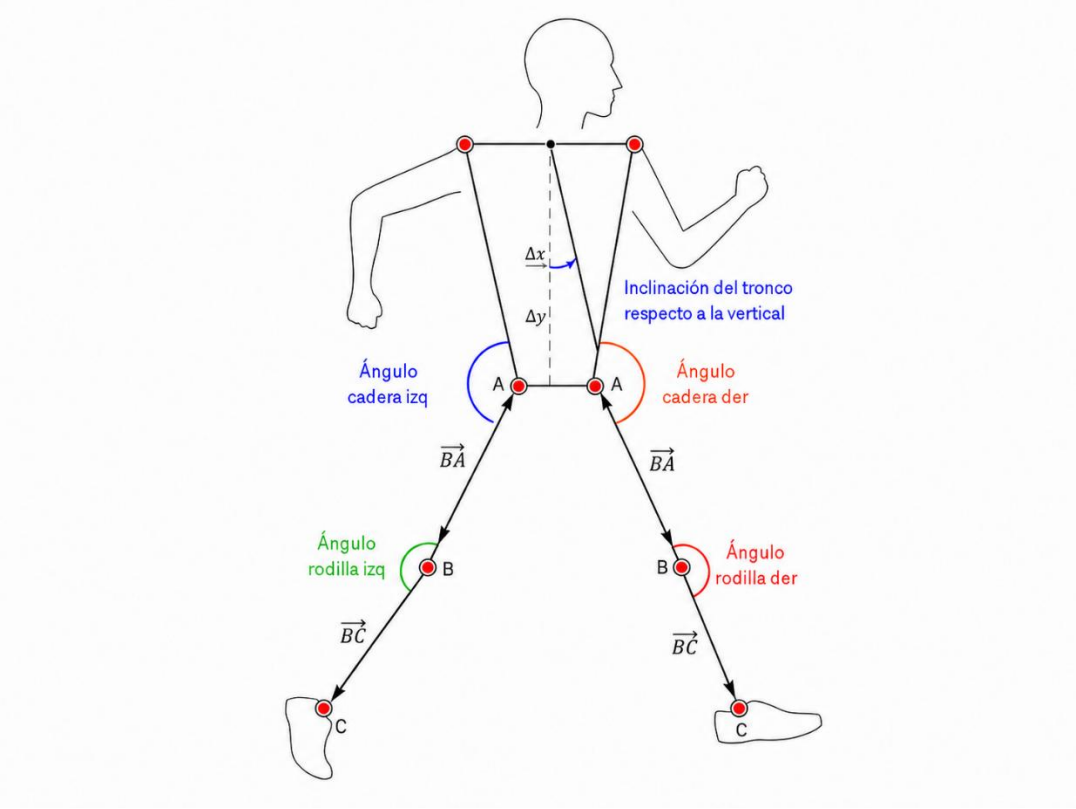


Figura 9 :Representación de los ángulos de rodilla, cadera e inclinación del tronco calculados a partir de los puntos corporales detectados

Como se explicó en el apartado anterior, estos cálculos no se utilizaron sin control. Los ángulos solo se consideraron válidos cuando la pose pertenecía al atleta y los puntos corporales necesarios superaban el umbral mínimo de visibilidad. Además, los valores con cambios excesivamente bruscos entre fotogramas consecutivos se filtraron antes de obtener las variables finales.

4.8 Detección de apoyos y generación de fotogramas clave

Una vez calculada y filtrada la pose del atleta, el siguiente paso fue identificar los apoyos principales de la carrera final y la batida. Para ello se utilizó la posición de los tobillos detectados por MediaPipe, ya reconstruida en coordenadas del vídeo original. La lógica fue localizar los momentos en los que el tobillo se encontraba más bajo en la imagen, ya que esos puntos podían corresponder a contactos del pie con la pista.

Antes de generar los apoyos, se descartaron los fotogramas en los que la pose no había sido validada como perteneciente al atleta. Además, para considerar un tobillo como candidato se exigió una visibilidad mínima de 0,45. De esta forma se evitó utilizar puntos detectados con poca fiabilidad. A partir de esos tobillos válidos, se calculó también la distancia horizontal hasta la tabla de batida mediante la escala definida en la calibración espacial.

Para cada fotograma se seleccionó el tobillo situado más bajo en la imagen. En OpenCV, una coordenada y mayor indica una posición más baja dentro del *frame*, por lo que este criterio permitía localizar los momentos en los que el pie podía estar más cerca del contacto con la pista. A partir de esta señal temporal se buscaron máximos locales, que funcionaban como posibles candidatos de apoyo.

Es importante diferenciar entre candidatos de apoyo y apoyos finales. En una primera fase, el sistema generaba una lista de posibles apoyos a partir de la señal del tobillo. Estos candidatos todavía podían incluir duplicados, detecciones poco claras o puntos que no correspondieran a un contacto real. Por eso, después se aplicaron filtros para quedarse solo con una secuencia final coherente.

Para construir esa secuencia, se aplicaron criterios mínimos de separación temporal y espacial. En concreto, se exigió una separación mínima de 24 fotogramas entre apoyos consecutivos. En el tramo entre el último apoyo y la batida, la separación mínima fue de 38 fotogramas, para evitar confundir la entrada y la salida de un mismo contacto. También se exigió una distancia mínima de 0,75 m entre apoyos y de 1,00 m entre el último apoyo y la batida.

Además, se revisaron posibles apoyos falsos. Si un apoyo aparecía demasiado alto en la imagen, podía tratarse de una detección en fase aérea y no de un contacto real. También se controlaron transiciones poco plausibles entre apoyos: cuando la velocidad estimada entre dos contactos superaba los 13 m/s, el apoyo se consideraba sospechoso y se revisaba como posible falso positivo.

Cuando la secuencia no era suficientemente clara, se aplicaron correcciones automáticas. Por ejemplo, si faltaba el apoyo inmediatamente anterior a la batida, se intentaba recuperar un candidato intermedio en la zona temporal esperada. Si la secuencia parecía contaminada por otra persona o por una detección incoherente, se reconstruía tomando como referencia una batida cercana a la tabla. El objetivo no era eliminar apoyos sin más, sino mantener una secuencia ordenada y compatible con la progresión real del atleta hacia la tabla de batida.

Finalmente, se seleccionaron los últimos seis eventos de la secuencia: los cinco apoyos previos y la batida. Estos eventos se nombraron como apoyo_-5, apoyo_-4, apoyo_-3, apoyo_-2, apoyo_-1 y batida. Esta nomenclatura permitió organizar todos los intentos con la misma estructura, aunque el número total de pasos

visibles variara entre vídeos.

La Figura 10 muestra de forma esquemática este proceso. La señal temporal del tobillo permite localizar candidatos de apoyo y seleccionar la secuencia final hasta la batida. Los puntos azules representan los apoyos previos seleccionados y el punto rojo corresponde a la batida.

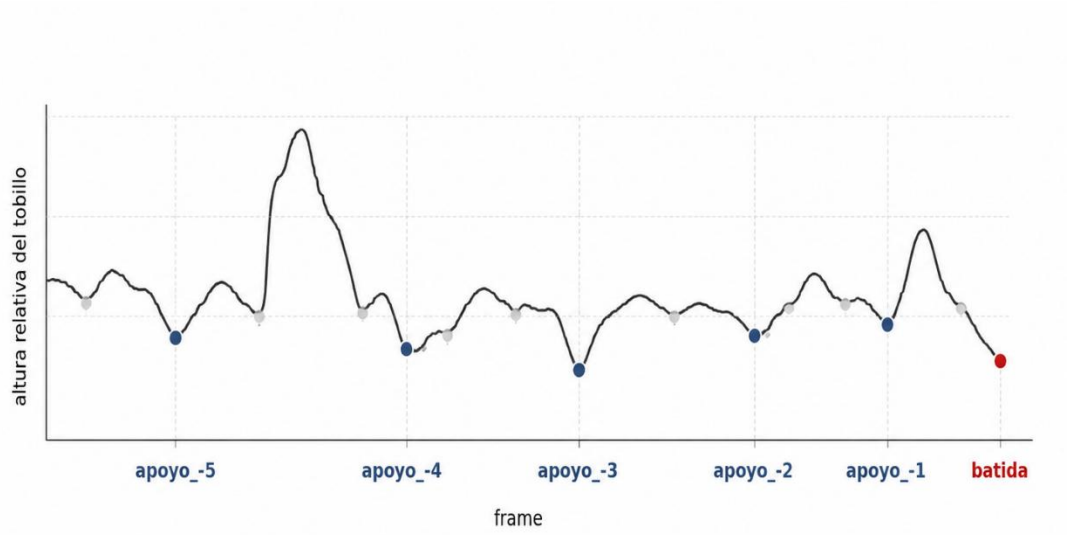


Figura 10 : Generación de fotogramas clave a partir de la secuencia de apoyos. Fuente: elaboración propia.

A partir de esta secuencia se definieron los fotogramas clave de cada intento. Estos fotogramas sirvieron después como referencia para extraer variables técnicas como distancias a la tabla, longitudes entre apoyos, tiempos entre contactos, velocidades medias y ángulos corporales asociados a cada evento.

4.9 Extracción de variables espaciales, temporales y angulares por evento

Una vez definida la secuencia de apoyos y batida, cada evento se utilizó como referencia para extraer variables técnicas del intento. El objetivo fue que todos los saltos quedaran descritos con la misma estructura: cinco apoyos previos y una batida final.

Para cada evento se guardó el fotograma correspondiente, el tiempo en segundos, el lado del apoyo, la posición del tobillo en coordenadas del vídeo original y la distancia horizontal hasta la tabla de batida. Esta distancia se calculó utilizando la calibración espacial definida anteriormente, por lo que quedó expresada en metros.

A partir de la distancia a la tabla de cada apoyo se calcularon también variables entre eventos consecutivos. La longitud entre apoyos se obtuvo como la diferencia de distancia a la tabla entre un apoyo y el siguiente. De esta forma, si un apoyo estaba más lejos de la tabla y el siguiente más cerca, la diferencia entre

ambos representaba el avance horizontal aproximado del atleta en ese tramo.

Además de las variables espaciales y temporales, se asociaron variables angulares a cada evento. Para ello, en torno al fotograma de cada apoyo se buscó el frame con mejor información angular disponible. Esta selección tuvo en cuenta la calidad de los ángulos y la proximidad temporal al evento. De esta forma, cada apoyo quedó asociado a un ángulo de rodilla, un ángulo de cadera y una inclinación del tronco.

En el caso de los ángulos de rodilla y cadera, se utilizó el lado del apoyo correspondiente. Es decir, si el apoyo era izquierdo, se tomaban los ángulos de rodilla y cadera izquierdos; si el apoyo era derecho, se tomaban los del lado derecho. Esto permitió que las variables angulares estuvieran relacionadas con la pierna que realizaba el contacto en cada evento.

Después de calcular estas variables, se aplicaron comprobaciones adicionales sobre la secuencia. Se revisó si existía alternancia entre lados, si la separación temporal entre apoyos era coherente, si la distancia entre apoyos era suficiente y si las longitudes obtenidas estaban dentro de rangos razonables. Estas comprobaciones no sustituyeron la revisión visual, pero ayudaron a identificar intentos o apoyos que podían requerir una comprobación posterior.

Con esta estructura, cada intento pasó de estar representado únicamente por un vídeo a estar descrito mediante una secuencia ordenada de eventos técnicos. Cada evento incluía información espacial, temporal y angular, y sirvió como base para calcular posteriormente las variables de velocidad.

4.10 Cálculo de velocidades

Además de las variables asociadas a la posición de los apoyos y a los ángulos corporales, se incorporaron variables de velocidad. Estas variables buscaban describir tanto la velocidad con la que el atleta llega a la batida como la evolución inmediata después del despegue. Su cálculo requirió diferenciar entre la velocidad de entrada, más estable al depender de la secuencia de apoyos, y la velocidad postbatida, más problemática por las pérdidas de seguimiento del atleta en algunos vídeos.

4.10.1 Velocidad de entrada y estimación inicial de velocidad postbatida

Una parte importante del extractor fue el cálculo de la velocidad de entrada a la batida. Esta variable intentó representar la velocidad horizontal del atleta en los últimos tramos de la aproximación.

La lógica general consistió en calcular el desplazamiento horizontal entre apoyos consecutivos y dividirlo por el tiempo transcurrido. Si dos apoyos se encuentran en los *frames* (frame_1) y (frame_2), el intervalo temporal se obtiene como:

$$\Delta t = \frac{\text{frame}_2 - \text{frame}_1}{\text{FPS}}$$

donde (FPS = 240). El desplazamiento horizontal en metros se obtiene mediante:

$$\Delta x_m = (x_2 - x_1) \cdot \text{escala}$$

Y la velocidad media entre apoyos se calcula como:

$$v = \frac{\Delta x_m}{\Delta t}$$

Se generaron distintas variables de velocidad de entrada: la velocidad del último tramo, la velocidad media de los dos últimos tramos, la velocidad media de los tres últimos tramos y la velocidad directa entre el apoyo inmediatamente anterior y la batida. Además, se definió una variable resumen, denominada velocidad de entrada principal, en la que se priorizó la media de los tres últimos tramos cuando estaba disponible. Si no había suficientes datos válidos, se utilizó la media de dos tramos o, en último caso, la velocidad del último tramo.

Esta estrategia permitió obtener una medida más estable que una única velocidad calculada sobre un solo intervalo. Al utilizar varios tramos, la media reduce el impacto de errores puntuales en la detección de un apoyo concreto. Aun así, estas variables debían interpretarse con cautela, ya que cualquier error en la secuencia de apoyos podía afectar directamente al cálculo de la velocidad.

4.10.2 Velocidad postbatida y *frame* común

Después de calcular la velocidad de entrada, se intentó estimar una variable relacionada con la velocidad posterior a la batida. En una primera estrategia se midió el desplazamiento de la cadera desde la batida hasta un número fijo de *frame*s posteriores, concretamente 10, 15 y 20 *frame*s. Para cada ventana se calcularon velocidades horizontales, verticales y resultantes.

La lógica era calcular la diferencia de posición de la cadera entre el *frame* de batida y el *frame* posterior seleccionado:

$$\Delta x_m = \left(x_{\text{post}} - x_{\text{batida}}\right) \cdot \text{escala}$$
$$\Delta y_m = -\left(y_{\text{post}} - y_{\text{batida}}\right) \cdot \text{escala}$$

El signo negativo en la componente vertical se debe a que en la imagen el eje (y) crece hacia abajo, mientras que en coordenadas físicas se interpreta normalmente como positivo hacia arriba. A partir del desplazamiento y del tiempo transcurrido se calcularon las componentes de velocidad:

$$v_x = \frac{\Delta x_m}{\Delta t}$$
$$v_y = \frac{\Delta y_m}{\Delta t}$$
$$v_{\text{resultante}} = \sqrt{v_x^2 + v_y^2}$$

Sin embargo, esta estrategia resultó inestable. En muchos vídeos no existía una pose válida exactamente a 10, 15 o 20 *frame*s después de la batida. Además, en esos instantes el atleta podía cambiar rápidamente de postura, quedar

parcialmente ocluido o perder temporalmente la detección. Como consecuencia, las velocidades calculadas en ventanas fijas presentaron valores extremos y, en algunos casos, no plausibles.

Por ello, estas velocidades se mantuvieron inicialmente como variables exploratorias, pero no se utilizaron como variables principales del modelo. En su lugar, se desarrolló una alternativa basada en un *frame* común postbatida. Esta solución buscó comparar todos los saltos en un punto temporal más homogéneo y estable después del despegue.

El procedimiento consistió en identificar, para cada vídeo, el primer *frame* posterior a la batida en el que se recuperaba una pose válida, ignorando los *frames* inmediatamente posteriores al despegue. Para evitar tomar *frames* demasiado cercanos a la batida, la búsqueda comenzó a partir de un mínimo de 40 *frames* posteriores:

$$\text{frame}_{\text{minimo}} = \text{frame}_{\text{batida}} + 40$$

Posteriormente, se identificó el mayor retraso de recuperación de pose válida entre los vídeos. Ese desfase se utilizó como offset común para todos los intentos. En el proceso desarrollado, el offset común se situó aproximadamente en 90 *frame*s, equivalente a:

$$\frac{90}{240} = 0.375\,s$$

A partir de ese criterio, para cada salto se intentó utilizar el *frame*:

$$\text{frame}_{\text{objetivo}} = \text{frame}_{\text{batida}} + \text{offset}_{\text{comun}}$$

Si no existía pose válida exactamente en ese *frame*, el sistema buscaba alrededor del objetivo, permitiendo pequeños desplazamientos. De esta forma, se mantuvo la comparabilidad entre vídeos sin exigir que todos tuvieran pose válida exactamente en el mismo *frame*.

En una primera versión, el script de *frame* común solo guardaba el *frame* elegido y las coordenadas de la cadera. Posteriormente se corrigió para calcular también la velocidad media desde la batida hasta ese *frame* postbatida. Esta variable no se interpretó como una velocidad instantánea exacta de salida, sino como una velocidad media entre la batida y un punto común posterior, más estable y comparable entre vídeos.

Para evitar errores, se definió un criterio de validez del *frame* común. Si el *frame* elegido se desviaba demasiado del objetivo común, la velocidad se consideraba no comparable y se trataba como valor ausente. En concreto, se aceptaron únicamente *frames* con una desviación máxima de 10 *frames* respecto al objetivo:

$$|\text{desviacion}_{\text{frames}}| \leq 10$$

Este criterio permitió invalidar únicamente la variable problemática, sin eliminar automáticamente el vídeo completo. Esta decisión fue coherente con el objetivo general de conservar el mayor número posible de intentos y descartar variables concretas solo cuando su cálculo no fuera fiable.

4.11 Construcción de la base final de variables

Una vez extraídas las variables de apoyos, ángulos y velocidades, se organizó toda la información en una base de datos final. El objetivo fue pasar de vídeos individuales a una tabla estructurada, donde cada intento de salto quedara representado por un conjunto de variables comparables.

En esta base, cada fila correspondía a un intento y cada columna a una variable obtenida durante el proceso de extracción. Para mantener una estructura común, todos los saltos se organizaron en torno a los mismos eventos: apoyo_-5, apoyo_-4, apoyo_-3, apoyo_-2, apoyo_-1 y batida. Esto permitió que las variables de todos los intentos siguieran el mismo orden, aunque los vídeos no fueran exactamente iguales en duración o encuadre.

Las variables finales se agruparon en cuatro bloques principales: espaciales, temporales, angulares y de velocidad. Las variables espaciales describían la relación del atleta con la tabla de batida y la longitud entre apoyos; las temporales recogían el momento de cada evento y los intervalos entre ellos; las angulares representaban la postura del atleta mediante los ángulos de rodilla, cadera e inclinación del tronco; y las de velocidad describían tanto la entrada a la batida como la fase inmediatamente posterior al despegue.

También se conservaron algunas variables auxiliares de control, como indicadores de calidad o revisión. Estas variables no se interpretaron como características biomecánicas directas, sino como información útil para comprobar si la extracción había sido fiable.

Cuando una variable no podía calcularse con suficiente fiabilidad, se dejó como valor ausente. Esta decisión evitó introducir datos forzados o poco plausibles. Así, un intento podía conservarse en la base aunque alguna variable concreta no estuviera disponible o no fuera suficientemente fiable.

La base final resultante fue la entrada para las fases posteriores del trabajo. A partir de ella se realizó la revisión de los datos, el análisis exploratorio y la preparación de las variables que después se utilizarían en los modelos de aprendizaje automático.

4.12 Resumen de decisiones metodológicas principales del extractor

La Tabla 3 resume las principales decisiones metodológicas adoptadas durante el desarrollo del extractor. Estas decisiones no se plantearon de forma arbitraria, sino como respuesta a problemas observados durante la revisión de los vídeos y de las salidas intermedias.

Tabla 3: Decisiones metodológicas principales del sistema de extracción.

Decisión metodológica	**Problema detectado**	**Criterio adoptado**	**Justificación**
Calibración espacial común	Pequeñas diferencias manuales al calibrar vídeo a vídeo	Escala fija basada en 3 m y 238 píxeles	Mantener coherencia entre intentos y reducir ruido artificial
Uso de recortes del atleta	Riesgo de detectar jueces u otras personas	Aplicar pose sobre una región centrada en el saltador	Mejorar la detección y reducir interferencias del entorno
Reconstrucción de coordenadas originales	Las coordenadas del crop no son comparables directamente	Sumar shifts y factores de escala del recorte	Calcular distancias en el sistema del vídeo completo
Filtro de identidad de pose	MediaPipe podía detectar otra persona	Validar la pose por proximidad al crop del atleta	Reducir detecciones incorrectas
Sistema de candidatos de apoyo	Apoyos falsos o incompletos	Seleccionar contactos mediante filtros temporales y espaciales	Mejorar la plausibilidad de la secuencia de apoyos
Uso de cuatro apoyos previos	El quinto apoyo no era fiable en todos los vídeos	Calcular variables sobre los cuatro últimos apoyos	Mantener información técnica sin forzar datos inestables
Velocidad de entrada principal	Redundancia entre velocidades de entrada	Usar una variable resumen basada en varios tramos	Reducir sensibilidad a errores puntuales
Descarte de velocidades a 10, 15 y 20 frames	Valores extremos y pérdida de pose postbatida	No usarlas como variables principales	Evitar variables inestables
Frame común postbatida	Recuperación de pose en momentos distintos	Usar un offset común posterior a la batida	Mejorar comparabilidad entre vídeos

Decisión metodológica	Problema detectado	Criterio adoptado	Justificación
Criterio de validez del frame común	Algunos frames elegidos podían alejarse demasiado del objetivo	Aceptar desviación máxima de 10 frames	Invalidar solo variables no comparables
Imputación dentro del pipeline	Existencia de algunos valores ausentes biomecánicos	Imputación por mediana en el entrenamiento	Evitar eliminar intentos y prevenir fuga de información

En conjunto, estas decisiones permitieron pasar de una extracción inicial más frágil a un sistema más estable y trazable. La metodología no elimina todas las limitaciones del vídeo real, pero sí establece criterios explícitos para reducir errores, identificar variables problemáticas y conservar la mayor cantidad posible de información útil.

5 Preparación del dataset, limpieza y modelado

Una vez construidas las variables técnicas a partir de los vídeos, el siguiente paso fue preparar el dataset para su uso en aprendizaje automático. Este capítulo explica cómo se organizó la información final, cómo se revisó la calidad de los datos y qué criterios se siguieron antes de entrenar los modelos.

En este caso, no se partía de una base de datos ya existente, sino de variables generadas a partir de los vídeos de competición. Por eso, antes de modelar fue necesario comprobar que esas variables fueran coherentes, detectar posibles errores de extracción y preparar el dataset de forma ordenada.

La preparación del dataset se realizó con un criterio agnóstico respecto al modelo. Es decir, las decisiones de limpieza y organización de variables no se tomaron para favorecer un algoritmo concreto, sino a partir de criterios generales de calidad del dato, interpretabilidad técnica y coherencia con el proceso de extracción.

El capítulo se organiza en dos partes. En primer lugar, se describe el dataset final y el proceso de limpieza y revisión de calidad. Después, se explican las tareas de modelado planteadas, los paquetes de variables utilizados y los modelos aplicados. Los resultados concretos de esos modelos se presentan en el capítulo siguiente.

5.1 Construcción del dataset final

El dataset final se construyó uniendo la información extraída de los vídeos con los datos competitivos asociados a cada intento. Cada fila del dataset corresponde a un intento de salto y cada columna representa una variable concreta, ya sea una variable técnica obtenida del vídeo, una variable identificativa o una variable objetivo utilizada posteriormente en el modelado.

La unidad de análisis fue el intento individual. Esta decisión permitió tratar cada salto como una observación propia, manteniendo al mismo tiempo la conexión con el vídeo original. Para ello, se conservó un identificador de vídeo en cada registro, de forma que cualquier caso problemático pudiera revisarse después sobre el material audiovisual.

En el dataset se integraron tres tipos principales de información. En primer lugar, las variables biomecánicas extraídas automáticamente desde vídeo, como distancias a la tabla, longitudes entre apoyos, tiempos entre eventos, ángulos corporales y variables de velocidad. En segundo lugar, la información competitiva del intento, especialmente si el salto fue válido o nulo y la marca oficial cuando existía. Por último, se incorporó información histórica del atleta para calcular un nivel de referencia individual, utilizado después para construir una variable de rendimiento relativo.

Esta organización permitió plantear varias tareas de aprendizaje automático a partir del mismo dataset. La variable de validez del intento permitió formular un problema de clasificación entre saltos válidos y nulos. La marca oficial permitió plantear una tarea de regresión sobre el rendimiento absoluto, limitada a los intentos válidos. Finalmente, la comparación entre la marca del intento y el nivel de referencia del atleta permitió definir una segunda tarea de regresión, orientada al rendimiento relativo.

Tras la unión de las fuentes y la revisión inicial, el dataset final quedó formado por 66 intentos, correspondientes a 66 vídeos únicos. El conjunto incluyó 75 columnas, de las cuales 64 correspondían a variables biomecánicas potencialmente utilizables como predictoras. El resto de columnas recogían información identificativa, resultado competitivo, condición de salto válido o nulo, nivel de referencia del atleta y variables derivadas del rendimiento.La Tabla 4 resume el dataset final utilizado para los modelos.

Tabla 4: Resumen del dataset final utilizado para modelado

Elemento	**Valor**
Intentos totales analizados	66
Vídeos únicos	66
Columnas totales del dataset	75
Variables biomecánicas disponibles	64
Saltos válidos	42
Saltos nulos	24
Casos sin nivel de referencia individual	7
Casos sin marca oficial en metros	24
Casos sin rendimiento relativo (marca_vs_nivel_cm)	27

La distribución entre saltos válidos y nulos muestra que la clase mayoritaria corresponde a los intentos válidos. Aun así, el número de saltos nulos fue suficiente para plantear una tarea de clasificación binaria. En este trabajo, la detección del salto nulo resulta especialmente relevante, ya que permite analizar si las variables extraídas de la carrera final, la batida y la postura del atleta contienen información asociada a la validez del intento.

Por último, las variables biomecánicas se organizaron en bloques o paquetes de análisis. Esta división permitió evaluar por separado distintos tipos de información técnica, en lugar de utilizar únicamente el conjunto completo de variables. Así, en las fases posteriores se compararon paquetes de variables angulares, variables de velocidad, variables temporales y espaciales, combinaciones de estas, y el conjunto completo de variables biomecánicas.

5.1.1 Decisión de utilizar cuatro apoyos previos

En una primera versión del dataset se valoró utilizar los cinco apoyos previos a la batida. La idea tenía sentido, porque los últimos pasos de la carrera de aproximación son importantes para preparar el despegue. Sin embargo, al revisar los vídeos y las variables extraídas se observó que el quinto apoyo anterior no aparecía con la misma fiabilidad en todos los intentos.

En algunos vídeos, los cuatro últimos apoyos previos a la batida estaban bien localizados, pero el quinto apoyo quedaba fuera de la zona de análisis, aparecía parcialmente o no cumplía los criterios mínimos de detección. Forzar su uso habría podido introducir ruido en el dataset o provocar la pérdida de intentos que sí eran válidos para el resto del análisis.

Por este motivo, se decidió utilizar como base principal los últimos cuatro apoyos previos a la batida. Esta decisión permitió conservar información suficiente sobre la fase final de la carrera sin depender de un apoyo que no estaba disponible de forma consistente en todos los vídeos.

A partir de esos cuatro apoyos se calcularon variables agregadas, como medias y desviaciones típicas de longitudes de paso, tiempos entre apoyos, velocidades y ángulos. Estas variables resultaban más estables que depender únicamente de valores aislados de un apoyo concreto, especialmente teniendo en cuenta que el dataset era reducido y procedía de vídeos reales de competición.

5.2 Limpieza y control de calidad del dataset

Una vez construido el dataset inicial, se realizó una fase de limpieza y control de calidad antes de entrenar los modelos. Esta revisión fue necesaria porque las variables no procedían de una base de datos ya validada, sino de un proceso automático de extracción desde vídeo. Por tanto, aunque el extractor ya incorporaba filtros de calidad, era necesario comprobar el comportamiento del dataset completo antes de utilizarlo en aprendizaje automático.

La limpieza se centró en revisar tres aspectos principales: la presencia de valores ausentes, la existencia de valores extremos y la calidad general de cada intento. Esta revisión se hizo tanto a nivel de variable como a nivel de vídeo, ya que un error podía afectar solo a una variable concreta o, en algunos casos, a un intento completo.

En primer lugar, se revisaron los valores ausentes. No todos tenían el mismo significado. En las variables biomecánicas, un valor ausente podía deberse a una pérdida de pose, a una detección poco fiable o a una decisión de limpieza después de revisar un valor no plausible. En cambio, la ausencia de marca oficial en un salto nulo no se consideró un error del dataset, sino una consecuencia normal de la competición: un intento nulo no tiene una marca válida comparable con un salto válido.

Esta diferencia fue importante para el tratamiento posterior. Los valores ausentes en variables predictoras podían imputarse dentro de los pipelines de modelado, siempre sin utilizar información del conjunto de validación. Sin embargo, las variables objetivo no se imputaron. Por ejemplo, no tendría sentido asignar una marca artificial a un salto nulo para incluirlo en una regresión de rendimiento. Por este motivo, los modelos de regresión se construyeron únicamente con los intentos que tenían una marca válida.

También se revisaron los valores extremos. Esta revisión no se utilizó para eliminar datos automáticamente, sino para detectar posibles errores de extracción. En un gesto deportivo real, un valor extremo puede aparecer por una característica técnica del salto, pero también puede deberse a un fallo de seguimiento, una mala detección de la pose o una pérdida temporal del atleta. Por eso, los outliers se analizaron con cautela y se clasificaron según su posible origen.

Para detectar estos casos se utilizaron criterios robustos, como el rango intercuartílico y el z-score robusto basado en la desviación absoluta mediana. El objetivo no fue borrar cualquier valor alejado de la media, sino identificar valores sospechosos que necesitaran revisión. La clasificación completa de outliers se incluye en el Apéndice A, para mantener la trazabilidad sin sobrecargar el texto principal.

A partir de esta revisión, algunos valores se conservaron porque podían representar variabilidad real del salto, mientras que otros se trataron como valores ausentes cuando eran claramente incompatibles con el movimiento esperado o con la lógica de la variable. Esta decisión permitió corregir errores puntuales sin eliminar necesariamente el intento completo.

Además de revisar variables aisladas, también se revisó la calidad por vídeo. Esta comprobación fue importante porque algunos intentos podían presentar más problemas que otros: interferencias visuales, pérdida del atleta, oclusiones o errores acumulados en varios puntos del proceso. Cuando un vídeo presentaba problemas demasiado amplios, podía excluirse del dataset final. En cambio, si el problema afectaba solo a una variable concreta, se mantuvo el intento y se trató únicamente esa variable.

La limpieza final siguió una idea sencilla: conservar toda la información útil posible, pero sin forzar datos que no fueran fiables. Por eso, se priorizó convertir en ausentes los valores problemáticos antes que eliminar registros completos. Esta estrategia era especialmente importante por el tamaño reducido del dataset, ya que perder muchos intentos habría limitado aún más el modelado posterior.

El proceso de limpieza también mantuvo la trazabilidad mediante el identificador del vídeo. Esto permitió relacionar cada fila del dataset con el intento original y revisar casos concretos cuando aparecían valores dudosos. De esta forma, la limpieza no se basó solo en criterios numéricos, sino también en la posibilidad de volver al vídeo y comprobar si el valor tenía sentido.

En conjunto, esta fase permitió obtener un dataset más estable para el modelado. No eliminó todas las limitaciones propias de trabajar con vídeo real de competición, pero sí redujo el impacto de errores evidentes de extracción y dejó diferenciados los valores ausentes, los outliers revisados y las variables que podían utilizarse con mayor confianza en las fases posteriores.

La Tabla 5resume los principales elementos revisados durante esta fase y el criterio aplicado en cada caso. El detalle completo de los valores atípicos revisados y su clasificación se recoge en el Apéndice A, para mantener la trazabilidad sin cargar el texto principal con tablas demasiado extensas.

Tabla 5: Resumen de la limpieza y control de calidad del dataset

Elemento revisado	Criterio aplicado	Decisión
Valores ausentes biomecánicos	Pérdida de pose, fallo de extracción o valor no plausible	Se mantienen como ausentes y se imputan posteriormente dentro del pipeline cuando actúan como predictores.
Marca oficial ausente	Saltos nulos sin resultado válido	No se imputa. Los saltos nulos se excluyen de las tareas de regresión que necesitan una marca real.
Nivel de referencia ausente	Falta de histórico suficiente o referencia individual disponible	No se fuerza un valor artificial. Estos casos no se utilizan en la regresión de rendimiento relativo.
Outliers	Valores extremos detectados mediante criterios robustos y revisados con lógica técnica	Se conservan si son plausibles; si se consideran errores de extracción, se tratan como valores ausentes.
Vídeos problemáticos	Errores amplios de tracking, oclusiones o fallos acumulados en la extracción	Se revisan individualmente. Si el problema afecta al intento completo, puede excluirse del dataset final.
Variables auxiliares de calidad	Indicadores relacionados con el proceso de extracción	Se usan como apoyo diagnóstico, no como variables biomecánicas principales.

5.3 Calidad del dato y tratamiento de valores ausentes

Antes de entrenar los modelos, se revisó la presencia de valores ausentes en el dataset final. Esta revisión fue necesaria porque no todos los valores faltantes tenían el mismo significado. Algunos estaban asociados a limitaciones de la extracción biomecánica, mientras que otros eran consecuencia natural de la lógica competitiva del salto de longitud.

Los valores ausentes en variables biomecánicas fueron muy reducidos. En total se identificaron 9 valores ausentes en variables biomecánicas, lo que representa únicamente el 0,213 % de los valores de ese bloque. Estos casos procedían de valores faltantes o de outliers críticos convertidos a NaN tras la revisión de calidad. Dado que su presencia era baja, no se eliminaron intentos completos por este motivo. En su lugar, se mantuvieron en el dataset y se imputaron dentro

de los pipelines de aprendizaje automático, evitando así introducir fuga de información.

Por otro lado, los valores ausentes en marca_m y marca_vs_nivel_cm tienen una interpretación diferente. En los saltos nulos no existe una marca válida, por lo que la ausencia de marca_m no debe considerarse un error del dataset, sino una consecuencia del propio reglamento de la prueba. Del mismo modo, si no existe marca válida, tampoco puede calcularse la diferencia respecto al nivel del atleta. Por esta razón, esos valores no se imputaron en las tareas de regresión, sino que los saltos nulos quedaron excluidos de los modelos que necesitaban una marca real como variable objetivo.

Para resumir esta revisión, la Tabla 6 recoge los principales valores ausentes detectados en el dataset final. La tabla distingue entre ausencias asociadas a variables biomecánicas, que proceden del proceso de extracción, y ausencias derivadas de la propia lógica competitiva, como ocurre con la marca oficial en los saltos nulos.

Tabla 6: Valores ausentes en el dataset final.

Elemento	**Número de valores ausentes**	**Porcentaje / interpretación**
Valores ausentes totales	67	1,354 % del dataset
Valores ausentes en variables biomecánicas	9	0,213 % del bloque biomecánico
marca_m	24	Asociados a saltos nulos
marca_vs_nivel_cm	27	Saltos nulos o falta de nivel individual
nivel_referencia_pc	7	Atletas sin histórico suficiente o referencia disponible

Además del resumen numérico, se representó la distribución de valores ausentes por variable. Esta visualización de la Figura 11 permite comprobar de forma rápida si las ausencias se concentran en unas pocas variables concretas o si aparecen de manera dispersa en todo el dataset.

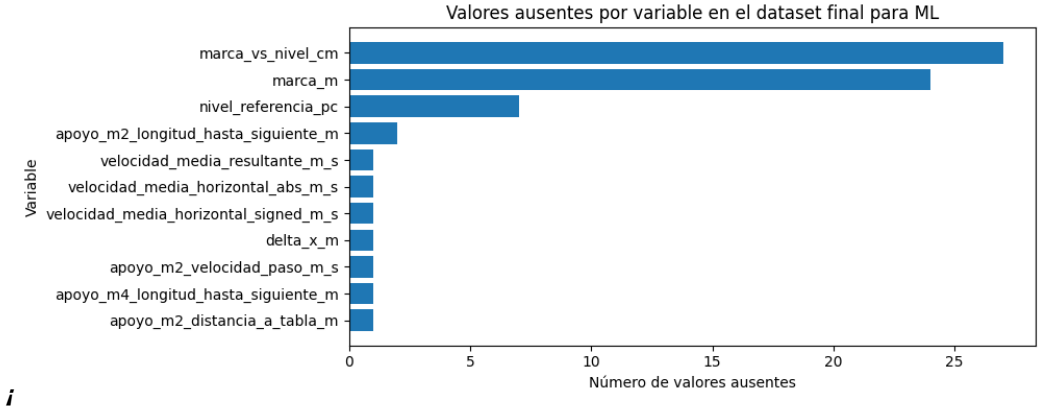


Figura 11: Distribución de valores ausentes por variable en el dataset final de modelado.

Esta distinción es relevante metodológicamente. Imputar una marca a un salto nulo habría introducido una información artificial y conceptualmente incorrecta, porque el nulo no equivale a una marca desconocida, sino a la ausencia de resultado válido. En cambio, imputar valores biomecánicos dentro del pipeline sí es aceptable cuando se realiza exclusivamente sobre variables predictoras y dentro de cada proceso de validación cruzada.

Además de los valores ausentes, se revisaron valores atípicos mediante criterios robustos. La detección de outliers se utilizó como herramienta diagnóstica y no como mecanismo automático de eliminación. Esto es importante porque, en un gesto deportivo real, un valor extremo puede deberse tanto a un error de extracción como a una situación técnica singular del propio salto. Por ello, solo los valores considerados físicamente no plausibles o claramente asociados a errores de extracción fueron candidatos a convertirse en valores ausentes.

En conjunto, la revisión de calidad permitió conservar el mayor número posible de intentos, evitando una limpieza excesivamente agresiva. Esta decisión resulta coherente con el tamaño reducido de la muestra: eliminar demasiados registros habría debilitado aún más la capacidad de generalización de los modelos. Por tanto, la estrategia seguida buscó un equilibrio entre depurar errores evidentes y mantener la variabilidad real de la competición.

5.4 Análisis de correlación y redundancia entre variables

Después de revisar los valores ausentes y los posibles outliers, se analizó la relación entre las variables biomecánicas del dataset. Este paso fue necesario porque muchas variables proceden de una misma secuencia técnica del salto y, por tanto, podían estar relacionadas entre sí.

Por ejemplo, las longitudes entre apoyos, los tiempos entre apoyos y las velocidades de paso no son variables completamente independientes. La velocidad se calcula a partir de una distancia y un tiempo, por lo que era esperable que existieran relaciones entre estos bloques. Algo similar podía ocurrir con algunas variables angulares, especialmente cuando se calculaban en momentos cercanos del salto o sobre el mismo lado del cuerpo.

El objetivo de este análisis no fue eliminar variables de forma automática, sino detectar posibles redundancias. En un dataset pequeño, incluir muchas

variables muy parecidas puede dificultar el modelado, porque aumenta la dimensionalidad sin aportar necesariamente información nueva. Además, una correlación alta entre variables puede hacer que algunos modelos sean menos estables o más difíciles de interpretar.

Por este motivo, se revisaron las correlaciones entre las variables predictoras. Esta revisión permitió identificar grupos de variables con comportamientos similares y ayudó a organizar mejor los paquetes utilizados después en el modelado. En concreto, se mantuvo la división entre variables angulares, variables de velocidad, variables temporales y espaciales, combinación de velocidad con temporales/espaciales y conjunto completo de variables biomecánicas.

La revisión de correlaciones también ayudó a interpretar los resultados posteriores. Si dos variables estaban muy relacionadas, no tenía sentido analizarlas como si aportaran información totalmente independiente. En cambio, podían entenderse como formas distintas de representar una misma parte del gesto técnico.

En este trabajo, la correlación se utilizó como herramienta de diagnóstico, no como único criterio de selección. Es decir, una variable no se descartó únicamente por estar correlacionada con otra, sino que se valoró también su significado técnico, su calidad de extracción y su papel dentro del bloque de variables al que pertenecía.

Esta decisión fue importante para mantener un criterio agnóstico antes del modelado. La selección y organización de variables no se realizó en función de qué combinación mejoraba más un modelo concreto, sino a partir de criterios previos de coherencia, redundancia e interpretabilidad. De esta forma, los modelos posteriores pudieron compararse sobre paquetes de variables definidos de manera ordenada y no ajustados artificialmente a un resultado determinado.

5.5 Criterio agnóstico de preparación de datos

La preparación del dataset se realizó antes de comparar los modelos. La idea fue dejar una base limpia y coherente sin tomar decisiones pensando en favorecer un algoritmo concreto. Es decir, las variables no se conservaron o descartaron porque mejorasen una métrica, sino por criterios de calidad, sentido técnico e interpretabilidad.

Este criterio era importante porque el número de intentos era reducido y las variables procedían de un proceso automático de extracción desde vídeo. En este contexto, ajustar demasiado la limpieza a un resultado concreto podía llevar a conclusiones poco fiables. Por eso, primero se revisaron los datos y después se aplicaron las mismas reglas de preparación a todos los modelos.

Los valores ausentes en variables predictoras se trataron dentro de los propios pipelines de modelado. De esta forma, la imputación se realizaba solo con la información disponible en cada fase de entrenamiento y se evitaba introducir información externa. En cambio, los valores ausentes en variables objetivo no se imputaron. Por ejemplo, en un salto nulo no existe una marca oficial válida, por lo que no tendría sentido asignarle una marca artificial.

También se separaron claramente las variables predictoras, las variables objetivo y las variables identificativas. Las variables identificativas, como el vídeo o el atleta, se conservaron para poder revisar los casos, pero no se usaron como entrada de los modelos. Del mismo modo, se evitaron variables que pudieran contener información demasiado directa sobre el resultado que se quería predecir.

Los paquetes de variables se definieron por su naturaleza técnica: variables angulares, variables de velocidad, variables temporales y espaciales, combinación de velocidad con temporales y espaciales, y conjunto completo de variables biomecánicas. Esta división se hizo antes de revisar qué modelo funcionaba mejor, para poder comparar los bloques de información de forma más limpia.

Con este criterio, el objetivo no fue construir una base adaptada a un modelo concreto, sino preparar los datos de forma ordenada para que todos los modelos se evaluaran bajo condiciones comparables.

5.6 Definición de las tareas de modelado

Una vez preparado el dataset, se definieron las tareas de aprendizaje automático que se iban a estudiar. Todas ellas se plantearon como problemas supervisados, porque en cada caso existía una variable objetivo conocida: la validez del intento, la marca oficial o el rendimiento respecto al nivel del atleta.

La primera tarea fue la clasificación de saltos válidos y nulos. En este caso, el objetivo fue predecir si un intento era válido o nulo a partir de las variables biomecánicas extraídas del vídeo. Esta tarea utilizó todos los intentos disponibles, ya que tanto los saltos válidos como los nulos tenían una etiqueta clara. La clase nula tenía especial interés porque representa los intentos en los que el atleta no obtiene una marca válida.

La segunda tarea fue la predicción de la marca absoluta. En este caso, el objetivo fue estimar la marca oficial del salto, expresada en centímetros. Esta tarea solo podía realizarse con saltos válidos, porque los saltos nulos no tienen una marca oficial comparable. Por tanto, los intentos nulos se excluyeron de esta regresión.

La tercera tarea fue la predicción del rendimiento relativo respecto al nivel del atleta. Para ello se utilizó una variable derivada que comparaba la marca del intento con el nivel de referencia individual del atleta. Esta variable permitió analizar el rendimiento de una forma más contextualizada. No es lo mismo saltar una determinada marca para un atleta con un nivel habitual muy alto que para otro con un nivel de referencia más bajo.

La diferencia entre la marca absoluta y el rendimiento relativo fue importante para el enfoque del trabajo. La marca absoluta refleja el resultado directo del salto, mientras que el rendimiento relativo intenta valorar si ese intento fue mejor o peor respecto al nivel del propio atleta. Por eso, esta tercera tarea solo pudo utilizar los casos en los que existía una marca válida y también un nivel de referencia disponible.

De esta forma, el modelado quedó organizado en tres problemas: una clasificación válido/nulo y dos tareas de regresión. Esta separación permitió evaluar si las variables extraídas del vídeo podían aportar información tanto sobre la validez del intento como sobre el rendimiento obtenido.

5.7 Paquetes de variables utilizados

Para entrenar los modelos no se utilizó únicamente un conjunto único de variables, sino varios paquetes de análisis. Esta decisión permitió comparar si determinados tipos de información biomecánica aportaban más valor que otros en las tareas de clasificación y regresión.

Los paquetes se definieron a partir de la naturaleza técnica de las variables. De esta forma, se separaron las variables angulares, las variables de velocidad y las variables temporales y espaciales. Además, se creó un paquete combinado de velocidad con variables temporales y espaciales, y un último paquete con todas las variables biomecánicas disponibles.

Esta organización permitió estudiar el comportamiento de los modelos desde una perspectiva más interpretativa. Por ejemplo, un modelo entrenado solo con variables angulares permite valorar si la postura del atleta en los apoyos y en la batida contiene información suficiente para la predicción. En cambio, un modelo basado en velocidades o en variables temporales y espaciales se centra más en la estructura de la carrera final y del despegue.

La Tabla 6 resume los paquetes de variables utilizados en el modelado. El diccionario completo de variables finales, con su nombre, categoría y descripción, se incluye en el Apéndice B.

Tabla 6: Paquetes de variables utilizados en el modelado.

Paquete de variables	**Contenido general**
Angulares	Ángulos de rodilla, cadera, inclinación del tronco y variables relacionadas
Velocidades	Velocidad de entrada, velocidad media postbatida y variables derivadas
Temporales/espaciales	Tiempos entre eventos, distancias a tabla, longitudes entre apoyos y desplazamientos
Velocidades + temporales/espaciales	Combinación de información cinemática y organización espacial de la carrera final
Todas las biomecánicas	Conjunto completo de variables técnicas disponibles tras la revisión

Esta división no buscó seleccionar el paquete que mejor funcionara desde el principio, sino comparar de forma ordenada distintos tipos de información. Así, los resultados posteriores permiten interpretar no solo qué modelo obtiene mejores métricas, sino también qué bloque de variables parece aportar más información en cada tarea.

5.8 Modelos, pipelines y criterios de evaluación

Para evaluar la capacidad predictiva de las variables biomecánicas se utilizaron modelos clásicos de aprendizaje automático supervisado. La elección de estos modelos respondió a las características del problema: el dataset tenía un tamaño reducido, las variables eran tabulares y el objetivo principal no era aplicar modelos complejos, sino comprobar si la información extraída de los vídeos podía aportar valor en tareas de clasificación y regresión.

Todos los modelos se implementaron en Python mediante la biblioteca scikit-learn. La preparación de los datos se integró dentro de pipelines, de forma que operaciones como la imputación de valores ausentes y la estandarización se aplicaron dentro de cada proceso de entrenamiento y validación. Esta decisión permitió evitar que la información del conjunto de validación influyera en el entrenamiento del modelo.

En todas las tareas se incluyó un modelo Dummy como referencia básica. Este modelo no pretende aprender una relación real entre variables, sino establecer un punto mínimo de comparación. Así, cualquier modelo entrenado con variables biomecánicas debía demostrar que era capaz de mejorar una estrategia simple basada en la distribución de las clases, en clasificación, o en la media o mediana del conjunto de entrenamiento, en regresión.

5.8.1. Modelos de clasificación

La tarea de clasificación consistió en predecir si un intento era válido o nulo a partir de las variables biomecánicas extraídas del vídeo. Para esta tarea se utilizaron cinco modelos: Dummy Classifier, Regresión Logística, SVM, Random Forest Classifier y Gradient Boosting Classifier.

El Dummy Classifier se utilizó como modelo base. En este caso se evaluaron estrategias simples como predecir siempre la clase mayoritaria o generar predicciones respetando la distribución de clases. Su función fue comprobar si los modelos reales aportaban información más allá de una regla mínima.

La Regresión Logística se incluyó como modelo lineal de clasificación binaria. Este modelo estima la probabilidad de que un intento pertenezca a una clase determinada. Es útil porque permite analizar una primera relación lineal entre las variables biomecánicas y la validez del salto. El parámetro principal evaluado fue C, que controla la regularización. Valores bajos de C aplican más regularización y producen modelos más simples; valores altos permiten ajustar más el modelo a los datos, aunque pueden aumentar el riesgo de sobreajuste. También se evaluó class_weight, que permite dar más peso a una clase cuando existe cierto desequilibrio entre saltos válidos y nulos.

El modelo SVM se utilizó únicamente en la tarea de clasificación. Este algoritmo busca una frontera de decisión que separe las clases con el mayor margen posible. Se evaluaron kernels lineales y RBF. El kernel lineal permite comprobar si la separación entre saltos válidos y nulos puede aproximarse mediante una frontera simple, mientras que el kernel RBF permite representar relaciones no lineales. El parámetro C controla el equilibrio entre margen amplio y errores de clasificación: valores bajos generan modelos más conservadores y valores altos permiten ajustar más los datos. El parámetro gamma, en el kernel RBF, controla

la influencia de cada observación; valores altos pueden producir fronteras más ajustadas y sensibles, mientras que valores bajos generan fronteras más suaves. Al igual que en la Regresión Logística, class_weight se evaluó para comprobar si compensar el peso de las clases mejoraba la detección de saltos nulos.

El Random Forest Classifier se incluyó como modelo basado en árboles de decisión. Este modelo combina varios árboles entrenados con cierto grado de aleatoriedad y permite capturar relaciones no lineales entre variables. Los parámetros evaluados controlan la complejidad del bosque. n_estimators indica el número de árboles; un número mayor suele estabilizar las predicciones, aunque aumenta el coste computacional. max_depth limita la profundidad de cada árbol; profundidades mayores permiten modelos más flexibles, pero también pueden favorecer el sobreajuste. min_samples_leaf establece el número mínimo de observaciones en una hoja, ayudando a evitar divisiones demasiado específicas. max_features define cuántas variables puede considerar cada árbol en cada división, lo que influye en la diversidad de los árboles. También se evaluó class_weight para valorar el efecto del desequilibrio entre clases.

El Gradient Boosting Classifier se utilizó como segundo modelo de árboles. A diferencia de Random Forest, construye los árboles de forma secuencial, de manera que cada nuevo árbol intenta corregir los errores cometidos por los anteriores. Sus principales parámetros fueron n_estimators, learning_rate, max_depth, min_samples_leaf y subsample. n_estimators indica el número de árboles añadidos al modelo. learning_rate controla cuánto aporta cada árbol nuevo; valores bajos suelen hacer el aprendizaje más gradual, pero pueden necesitar más árboles. max_depth limita la complejidad de cada árbol. min_samples_leaf evita hojas con muy pocos casos y subsample permite entrenar cada árbol con una parte de los datos, lo que puede reducir el sobreajuste.

La Tabla 7 resume los modelos e hiperparámetros evaluados en las tareas de clasificación.

Tabla 7: Modelos e hiperparámetros evaluados en la tarea de clasificación.

Modelo	**Preprocesamiento**	**Hiperparámetros evaluados**
Dummy Classifier	No requiere escalado	strategy: most_frequent, stratified
Regresión Logística	Imputación por mediana + estandarización	C: 0.01, 0.1, 1, 10; class_weight: None, balanced
SVM	Imputación por mediana + estandarización	kernel: linear, rbf; C: 0.1, 1, 10; gamma: scale, 0.01, 0.1; class_weight: None, balanced
Random Forest	Imputación por mediana	n_estimators: 100, 300; max_depth: None, 3, 5; min_samples_leaf: 1, 2, 4; max_features: sqrt, log2; class_weight:

Modelo	Preprocesamiento	Hiperparámetros evaluados
Classifier		None, balanced
Gradient Boosting Classifier	Imputación por mediana	n_estimators: 50, 100; learning_rate: 0.03, 0.1; max_depth: 2, 3; min_samples_leaf: 1, 3; subsample: 0.8, 1.0

5.8.2. Modelos de regresión

Las tareas de regresión tuvieron como objetivo predecir dos variables continuas: la marca absoluta del salto y el rendimiento relativo respecto al nivel individual del atleta. En ambos casos, la variable objetivo se expresó en centímetros para facilitar la interpretación de los errores. Para estas tareas se utilizaron Dummy Regressor, Ridge, ElasticNet, SVR, Random Forest Regressor y Gradient Boosting Regressor.

El Dummy Regressor [40] se utilizó como referencia básica. Se evaluaron estrategias basadas en la media y la mediana del conjunto de entrenamiento. Su función fue comprobar si los modelos que usaban variables biomecánicas eran capaces de mejorar una predicción muy simple.

El modelo Ridge se utilizó como regresión lineal regularizada. Este modelo penaliza coeficientes demasiado grandes mediante regularización L2, lo que puede ayudar cuando existen variables correlacionadas entre sí. El parámetro principal es alpha: valores bajos permiten un ajuste más parecido a una regresión lineal clásica, mientras que valores altos aplican más penalización y producen modelos más simples [41].

ElasticNet [42] también es un modelo lineal regularizado, pero combina regularización L1 y L2. Esto permite reducir la magnitud de los coeficientes y, en algunos casos, acercar a cero los coeficientes de variables menos relevantes. Sus parámetros principales son alpha y l1_ratio. alpha controla la intensidad global de la regularización. l1_ratio define el equilibrio entre L1 y L2: valores cercanos a 0 se parecen más a Ridge, mientras que valores cercanos a 1 se acercan más a una regularización tipo Lasso.

El modelo SVR se utilizó únicamente en las tareas de regresión. decisión[37]. Es la adaptación de las máquinas de vectores soporte a variables continuas. En lugar de separar clases, busca ajustar una función que prediga el valor de la variable objetivo permitiendo un margen de tolerancia. Se evaluaron kernels lineales y RBF. El parámetro C controla cuánto se penalizan los errores; valores altos permiten ajustar más el modelo, mientras que valores bajos producen funciones más suaves. El parámetro epsilon define el margen de tolerancia dentro del cual los errores no se penalizan. Valores mayores de epsilon hacen que el modelo sea menos sensible a pequeñas desviaciones. El parámetro gamma, cuando se utiliza kernel RBF, controla la flexibilidad de la función no lineal.

El Random Forest Regressor se utilizó como modelo no lineal basado en árboles. Su funcionamiento es similar al Random Forest de clasificación, pero en lugar

de predecir una clase predice un valor continuo. Los parámetros evaluados fueron n_estimators, max_depth, min_samples_leaf y max_features. Estos parámetros influyen en la estabilidad del modelo, la profundidad de los árboles, el grado de regularización y la diversidad entre árboles.

El Gradient Boosting Regressor [38] se incorporó como modelo ensemble secuencial para regresión. Construye árboles de forma progresiva, corrigiendo los errores residuales del modelo anterior. Sus parámetros cumplen la misma función general que en clasificación: n_estimators controla el número de árboles, learning_rate regula la contribución de cada árbol, max_depth limita su complejidad, min_samples_leaf evita divisiones demasiado específicas y subsample introduce aleatoriedad en el entrenamiento.

La Tabla 8 resume los modelos e hiperparámetros evaluados en las tareas de regresión.

Tabla 8: Modelos e hiperparámetros evaluados en las tareas de regresión.

Modelo	**Preprocesamiento**	**Hiperparámetros evaluados**
Dummy Regressor	No requiere escalado	strategy: mean, median
Ridge	Imputación por mediana + estandarización	alpha: 0.1, 1, 10, 100
ElasticNet	Imputación por mediana + estandarización	alpha: 0.01, 0.1, 1, 10; l1_ratio: 0.1, 0.5, 0.9
SVR	Imputación por mediana + estandarización	kernel: linear, rbf; C: 0.1, 1, 10; epsilon: 1, 5, 10; gamma: scale
Random Forest Regressor	Imputación por mediana	n_estimators: 100, 300; max_depth: None, 3, 5; min_samples_leaf: 1, 2, 4; max_features: sqrt, log2, 1.0
Gradient Boosting Regressor	Imputación por mediana	n_estimators: 50, 100; learning_rate: 0.03, 0.1; max_depth: 2, 3; min_samples_leaf: 1, 3; subsample: 0.8, 1.0

5.8.3 Interpretación de los hiperparámetros utilizados

Además de definir los modelos utilizados, se revisaron los principales hiperparámetros incluidos en las búsquedas. Estos hiperparámetros controlan el grado de flexibilidad de cada modelo y, por tanto, influyen directamente en su capacidad para ajustarse a los datos. En un dataset reducido como el de este trabajo, esta cuestión es especialmente importante, ya que un modelo demasiado simple puede no captar relaciones relevantes, mientras que un

modelo demasiado flexible puede adaptarse en exceso a los intentos disponibles y generalizar peor.

En los modelos lineales de clasificación y regresión se evaluaron parámetros relacionados con la regularización. En la Regresión Logística, el parámetro C controla la intensidad de la regularización. Valores bajos de C generan modelos más simples, porque penalizan más los coeficientes grandes. Valores altos permiten que el modelo se ajuste más a los datos, aunque también pueden aumentar el riesgo de sobreajuste. En Ridge y ElasticNet, el parámetro alpha cumple una función similar: cuanto mayor es su valor, mayor es la penalización aplicada a los coeficientes y más simple tiende a ser el modelo. En ElasticNet también se evaluó l1_ratio, que controla el equilibrio entre regularización L1 y L2. Valores bajos se parecen más a Ridge, mientras que valores altos se acercan más a un comportamiento tipo Lasso, favoreciendo que algunas variables tengan coeficientes muy próximos a cero.

En los modelos SVM y SVR se evaluaron parámetros que controlan la forma de la frontera de decisión o de la función de regresión. En clasificación se utilizó SVM, mientras que en regresión se utilizó SVR. El parámetro C regula el equilibrio entre permitir errores y ajustar el modelo a los datos. Valores bajos producen modelos más suaves y conservadores, mientras que valores altos penalizan más los errores y pueden generar modelos más ajustados al conjunto de entrenamiento. El parámetro kernel define el tipo de relación que puede aprender el modelo. Un kernel lineal busca una relación más simple, mientras que el kernel RBF permite capturar relaciones no lineales. En el caso del kernel RBF, gamma controla la influencia de cada observación: valores bajos generan funciones más suaves y valores altos pueden producir modelos más sensibles a casos concretos. En SVR también se evaluó epsilon, que define un margen de tolerancia dentro del cual los errores no se penalizan. Un valor mayor de epsilon hace que el modelo sea menos sensible a pequeñas diferencias entre la predicción y el valor real.

En los modelos basados en árboles se evaluaron hiperparámetros relacionados con la complejidad y estabilidad del modelo. n_estimators indica el número de árboles utilizados. Un número mayor suele hacer el modelo más estable, aunque también aumenta el coste computacional. max_depth limita la profundidad máxima de cada árbol. Si la profundidad es muy alta, el modelo puede captar relaciones muy específicas del conjunto de entrenamiento; si es baja, el modelo es más simple y puede generalizar mejor. min_samples_leaf establece el número mínimo de observaciones que debe tener una hoja final del árbol. Valores más altos reducen el riesgo de crear reglas basadas en muy pocos casos. max_features controla cuántas variables se consideran en cada división del árbol, lo que afecta a la diversidad de los árboles y puede reducir el sobreajuste.

En Gradient Boosting se evaluaron además parámetros propios del aprendizaje secuencial. learning_rate controla cuánto aporta cada árbol nuevo al modelo final. Valores bajos hacen que el aprendizaje sea más gradual y suelen requerir más árboles, mientras que valores altos pueden ajustar más rápido, pero con mayor riesgo de sobreajuste. subsample indica la proporción de datos utilizada para entrenar cada árbol. Cuando este valor es menor que 1, se introduce cierta aleatoriedad en el proceso, lo que puede ayudar a mejorar la generalización.

Por último, en los modelos de clasificación se evaluó class_weight, que permite modificar el peso asignado a cada clase. Esta opción era relevante porque los saltos nulos eran menos frecuentes que los válidos. Utilizar class_weight =

balanced permite que el modelo dé mayor importancia relativa a la clase minoritaria, lo que puede mejorar la detección de nulos, aunque en algunos casos también puede aumentar los falsos positivos.

En conjunto, la evaluación de hiperparámetros permitió comparar versiones más simples y más flexibles de cada modelo. Esta búsqueda no tuvo como objetivo forzar el mejor resultado posible, sino comprobar qué configuración ofrecía un equilibrio razonable entre rendimiento, estabilidad e interpretabilidad.

5.8.4 Criterios de evaluación

Los modelos se evaluaron mediante validación cruzada, aplicando siempre el mismo procedimiento para cada paquete de variables. En cada iteración, la imputación y el escalado se realizaron únicamente con los datos de entrenamiento, y después se aplicaron al conjunto de validación correspondiente. De esta forma, se evitó que la información del conjunto de validación influyera en el ajuste del modelo.

La selección de hiperparámetros se realizó mediante búsqueda en rejilla con validación cruzada. Para cada combinación de modelo y paquete de variables se definió una rejilla de parámetros, y se seleccionó la configuración con mejor rendimiento según la métrica principal de cada tarea. Este procedimiento permitió comparar modelos de forma sistemática y reducir la arbitrariedad en la elección de parámetros.

En la tarea de clasificación se utilizó validación cruzada estratificada de 5 particiones. Esta decisión permitió mantener una proporción similar de saltos válidos y nulos en cada partición, algo importante porque la clase nulo era menos frecuente que la clase válido. La métrica principal fue el F1-score de la clase nulo, ya que interesaba evaluar la capacidad del modelo para detectar intentos nulos sin depender únicamente de la exactitud global. También se tuvieron en cuenta otras métricas complementarias, como accuracy, balanced accuracy, precision, recall, ROC-AUC y matrices de confusión.

En las tareas de regresión se utilizó validación cruzada de 5 particiones con mezcla aleatoria y semilla fija. La métrica principal fue el MAE, porque expresa el error absoluto medio en centímetros y resulta directamente interpretable en el contexto del salto de longitud. Además, se calcularon RMSE y R^2 como métricas complementarias. El RMSE permitió valorar la presencia de errores grandes, mientras que el R^2 se interpretó con cautela debido al tamaño reducido del dataset.

Por último, los modelos se compararon utilizando los paquetes de variables definidos en el apartado anterior. De esta forma, la evaluación no solo permitió observar qué algoritmo funcionaba mejor, sino también qué tipo de información biomecánica parecía aportar más valor en cada tarea.

5.8.5 Resumen de las métricas de evaluación

Las métricas se seleccionaron en función del tipo de tarea.

En clasificación se calcularon métricas orientadas tanto al rendimiento global como a la detección de la clase nulo. La métrica principal fue el F1-score de la

clase nulo, ya que interesaba evaluar la capacidad del modelo para detectar intentos nulos sin depender únicamente de la exactitud general. También se calcularon accuracy, balanced accuracy, precision, recall, ROC-AUC y matrices de confusión. La Tabla 9 resumen y explica las métricas utilizadas para la evaluación de los problemas de clasificación.

Tabla 9: Métricas utilizadas en la tarea de clasificación.

Métrica	**Interpretación**
Accuracy	Proporción total de aciertos
Balanced accuracy	Media del recall por clase, útil ante cierto desequilibrio
Precision clase nulo	Proporción de predicciones de nulo que realmente son nulos
Recall clase nulo	Proporción de nulos reales correctamente detectados
F1-score clase nulo	Equilibrio entre precision y recall de la clase nulo
ROC-AUC	Capacidad de separación entre clases

En regresión se utilizaron MAE, RMSE y R^2. El MAE fue la métrica principal porque expresa el error medio absoluto en centímetros, una unidad directamente interpretable para el salto de longitud. El RMSE se utilizó como métrica complementaria, más sensible a errores grandes. El R^2 se interpretó con cautela debido al tamaño reducido del conjunto de datos y a la posible influencia de valores extremos. La Tabla 10 resumen y explica las métricas utilizadas para la evaluación de los problemas de regresión.

Tabla 10 : Métricas utilizadas en las tareas de regresión.

Métrica	**Interpretación**
MAE	Error absoluto medio en centímetros
RMSE	Error cuadrático medio, más sensible a errores grandes
R^2	Proporción de variabilidad explicada por el modelo

6 Resultados y Discusión

En este capítulo se presentan y discuten los resultados obtenidos en las tareas de aprendizaje automático planteadas en la metodología. Una vez construido el dataset final y definidos los paquetes de variables, el análisis se centra en evaluar hasta qué punto las variables biomecánicas extraídas desde vídeo permiten abordar tres problemas: clasificar los intentos como válidos o nulos, estimar la marca absoluta de los saltos válidos y analizar el rendimiento relativo respecto al nivel individual del atleta.

La presentación de resultados sigue esa misma estructura. En primer lugar, se analiza la clasificación válido/nulo, prestando especial atención al comportamiento del modelo sobre la clase nulo. En segundo lugar, se estudia la regresión de la marca absoluta, entendida como la distancia oficial alcanzada en los saltos válidos. Finalmente, se evalúa la variable de rendimiento relativo, que permite contextualizar cada marca en función del nivel previo del atleta.

En todos los casos, los modelos se interpretan de forma prudente, teniendo en cuenta el tamaño reducido de la muestra, el uso de vídeo lateral bidimensional y las limitaciones propias de una extracción automática de variables en contexto competitivo real. Por tanto, los resultados no se presentan como un sistema predictivo definitivo, sino como una evaluación exploratoria de la información técnica contenida en las variables extraídas.

6.1 Clasificación de saltos válidos y nulos

La primera tarea de aprendizaje automático consistió en clasificar cada intento como válido o nulo a partir de las variables biomecánicas extraídas del vídeo. Esta tarea se planteó sobre los 66 intentos disponibles, con 42 saltos válidos y 24 saltos nulos.

El objetivo de este primer modelo no era únicamente obtener una tasa de acierto global elevada, sino comprobar si existían patrones biomecánicos asociados a la validez del intento. Por ello, se dio especial importancia al rendimiento sobre la clase nula. En una competición de salto de longitud, el nulo no es simplemente una clase minoritaria desde el punto de vista estadístico, sino un resultado técnicamente relevante, ya que puede estar relacionado con la gestión de la carrera, la precisión de la batida y la distancia respecto a la tabla.

Se entrenaron distintos modelos de clasificación sobre los paquetes de variables definidos previamente. La comparación incluyó modelos de referencia, modelos lineales y modelos no lineales. La métrica principal utilizada para ordenar los resultados fue el F1-score de la clase nulo, ya que combina precisión y sensibilidad sobre la clase de mayor interés en este problema. Además, se analizaron la accuracy, la balanced accuracy, la precisión de la clase nulo, el recall de la clase nulo y el ROC-AUC.

El mejor resultado global se obtuvo con el paquete de variables temporales y espaciales y un modelo de Regresión Logística. Este resultado es especialmente interesante porque indica que las variables relacionadas con la organización espacial y temporal de los apoyos en la aproximación contienen más información útil para distinguir entre salto válido y nulo que otros bloques más complejos, como el conjunto completo de ángulos corporales.

La Tabla 12 resume las métricas del mejor modelo obtenido en esta tarea. Se incluyen tanto métricas globales como métricas específicas de la clase nulo, ya que esta clase tiene especial interés técnico dentro del problema analizado.

Tabla 12: Mejor modelo de clasificación válido/nulo.

Elemento	**Resultado**
Modelo	Regresión Logística
Paquete de variables	Temporales y espaciales
Número de variables	16
Intentos utilizados	66
Saltos válidos	42
Saltos nulos	24
Accuracy	0,742
Balanced accuracy	0,717
Precisión clase nulo	0,652
Recall clase nulo	0,625
F1-score clase nulo	0,638
ROC-AUC	0,743

Para situar este resultado dentro del conjunto de modelos evaluados, la Figura 12 compara las principales configuraciones de clasificación según el F1-score de la clase nulo. Esta comparación permite observar que las mejores combinaciones se concentran en modelos entrenados con variables temporales y espaciales o con paquetes biomecánicos amplios.

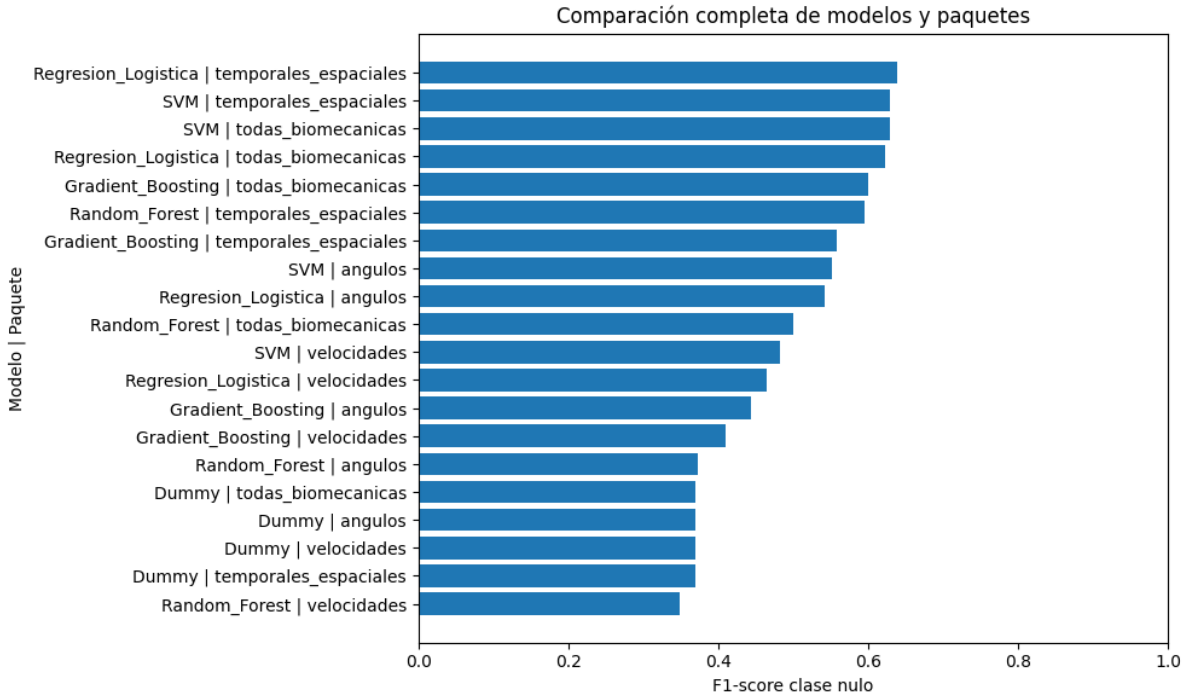


Figura 12: Comparación de los principales modelos de clasificación según F1-score de la clase nulo y balanced accuracy..

A partir de estos resultados, se observa que el modelo clasifica correctamente aproximadamente tres de cada cuatro intentos. No obstante, en esta tarea la balanced accuracy resulta más informativa que la accuracy simple, ya que tiene en cuenta la diferencia de tamaño entre saltos válidos y nulos. El valor obtenido, 0,717, indica que el modelo no se limita a favorecer la clase mayoritaria, sino que mantiene una capacidad razonable de detección en ambas clases.

En la clase nulo, el modelo obtuvo una precisión de 0,652 y un recall de 0,625. Esto significa que aproximadamente el 65 % de los intentos predichos como nulos fueron realmente nulos, y que el modelo detectó el 62,5 % de los nulos reales. Aunque estos valores no son suficientes para un uso automático en competición, sí muestran que las variables extraídas desde vídeo contienen señales asociadas a la validez del salto.

La Figura 13 muestra la matriz de confusión del mejor modelo de clasificación, correspondiente a la Regresión Logística entrenada con variables temporales y espaciales. Esta matriz permite observar no solo el número total de aciertos, sino también qué tipo de errores cometió el modelo.

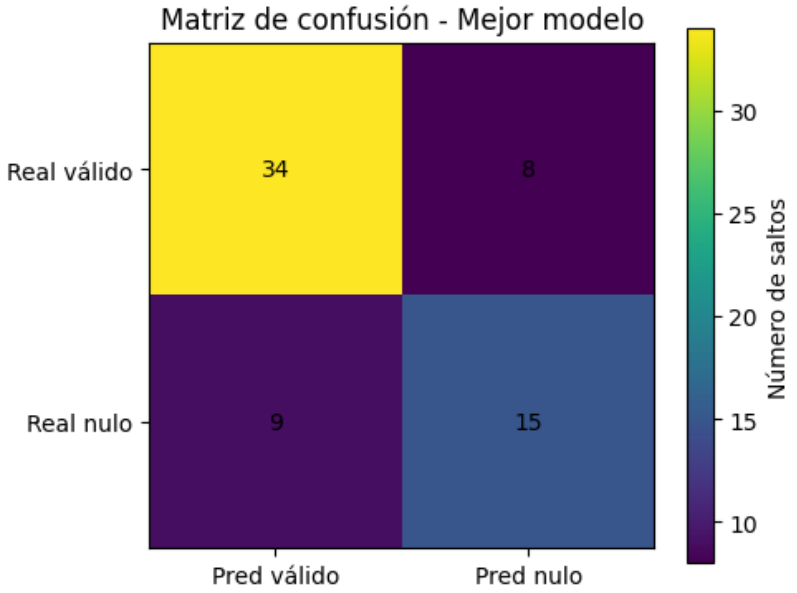


Figura 13: Matriz de confusión del mejor modelo de clasificación válido/nulo.

El modelo clasificó correctamente 34 de los 42 saltos válidos y 15 de los 24 saltos nulos. Los principales errores se distribuyeron en dos tipos. Por un lado, 8 saltos válidos fueron clasificados como nulos. Este tipo de error puede estar relacionado con intentos técnicamente cercanos al límite de la tabla o con patrones de aproximación similares a los observados en saltos nulos. Por otro lado, 9 saltos nulos fueron clasificados como válidos, lo que sugiere que no todos los nulos presentan una señal biomecánica fácilmente detectable a partir de las variables disponibles.

Este resultado es coherente con la naturaleza del salto nulo. En algunos casos, un nulo puede deberse a una diferencia muy pequeña en la posición del pie respecto a la tabla, difícil de captar mediante variables globales extraídas del movimiento. Además, la cámara lateral y el uso de estimación de pose 2D limitan la precisión con la que puede representarse el contacto exacto del pie en la zona de batida. Por tanto, el resultado no debe interpretarse como una clasificación definitiva, sino como una evidencia inicial de que las variables temporales y espaciales de la aproximación contienen información relevante sobre la validez del intento.

Desde el punto de vista interpretativo, resulta coherente que el mejor paquete sea el de variables temporales y espaciales.. La nulidad en salto de longitud está directamente relacionada con la precisión de la batida, la distancia respecto a la tabla y la organización de los últimos apoyos. En cambio, las variables angulares pueden estar más afectadas por errores de estimación de pose, o reflejar aspectos técnicos que no se traducen de forma directa en la condición válido/nulo.

6.2 Interpretabilidad del modelo de clasificación

Además de las métricas globales, se revisó la interpretación del mejor modelo de clasificación, correspondiente a la Regresión Logística entrenada con variables temporales y espaciales.. Esta fase fue importante porque el objetivo del trabajo no era únicamente obtener un porcentaje de acierto, sino

comprender qué tipo de información técnica parecía asociarse a la detección de saltos nulos.

La Regresión Logística con variables temporales y espaciales ofrece una ventaja interpretativa frente a modelos más complejos, ya que trabaja con un paquete reducido de 16 variables y permite analizar tanto los coeficientes del modelo como la importancia por permutación. La interpretación se realizó con cautela, entendiendo estas medidas como asociaciones predictivas y no como relaciones causales directas.

La Figura 14 muestra la importancia por permutación de las variables incluidas en este modelo. Esta medida permite comprobar qué variables afectan más al rendimiento predictivo cuando sus valores se alteran, por lo que resulta útil para interpretar qué tipo de información está utilizando el clasificador.

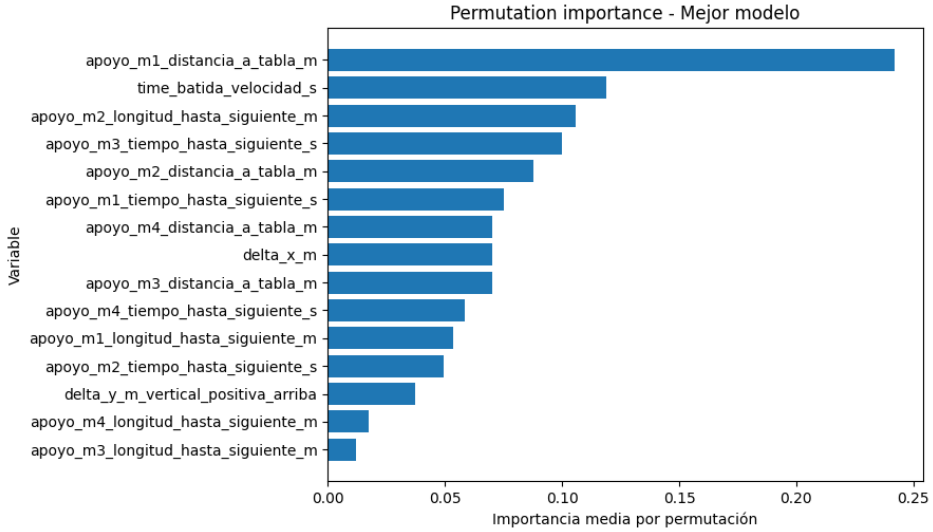


Figura 14: Importancia por permutación de las variables de la Regresión Logística con variables temporales y espaciales.

La importancia por permutación mostró que las variables más relacionadas con la clasificación estaban vinculadas principalmente con distancias a la tabla, longitudes de apoyo y tiempos entre eventos. Este resultado refuerza la idea de que la organización final de la carrera de aproximación contiene información relevante para distinguir saltos válidos y nulos.

Para facilitar la interpretación biomecánica de estos resultados, la Tabla 11 agrupa las variables más relevantes según el tipo de información que aportan al mod

Tabla 11: Variables relevantes en el mejor modelo de clasificación.

Variable	**Tipo de información**	**Interpretación técnica**
Distancia de los apoyos a la tabla	Espacial	Relación del atleta con la zona de batida
Longitud entre apoyos	Espacial	Organización de los últimos pasos

Variable	Tipo de información	Interpretación técnica
Tiempo entre apoyos	Temporal	Ritmo final de aproximación
Variables de batida	Temporal/espacial	Momento de transición entre carrera y salto

Esta agrupación confirma que las variables más relevantes pertenecen principalmente al bloque temporal y espacial, lo que resulta coherente con la lógica biomecánica de la prueba.. La validez del intento depende de cómo el atleta regula sus últimos apoyos y llega a la tabla. Por tanto, aunque la posición exacta del pie no pueda medirse con la precisión de un sistema oficial, las variables derivadas de la aproximación final parecen captar parte de esa información.

6.3 Regresión de la marca absoluta

La segunda tarea consistió en predecir la marca absoluta del salto, expresada en centímetros. Esta aproximación representa el resultado competitivo más directo: la distancia oficial alcanzada por el atleta en un intento válido.

Para esta tarea se utilizaron únicamente los 42 saltos válidos con marca disponible. Los saltos nulos fueron excluidos, ya que no tienen una marca oficial válida. La variable objetivo se construyó multiplicando la marca en metros por 100, de forma que el error del modelo pudiera interpretarse directamente en centímetros.

La Tabla 12 resume los principales estadísticos descriptivos de la variable objetivo utilizada en esta tarea. Estos valores permiten situar el rango de marcas que el modelo intenta predecir y ayudan a interpretar posteriormente la magnitud de los errores obtenidos.

Tabla 12: Descripción de la variable objetivo en la regresión de marca absoluta.

Estadístico	Valor
Número de saltos válidos	42
Media de la marca	724,79 cm
Mediana de la marca	730,00 cm
Desviación típica	44,79 cm
Mínimo	582,00 cm
Máximo	814,00 cm

Los valores de la Tabla 12 muestran una variabilidad relevante entre los saltos válidos analizados. El rango de marcas, desde 582 cm hasta 814 cm, refleja que

en la muestra conviven atletas con niveles competitivos distintos y también intentos de diferente calidad dentro de la misma final.

Se entrenaron modelos de regresión sobre los diferentes paquetes de variables. La métrica principal utilizada fue el MAE, ya que expresa el error medio absoluto en centímetros y resulta fácilmente interpretable en el contexto del salto de longitud. También se calcularon el RMSE y el R^2. El RMSE penaliza más los errores grandes, mientras que el R^2 permite valorar la proporción de variabilidad explicada por el modelo en comparación con una predicción media o constante.

El mejor resultado se obtuvo con el modelo SVR utilizando el paquete completo de variables biomecánicas. Este modelo alcanzó un MAE de 29,96 cm, un RMSE de 39,81 cm y un R^2 de 0,191.

La Tabla 13 recoge las configuraciones con menor MAE en la tarea de regresión de la marca absoluta, junto con el modelo Dummy utilizado como referencia. No se incluyen todas las combinaciones evaluadas, sino aquellas que permiten resumir el comportamiento de los modelos con mejor rendimiento.

Tabla 13: Mejores configuraciones obtenidas en la regresión de marca absoluta, ordenadas por MAE.

Paquete	**Modelo**	**Nº variables**	**Nº saltos**	**MAE (cm)**	**RMSE (cm)**	**R^2**
Todas biomecánicas	SVR	64	42	29,96	39,81	0,191
Todas biomecánicas	ElasticNet	64	42	32,06	43,02	0,055
Velocidades + temporales/espaciales	Random Forest	29	42	32,16	42,13	0,094
Velocidades + temporales/espaciales	SVR	29	42	32,44	40,28	0,171
Velocidades	SVR	13	42	32,46	41,08	0,138
Dummy	Mediana	-	42	33,86	44,62	-0,017

Para complementar las métricas de la Tabla 13, la Figura 15 muestra la relación entre la marca real y la marca predicha por el mejor modelo. La línea diagonal representa la predicción ideal, por lo que la distancia de los puntos respecto a esa línea permite observar visualmente los errores de estimación.

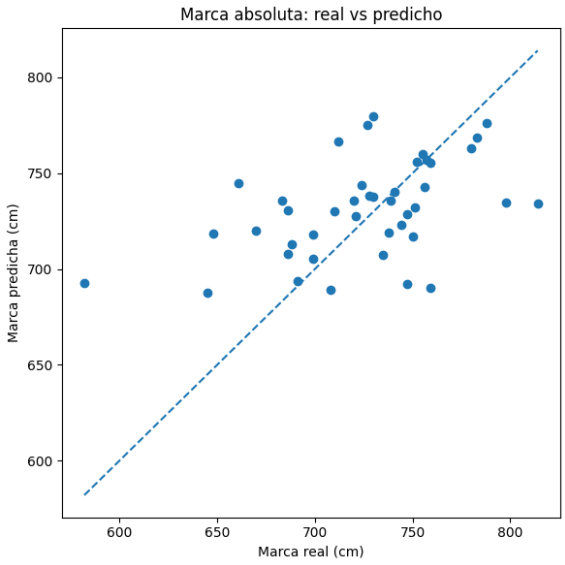


Figura 15: Relación entre marca real y marca predicha en el mejor modelo de regresión de marca absoluta.

El SVR con todas las variables biomecánicas fue el modelo con menor MAE, reduciendo el error medio de 33,86 cm en el modelo Dummy a 29,96 cm. La mejora existe, aunque es moderada, y el R^2 de 0,191 indica que la capacidad explicativa del modelo sigue siendo limitada. Este resultado sugiere que las variables extraídas desde vídeo contienen cierta información relacionada con la marca final, pero no capturan todos los factores que determinan el rendimiento competitivo.

Además, la predicción de marca absoluta plantea una dificultad conceptual importante: mezcla el nivel estructural del atleta con la calidad concreta del intento. Un salto de 7,50 m puede ser un resultado excelente para un atleta cuyo nivel habitual está en torno a 7,20 m, pero puede ser un resultado discreto para un atleta acostumbrado a saltar cerca de 8,00 m. Por tanto, aunque la marca absoluta es una variable objetiva y competitivamente relevante, no siempre permite interpretar adecuadamente si un intento fue bueno o malo para el atleta que lo realizó.

Esta limitación motivó la construcción de una segunda variable objetivo, orientada a contextualizar el rendimiento del salto en relación con el nivel previo de cada atleta.

6.4 Construcción e interpretación del rendimiento relativo respecto al nivel individual

A partir de la limitación observada en la marca absoluta, se planteó una segunda aproximación al problema de regresión. En lugar de predecir únicamente la distancia oficial alcanzada, se construyó una variable derivada que mide la diferencia entre la marca del intento y el nivel de referencia previo del atleta.

Esta variable se denominó marca_vs_nivel_cm y se calculó en centímetros. Su objetivo es representar si el salto analizado estuvo por encima o por debajo del rendimiento esperable del atleta, de acuerdo con su historial previo.

La lógica de esta variable es la siguiente:

$$marca_vs_nivel_cm = (marca_m - nivel_referencia_pc) \times 100$$

Un valor positivo indica que el salto se situó por encima del nivel de referencia del atleta. Un valor negativo indica que el salto estuvo por debajo de ese nivel. De esta forma, el análisis deja de depender únicamente de la magnitud absoluta de la marca y pasa a incorporar una lectura contextualizada del rendimiento.

Esta decisión es relevante porque permite comparar intentos de atletas con niveles competitivos distintos. En una final nacional, no todos los participantes parten del mismo nivel. Por ello, una marca aparentemente media puede ser un gran intento para un atleta y, al mismo tiempo, una marca por debajo de lo esperado para otro. La variable relativa intenta capturar precisamente esa diferencia.

El nivel de referencia se calculó utilizando resultados previos del atleta, evitando incluir resultados posteriores a la competición analizada. Esta decisión fue importante para no introducir información futura en el modelo. Cuando existían suficientes resultados previos en pista cubierta, se utilizó una referencia basada en el rendimiento reciente del atleta. En los casos con menos información disponible, el nivel se calculó con menor fiabilidad o quedó ausente si no había datos suficientes.

La variable marca_vs_nivel_cm no sustituye a la marca absoluta. Ambas responden a preguntas distintas. La marca absoluta responde a cuánto saltó el atleta. El rendimiento relativo responde a cómo fue ese salto en relación con lo que cabía esperar de ese atleta concreto. Por este motivo, ambas tareas se mantienen en el análisis.

6.5 Regresión del rendimiento relativo

La regresión del rendimiento relativo se realizó únicamente con los saltos válidos que tenían disponible tanto la marca oficial como el nivel de referencia individual. El dataset utilizado en esta tarea quedó formado por 39 intentos.

La variable objetivo presentó una media de -24,37 cm y una desviación típica de 39,11 cm. Esto indica que, de media, los saltos válidos analizados se situaron por debajo del nivel de referencia previo de los atletas. Esta situación puede deberse a varios factores: la competición analizada corresponde a una final concreta, los intentos válidos no tienen por qué coincidir con el mejor intento del atleta, y algunos saltos pueden haber sido conservadores o técnicamente alejados del rendimiento habitual.

La Tabla 14 resume la distribución de la variable marca_vs_nivel_cm en los saltos válidos con nivel de referencia disponible. Estos valores permiten interpretar el rango de rendimiento relativo que posteriormente intentan estimar los modelos

Tabla 14 : Descripción de la variable marca_vs_nivel_cm.

Estadístico	**Valor**
Número de saltos válidos con target disponible	39

Estadístico	Valor
Media	-24,37 cm
Mediana	-11,33 cm
Desviación típica	39,11 cm
Mínimo	-176,00 cm
Máximo	20,33 cm

La Figura 16 representa gráficamente esta distribución y permite identificar los intentos más alejados del nivel individual de referencia. Esta visualización es útil para observar la presencia de valores extremos antes de interpretar los resultados de la regresión.

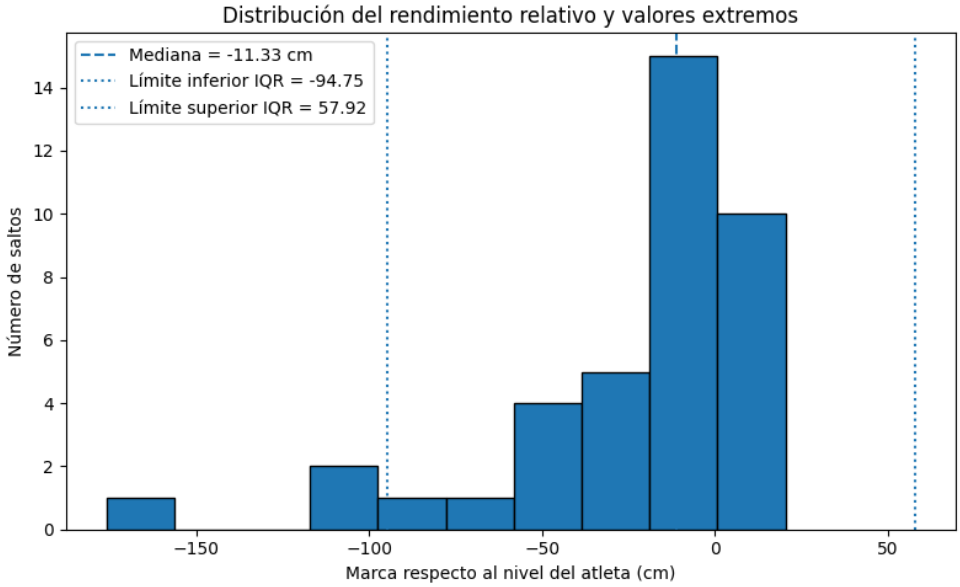


Figura 16: Distribución de la variable marca_vs_nivel_cm, con identificación de los valores más alejados del nivel individual del atleta.

El valor mínimo de -176 cm muestra la presencia de intentos muy alejados del nivel de referencia del atleta. Estos casos son importantes porque pueden influir de forma notable en el entrenamiento y evaluación de los modelos. Por esta razón, además del análisis principal, se realizó posteriormente un análisis de sensibilidad excluyendo valores extremos.

En el análisis principal, el mejor resultado se obtuvo con un modelo SVR utilizando únicamente variables de velocidad. Este modelo alcanzó un MAE de 23,51 cm, un RMSE de 34,93 cm y un R^2 de 0,181.

La Tabla 15 recoge las configuraciones más relevantes de la regresión del rendimiento relativo, ordenadas principalmente según el MAE. Aunque algunas configuraciones presentan un R^2 ligeramente superior, el MAE se utilizó como criterio principal porque expresa directamente el error medio en centímetros.

Tabla 15: Mejores configuraciones obtenidas en la regresión del rendimiento relativo, ordenadas por MAE.

Paquete	**Modelo**	**Nº variables**	**Nº saltos**	**MAE (cm)**	**RMSE (cm)**	**R^2**
Velocidades	SVR	13	39	23,51	34,93	0,181
Velocidades	Random Forest	13	39	23,58	35,03	0,177
Todas biomecánicas	Random Forest	64	39	24,16	35,89	0,136
Temporales/espaciales	SVR	16	39	24,56	38,16	0,023
Velocidades	ElasticNet	13	39	24,57	34,54	0,200
Dummy	Mediana	-	39	25,99	40,83	-0,119

El resultado es interesante por dos motivos. En primer lugar, el mejor paquete fue el de velocidades, no el conjunto completo de variables. Esto sugiere que, para estimar si un salto está por encima o por debajo del nivel individual del atleta, la información cinemática relacionada con la velocidad puede ser más relevante que añadir un número mayor de variables angulares o espaciales. En segundo lugar, la diferencia respecto al Dummy es moderada, pero suficiente para indicar que las variables extraídas contienen información útil para aproximar el rendimiento relativo.

El MAE de 23,51 cm significa que, de media, el modelo se equivoca en unos 23,5 cm al estimar la diferencia entre la marca del intento y el nivel individual del atleta. En salto de longitud, este error sigue siendo elevado para una aplicación práctica precisa, pero resulta razonable en un estudio exploratorio con 39 observaciones y variables obtenidas automáticamente desde vídeo.

El R^2 de 0,181 también debe interpretarse con prudencia. No indica una explicación fuerte de la variabilidad del rendimiento relativo, pero sí una señal por encima del modelo de referencia. Este resultado refuerza la idea de que el rendimiento individual contextualizado es una tarea difícil, especialmente cuando el dataset contiene intentos muy alejados del nivel habitual del atleta.

6.6 Análisis de sensibilidad sin valores extremos

Dado que la variable marca_vs_nivel_cm presentaba algunos valores muy alejados de la distribución principal, se realizó un análisis de sensibilidad. El objetivo fue comprobar si el rendimiento de los modelos estaba condicionado por unos pocos saltos válidos extremadamente alejados del nivel de referencia del atleta.

Para detectar estos casos se utilizaron dos criterios robustos: el rango intercuartílico ampliado (IQR) y el z-score robusto basado en la desviación absoluta mediana (MAD). Se identificaron tres valores extremos, todos ellos situados claramente por debajo del nivel de referencia individual.

La Tabla 16 recoge los tres intentos identificados como valores extremos en la variable marca_vs_nivel_cm. En todos los casos, el salto válido quedó muy por debajo del nivel de referencia individual del atleta.

Tabla 16: Valores extremos detectados en marca_vs_nivel_cm.

Vídeo	Atleta	Marca (m)	Nivel referencia (m)	marca_vs_nivel_cm	z robusto
Longi_MASC_057	Juan Francisco Trujillo Díaz	5,82	7,58	-176,00	-7,09
Longi_MASC_028	Sergio Coello Berreco	6,61	7,67	-106,33	-4,09
Longi_MASC_024	Iván Verdugo Guerra	6,45	7,44	-99,00	-3,77

Estos tres casos no fueron eliminados del análisis principal, ya que representan saltos reales y válidos. Sin embargo, se analizaron por separado para comprobar si estaban afectando de forma desproporcionada a la regresión. Desde el punto de vista técnico, estos intentos son menos comparables con el resto porque se sitúan muy por debajo del nivel de referencia del atleta. La revisión cualitativa de este tipo de casos sugiere que algunos pueden corresponder a ejecuciones incompletas, saltos no finalizados con la misma continuidad técnica, pérdidas de estabilidad durante la fase aérea o intentos válidos pero claramente alejados del rendimiento habitual.

Este punto es importante porque el modelo no incorpora una descripción completa de la fase aérea ni de la caída. El análisis se centra principalmente en la aproximación final, los últimos apoyos, la batida y un tramo postbatida controlado. Por tanto, cuando un salto se aleja mucho del nivel del atleta por factores ocurridos durante el vuelo, la caída o la finalización del gesto, esas causas pueden no quedar suficientemente representadas en las variables de entrada. Esta limitación ayuda a explicar por qué ciertos valores extremos son

difíciles de predecir.

Tras excluir los tres valores extremos, el dataset de sensibilidad quedó formado por 36 saltos. En este segundo escenario, el mejor modelo pasó a ser un Random Forest con variables temporales y espaciales. El MAE se redujo hasta 16,71 cm y el RMSE hasta 21,65 cm. El R^2 se situó en 0,165.

La Tabla 17 compara el mejor resultado obtenido con el dataset completo y el mejor resultado obtenido tras excluir los tres valores extremos. Esta comparación permite valorar si los casos extremos estaban condicionando el error medio de la regresión.

Tabla 17: Comparación entre regresión completa y regresión sin extremos.

Escenario	**Nº saltos**	**Mejor paquete**	**Mejor modelo**	**MAE (cm)**	**RMSE (cm)**	**R^2**
Dataset completo	39	Velocidades	SVR	23,51	34,93	0,181
Sin valores extremos	36	Temporales/espaciales	Random Forest	16,71	21,65	0,165

Para visualizar esta diferencia, la Figura 17 representa la reducción del MAE entre el análisis completo y el análisis sin valores extremos.

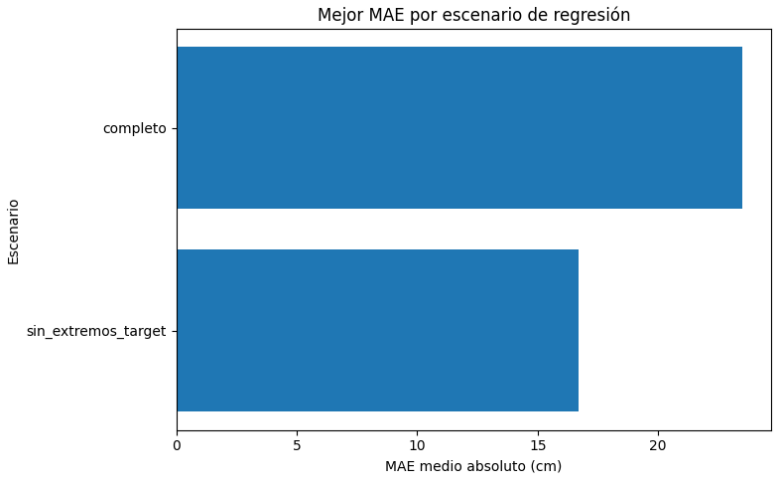


Figura 17: Comparación del MAE en la regresión del rendimiento relativo con el dataset completo y sin valores extremos.

El análisis de sensibilidad muestra una mejora clara del error absoluto al excluir los tres casos extremos. El MAE se reduce aproximadamente 6,8 cm, lo que indica que esos intentos condicionaban de forma importante el error medio del modelo. Sin embargo, el R^2 no aumenta de forma equivalente, lo que sugiere que, aunque el modelo predice mejor en términos de error absoluto, la explicación global de la variabilidad sigue siendo limitada.

Este resultado es relevante para la interpretación del trabajo. Por un lado, confirma que el rendimiento relativo es una variable más sensible a casos atípicos que la marca absoluta. Por otro lado, muestra que, cuando se analizan saltos más comparables entre sí, las variables temporales y espaciales vuelven a adquirir importancia, como ya ocurría en la clasificación válido/nulo.

La diferencia entre el análisis completo y el análisis sin extremos no debe entenderse como una razón para eliminar esos saltos del estudio. Al contrario, esos casos aportan información sobre los límites del sistema. En competiciones reales pueden aparecer intentos válidos muy alejados del nivel habitual de un atleta, y precisamente esos casos son difíciles de modelar con una muestra pequeña y con variables centradas en la aproximación y la batida. Por tanto, el análisis de sensibilidad no sustituye al análisis principal, sino que lo complementa.

6.7 Interpretabilidad en la regresión sin extremos

El análisis de sensibilidad permitió estudiar con mayor detalle qué variables eran más relevantes cuando se excluían los casos más extremos de rendimiento relativo. En este escenario, el mejor modelo fue un Random Forest con variables temporales y espaciales. Aunque Random Forest es menos directamente interpretable que una regresión lineal, permite obtener medidas de importancia interna y también analizar la importancia por permutación.

La Tabla 18 recoge las variables con mayor importancia interna en el Random Forest entrenado con variables temporales y espaciales, una vez excluidos los valores extremos. Esta tabla permite identificar qué variables aportaron más información al modelo dentro de este escenario de sensibilidad.

Tabla18: Variables con mayor importancia interna en el Random Forest sin valores extremos.

Variable	Importancia RF
apoyo_m2_distancia_a_tabla_m	0,129
apoyo_m4_distancia_a_tabla_m	0,106
apoyo_m3_distancia_a_tabla_m	0,106
apoyo_m3_longitud_hasta_siguiente_m	0,094
apoyo_m2_longitud_hasta_siguiente_m	0,081
apoyo_m1_tiempo_hasta_siguiente_s	0,076
apoyo_m1_longitud_hasta_siguiente_m	0,069
time_batida_velocidad_s	0,059
apoyo_m3_tiempo_hasta_siguiente_s	0,055

Variable	Importancia RF
apoyo_m1_distancia_a_tabla_m	0,046

De forma complementaria, la Figura 18 muestra visualmente la importancia de estas variables, facilitando la comparación entre ellas.

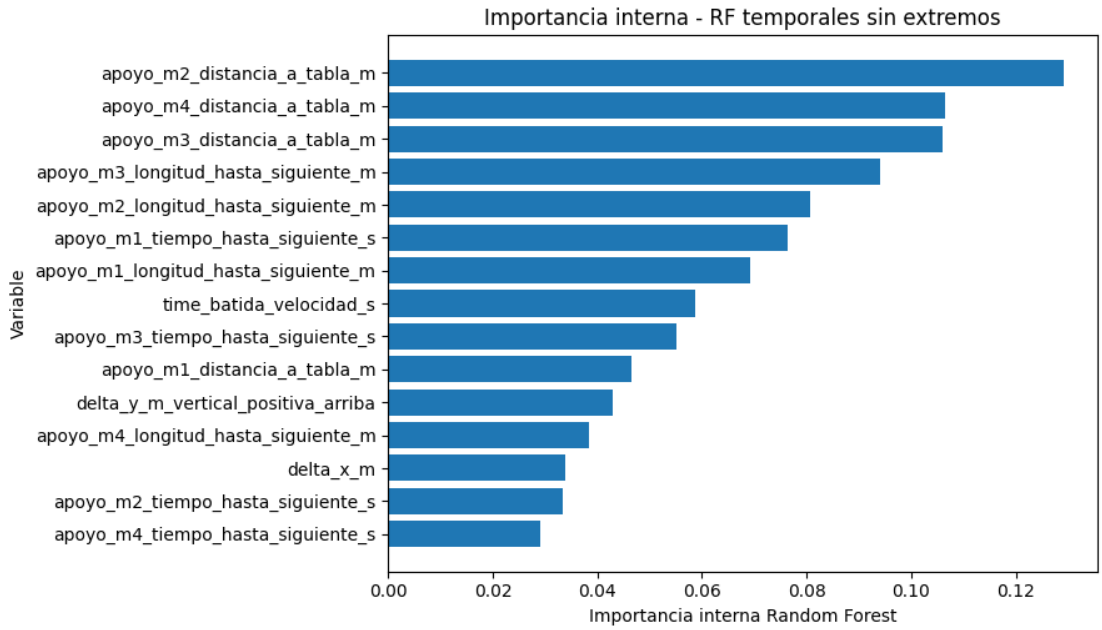


Figura 18: Importancia de variables del modelo Random Forest

en la regresión del rendimiento relativo sin valores extremos

La tabla y la figura muestran que las variables más relevantes están relacionadas con la distancia de los apoyos a la tabla, la longitud entre apoyos y el tiempo hasta el siguiente apoyo. Este patrón es coherente con la interpretación biomecánica del salto de longitud: la forma en que el atleta organiza los últimos apoyos antes de la tabla condiciona la calidad de la batida y, por tanto, puede estar relacionada con que el salto se acerque más o menos a su nivel esperado.

También resulta significativo que, al retirar los casos más extremos, las variables temporales y espaciales ganen importancia frente a las variables de velocidad. Esto puede indicar que, en saltos más comparables, la organización final de la carrera y la precisión de los apoyos aportan una señal más estable para explicar el rendimiento relativo. En cambio, cuando se incluyen intentos muy alejados del nivel habitual, las diferencias de velocidad pueden captar mejor parte de la variabilidad general, aunque de forma todavía limitada.

Debe recordarse que la importancia de variables no implica causalidad. Estos resultados indican que determinadas variables ayudan al modelo a predecir mejor dentro de este dataset, pero no permiten afirmar de forma definitiva que sean las causas directas de un mejor o peor rendimiento. Para establecer relaciones causales sería necesario un diseño experimental más amplio, con más atletas, más competiciones y mediciones biomecánicas más precisas.

6.8 Análisis de errores

El análisis de errores permitió identificar qué situaciones fueron más difíciles para los modelos. En la clasificación válido/nulo, los errores se distribuyeron entre saltos válidos predichos como nulos y saltos nulos predichos como válidos. Los falsos nulos pueden corresponder a intentos válidos que presentan patrones temporales o espaciales similares a los de un salto nulo, especialmente si el atleta llega muy próximo al límite de la tabla. Por el contrario, los nulos predichos como válidos sugieren que algunos intentos nulos no se diferencian claramente en las variables extraídas, posiblemente porque la nulidad depende de una diferencia muy pequeña en la posición exacta del pie.

En la regresión de marca absoluta, los errores más relevantes se relacionan con la propia naturaleza de la variable objetivo. La marca final no depende solo del intento observado, sino también del nivel estructural del atleta. Por ello, dos atletas pueden presentar patrones técnicos similares en las variables extraídas y, sin embargo, alcanzar marcas diferentes por diferencias de capacidad física, experiencia, forma competitiva o historial de rendimiento.

En la regresión del rendimiento relativo, los errores más altos aparecen en intentos muy alejados del nivel de referencia. Estos casos son difíciles porque pueden responder a factores que no están completamente recogidos por las variables analizadas. Por ejemplo, un salto válido pero muy por debajo del nivel del atleta puede deberse a una ejecución incompleta, una pérdida de estabilidad en el vuelo, una mala finalización de la caída o una decisión competitiva del atleta. Al no analizar de forma completa la fase aérea ni la caída, el modelo puede no disponer de información suficiente para explicar esos descensos extremos de rendimiento.

Esta observación no debilita el trabajo, sino que delimita claramente su alcance. El estudio analiza principalmente la aproximación final, los últimos apoyos, la batida y un instante postbatida controlado. Por tanto, sus resultados deben interpretarse como una aproximación al rendimiento desde esas fases, no como una reconstrucción total del salto.

6.9 Comparación con la literatura y coherencia biomecánica

Los resultados obtenidos son coherentes tanto con la literatura biomecánica clásica como con trabajos recientes que aplican aprendizaje automático e inteligencia artificial explicable al análisis del salto de longitud. Tradicionalmente, la velocidad de aproximación, la preparación de la batida y la organización de los últimos apoyos se han considerado factores determinantes del rendimiento. En esta memoria, las variables temporales y espaciales fueron especialmente relevantes en la clasificación válido/nulo y en la regresión del rendimiento relativo sin extremos, mientras que las variables de velocidad destacaron en la regresión principal del rendimiento relativo.

Esta interpretación encaja con trabajos recientes que han aplicado modelos de aprendizaje automático e inteligencia artificial explicable al estudio del salto de longitud [28]. En estos enfoques, la velocidad aparece como una variable relevante, pero no como el único factor explicativo del rendimiento, ya que otros aspectos técnicos también pueden contribuir de forma importante al resultado. En el presente estudio, esta idea se refleja en que la velocidad aporta

información útil para contextualizar el rendimiento del atleta, mientras que las variables temporales y espaciales ayudan a interpretar la validez del intento y la organización técnica de la aproximación final.

De forma complementaria, la revisión reciente sobre visión por computador y aprendizaje automático en pruebas de salto refuerza la idea de que estas herramientas están adquiriendo un papel creciente en el análisis del rendimiento deportivo [29]. No obstante, los resultados de esta memoria deben interpretarse con prudencia, ya que proceden de una muestra reducida, una única competición y vídeo lateral bidimensional.

Al mismo tiempo, los resultados muestran que la predicción de rendimiento mediante vídeo lateral y variables extraídas automáticamente tiene límites claros. Los valores de R^2 obtenidos son bajos o moderados, lo que indica que una parte importante de la variabilidad no queda explicada por las variables disponibles. Esta conclusión es coherente con la complejidad del salto de longitud: el rendimiento final depende de factores biomecánicos, físicos, técnicos, tácticos y contextuales que no pueden capturarse completamente con una única cámara lateral.

En comparación con estudios más instrumentados, este trabajo no pretende alcanzar la precisión de un análisis biomecánico de laboratorio. Su aportación se sitúa en otro punto: demuestra que, incluso a partir de vídeo real de competición, es posible construir un pipeline completo de extracción, limpieza, modelado e interpretación. Esto tiene valor aplicado porque acerca el análisis biomecánico a contextos donde no se dispone de sistemas tridimensionales, plataformas de fuerza o marcadores corporales.

Desde esta perspectiva, los resultados no deben evaluarse únicamente por la magnitud de las métricas predictivas, sino también por la capacidad del trabajo para construir una base de datos propia, definir variables con sentido técnico, comparar modelos y extraer conclusiones biomecánicamente razonables.

6.10 Discusión general

A partir de los resultados anteriores, se pueden extraer varias ideas principales.

En primer lugar, la clasificación de saltos válidos y nulos mostró que las variables biomecánicas extraídas del vídeo contienen información útil para distinguir entre ambos tipos de intento. El mejor modelo alcanzó una accuracy de 0,742, una balanced accuracy de 0,717 y un F1-score de 0,638 para la clase nulo. Aunque estos valores no permiten plantear una herramienta automática definitiva, sí muestran que existe una señal biomecánica aprovechable.

En segundo lugar, las variables temporales y espaciales tuvieron un papel especialmente importante. Fueron el mejor paquete en la clasificación y también ofrecieron el mejor rendimiento en la regresión del rendimiento relativo sin extremos. Esta coincidencia refuerza la importancia de la organización de los últimos apoyos y de la relación del atleta con la tabla de batida. En salto de longitud, la precisión espacial y temporal de la carrera de aproximación es un componente técnico fundamental, y los resultados del modelo son coherentes con esa realidad.

En tercer lugar, la predicción de la marca absoluta mostró una mejora moderada respecto al modelo de referencia. El mejor modelo alcanzó un MAE de 29,96 cm.

Este resultado indica que la marca oficial puede estimarse parcialmente a partir de las variables extraídas, pero también evidencia que la marca absoluta depende de factores que no están plenamente representados en el dataset. Entre ellos se encuentran el nivel previo del atleta, su estado de forma, la estrategia competitiva y la variabilidad propia de una final.

En cuarto lugar, la construcción de la variable marca_vs_nivel_cm permitió introducir una lectura más contextualizada del rendimiento. Esta variable representa una aportación metodológica del trabajo, ya que transforma la pregunta inicial. En lugar de analizar únicamente cuánto saltó un atleta, permite estudiar si ese salto estuvo por encima o por debajo de lo esperable para él. Esta aproximación resulta especialmente útil en contextos competitivos donde los atletas tienen niveles muy diferentes.

No obstante, el rendimiento relativo también introdujo nuevos retos. La presencia de tres valores extremos condicionó el error de los modelos y obligó a realizar un análisis de sensibilidad. Al excluir esos casos, el MAE se redujo de 23,51 cm a 16,71 cm, lo que muestra que los modelos funcionan mejor cuando los intentos analizados son más comparables. Sin embargo, esos valores extremos no deben considerarse errores por defecto, sino intentos reales que muestran la complejidad del rendimiento deportivo.

Por último, los resultados deben interpretarse siempre desde la prudencia. La muestra es reducida, procede de una única competición y no existe un conjunto de test independiente. La validación cruzada permite aprovechar mejor los datos disponibles, pero no sustituye a una evaluación externa con nuevos saltos y nuevos atletas. Por ello, el valor principal de este trabajo no está en desarrollar un modelo predictivo definitivo, sino en haber demostrado que es posible construir un pipeline completo de extracción, limpieza, integración y modelado a partir de vídeo real de competición.

7 Conclusiones

En este capítulo se presentan las principales conclusiones del trabajo, a partir de los resultados obtenidos en la construcción del dataset, la extracción de variables biomecánicas y la aplicación de modelos de aprendizaje automático. Además, se recogen las principales limitaciones del estudio y se proponen líneas de trabajo futuro que podrían mejorar la calidad del análisis y ampliar su aplicabilidad en contextos deportivos reales.

El objetivo general de este Trabajo Fin de Grado era analizar la viabilidad de utilizar técnicas de visión por computador y aprendizaje automático para extraer variables biomecánicas a partir de vídeos reales de salto de longitud y estudiar su relación con la validez del intento y el rendimiento del atleta. A partir del proceso desarrollado, puede concluirse que este objetivo se ha cumplido de forma satisfactoria dentro del alcance exploratorio del estudio.

El trabajo ha permitido construir un pipeline completo que parte de material audiovisual real de competición, lo transforma en variables numéricas con interpretación técnica, integra esas variables con resultados oficiales e históricos de rendimiento, y finalmente las utiliza en tareas supervisadas de clasificación y regresión. Esta cadena completa constituye una de las principales aportaciones del proyecto, ya que el trabajo no se limita a aplicar modelos sobre un dataset ya existente, sino que aborda también la construcción, limpieza y validación de una base de datos propia.

7.1. Conclusiones principales

La primera conclusión relevante es que resulta viable construir un dataset biomecánico tabular a partir de vídeos laterales reales de competición. Aunque el material audiovisual no fue grabado en condiciones controladas de laboratorio, el proceso desarrollado permitió extraer variables espaciales, temporales, angulares y de velocidad asociadas a la fase final de la aproximación, los últimos apoyos, la batida y un tramo postbatida controlado.

Esta conclusión es importante porque demuestra que el análisis biomecánico no tiene por qué depender exclusivamente de sistemas complejos de captura tridimensional, plataformas de fuerza o entornos experimentales. Aunque estos sistemas siguen siendo más precisos, el uso de visión por computador permite aproximarse al análisis técnico desde materiales más accesibles. En este trabajo, la combinación de recorte del atleta, estimación de pose, filtrado de detecciones, calibración espacial, detección de apoyos y control de calidad permitió transformar vídeos reales en una base estructurada útil para el análisis.

La segunda conclusión es que las variables temporales y espaciales de la aproximación final contienen información relevante para distinguir entre saltos válidos y nulos. El mejor modelo de clasificación fue una Regresión Logística entrenada con variables temporales y espaciales, alcanzando una accuracy de 0,742, una balanced accuracy de 0,717 y un F1-score de 0,638 para la clase nulo. Estos resultados no permiten plantear una herramienta automática definitiva, pero sí muestran que las variables extraídas contienen una señal asociada a la validez del intento.

Desde el punto de vista deportivo, este resultado es coherente con la lógica del

salto de longitud. La nulidad del intento está directamente relacionada con la precisión de la llegada a la tabla, la organización de los últimos apoyos y la gestión de la carrera de aproximación. Por tanto, que el mejor paquete de variables sea el temporal y espacial refuerza la interpretación biomecánica de los resultados.

La tercera conclusión es que la predicción de la marca absoluta resulta posible, pero limitada. El mejor modelo para esta tarea fue un SVR utilizando el conjunto completo de variables biomecánicas, con un MAE de 29,96 cm, un RMSE de 39,81 cm y un R^2 de 0,191. Aunque este modelo mejora al modelo de referencia, la mejora es moderada. Esto indica que las variables extraídas desde vídeo contienen cierta información asociada al rendimiento, pero no explican de forma completa la marca final.

Esta limitación era esperable. La marca absoluta de un salto no depende únicamente de la ejecución técnica observada en un intento concreto, sino también del nivel estructural del atleta, su estado de forma, su capacidad física, su experiencia competitiva, la estrategia de la competición y otros factores no incluidos en el dataset. Por ello, la predicción de la marca absoluta debe interpretarse como una primera aproximación al rendimiento, no como una estimación precisa de la distancia final.

La cuarta conclusión es que la variable de rendimiento relativo respecto al nivel individual del atleta aporta una lectura más contextualizada del salto. La construcción de la variable marca_vs_nivel_cm permitió pasar de una interpretación basada únicamente en la marca absoluta a una valoración del intento en función del nivel previo de cada deportista. Esta aportación resulta especialmente interesante porque una misma marca puede tener significados diferentes según el atleta que la realiza.

El modelo de regresión del rendimiento relativo obtuvo como mejor combinación un SVR con variables de velocidad, con un MAE de 23,51 cm, un RMSE de 34,93 cm y un R^2 de 0,181. Aunque las métricas siguen siendo prudentes, el resultado muestra que las variables de velocidad contienen información útil para estimar si un salto se sitúa por encima o por debajo del nivel esperado del atleta. Esto resulta coherente con la importancia de la velocidad de aproximación y su transferencia hacia la batida en el rendimiento del salto de longitud.

La quinta conclusión es que los valores extremos influyen de forma importante en la regresión del rendimiento relativo. Al analizar la variable marca_vs_nivel_cm, se detectaron tres intentos válidos muy alejados del nivel de referencia de sus respectivos atletas. Estos casos no se eliminaron del análisis principal, ya que correspondían a saltos reales, pero sí se estudiaron mediante un análisis de sensibilidad.

Al excluir esos valores extremos, el mejor modelo pasó a ser un Random Forest con variables temporales y espaciales, reduciendo el MAE hasta 16,71 cm y el RMSE hasta 21,65 cm. Este resultado muestra que los modelos funcionan mejor cuando los intentos son técnicamente más comparables. También indica que algunos saltos válidos muy alejados del nivel del atleta pueden estar influidos por factores que no quedan completamente representados en las variables extraídas, especialmente aquellos relacionados con la fase aérea, la caída o la finalización del gesto.

La sexta conclusión es que el trabajo confirma la utilidad de combinar análisis

biomecánico e inteligencia artificial, pero también muestra la necesidad de interpretar los resultados con prudencia. Los modelos no deben entenderse como sistemas cerrados de predicción automática, sino como herramientas exploratorias que permiten identificar señales, comparar tipos de variables y generar hipótesis técnicas sobre el rendimiento.

7.2. Cumplimiento de los objetivos

En relación con los objetivos planteados al inicio del trabajo, puede afirmarse que se han cumplido de forma general.

El primer objetivo consistía en construir una base de datos propia a partir de material real de competición. Este objetivo se ha alcanzado mediante la integración de vídeos laterales, hoja oficial de resultados e información histórica de rendimiento de los atletas. El resultado fue un dataset a nivel de intento, con trazabilidad entre cada vídeo, el atleta correspondiente, el resultado oficial y las variables técnicas extraídas.

El segundo objetivo era desarrollar un procedimiento de extracción de variables biomecánicas a partir de vídeo. Este objetivo también se ha cumplido. El pipeline desarrollado permitió obtener variables espaciales, temporales, angulares y de velocidad, utilizando estimación de pose y criterios de filtrado adaptados a las condiciones reales de grabación.

El tercer objetivo consistía en analizar la calidad del dataset y preparar los datos para aprendizaje automático. Este objetivo se abordó mediante una fase de análisis exploratorio, revisión de valores ausentes, detección de outliers y organización de las variables en paquetes biomecánicos. Esta fase permitió conservar el mayor número posible de intentos y, al mismo tiempo, evitar que errores evidentes de extracción condicionaran los modelos.

El cuarto objetivo era evaluar si las variables extraídas permitían clasificar saltos válidos y nulos. Los resultados obtenidos muestran que existe señal útil para esta tarea, especialmente en las variables temporales y espaciales. Aunque el modelo no alcanza una precisión suficiente para su uso práctico automático, sí supera una aproximación básica y ofrece una interpretación coherente con la técnica del salto.

El quinto objetivo consistía en estudiar la relación entre las variables biomecánicas y el rendimiento del salto. Este objetivo se abordó mediante dos tareas de regresión: la predicción de marca absoluta y la predicción del rendimiento relativo. Ambas tareas mostraron mejoras moderadas respecto a modelos de referencia, aunque también evidenciaron la complejidad de predecir el rendimiento deportivo a partir de una muestra reducida y de vídeo 2D.

Finalmente, el sexto objetivo era interpretar los resultados desde una perspectiva biomecánica y metodológica. Este objetivo se ha cumplido mediante el análisis de paquetes de variables, la revisión de errores, el análisis de sensibilidad y la discusión de las limitaciones del sistema. El trabajo no se limita a presentar métricas, sino que intenta explicar qué significan esos resultados en el contexto del salto de longitud.

7.3. Aportaciones del trabajo

La primera aportación del trabajo es la construcción de un flujo completo de análisis desde vídeo real hasta modelado predictivo. Este aspecto es relevante porque la mayor dificultad no estuvo únicamente en entrenar modelos, sino en transformar material audiovisual no estructurado en una base de datos técnica y utilizable.

La segunda aportación es la adaptación de herramientas de visión por computador a un contexto deportivo real. El uso de MediaPipe Pose, combinado con recortes del atleta, filtros de identidad, reconstrucción de coordenadas y control de calidad, permitió obtener variables interpretables sin necesidad de instrumentación específica.

La tercera aportación es la organización de las variables en paquetes biomecánicos. Esta decisión permitió estudiar de forma separada la utilidad de variables angulares, velocidades, variables temporales y espaciales, y combinaciones de todas ellas. Gracias a esta comparación, el análisis no se limitó a buscar el mejor modelo, sino que permitió interpretar qué tipo de información parecía más relevante para cada tarea.

La cuarta aportación es la propuesta de la variable marca_vs_nivel_cm. Esta variable permitió contextualizar cada salto en función del nivel previo del atleta, ofreciendo una lectura más individualizada del rendimiento. En lugar de analizar únicamente la marca absoluta, el trabajo pudo estudiar si un intento se situaba por encima o por debajo del rendimiento esperable para ese deportista concreto.

La quinta aportación es el análisis de sensibilidad aplicado a los valores extremos del rendimiento relativo. Esta fase permitió comprobar cómo cambiaba el comportamiento de los modelos al retirar intentos muy alejados del nivel habitual del atleta. El análisis mostró que estos casos condicionaban de forma importante el error, pero también que no debían eliminarse sin más, ya que representan situaciones reales de competición.

7.4. Limitaciones del estudio

A pesar de las aportaciones anteriores, el trabajo presenta varias limitaciones que deben tenerse en cuenta.

La primera limitación es el tamaño reducido de la muestra. El dataset final contiene 66 intentos, de los cuales 42 son válidos y 24 nulos. Este tamaño permite realizar un análisis exploratorio, pero limita la estabilidad de los modelos y la capacidad de generalización de los resultados. Con muestras pequeñas, las métricas pueden verse afectadas por pocos casos concretos, especialmente en las tareas de regresión.

La segunda limitación es que todos los datos proceden de una única competición. Esta decisión permitió mantener un entorno homogéneo de grabación, pero también limita la variabilidad del dataset. No se puede asegurar que los modelos funcionen igual en otras competiciones, instalaciones, cámaras, categorías o niveles deportivos.

La tercera limitación es el uso de una única cámara lateral. Esta perspectiva resulta útil para estudiar variables horizontales, distancias a la tabla, longitudes de paso y algunos ángulos observables en el plano principal del movimiento. Sin

embargo, no permite reconstruir con precisión tridimensional el gesto completo. Algunos movimientos fuera del plano de cámara, rotaciones corporales, ajustes laterales o detalles de la caída no pueden analizarse adecuadamente con esta configuración.

La cuarta limitación está relacionada con la estimación automática de pose. Aunque MediaPipe Pose permite obtener puntos corporales de forma accesible, sus detecciones pueden verse afectadas por oclusiones, cambios rápidos de postura, presencia de otras personas, pérdida de puntos corporales o confusión con elementos del entorno. Por ello, las variables extraídas deben interpretarse como aproximaciones, no como mediciones biomecánicas exactas.

La quinta limitación es que el trabajo no analiza de forma completa la fase aérea ni la caída. Esta decisión fue metodológica y técnica. Desde el punto de vista técnico, la fase aérea y la caída presentan mayor inestabilidad visual, más oclusiones y más superposición de segmentos corporales. Desde el punto de vista metodológico, utilizar variables demasiado cercanas al final del salto podría introducir información excesivamente relacionada con la marca final. Por esta razón, el análisis se centró en la aproximación final, los últimos apoyos, la batida y un tramo postbatida controlado.

La sexta limitación es la ausencia de un conjunto de test externo. Debido al tamaño reducido de la muestra, se utilizó validación cruzada en lugar de reservar una parte fija del dataset para test. Esta decisión permitió aprovechar mejor los datos disponibles, pero no sustituye a una validación externa con nuevos vídeos y nuevos atletas.

La séptima limitación es que las variables históricas utilizadas para calcular el nivel de referencia dependen de la disponibilidad de registros previos. En algunos atletas no existía suficiente información comparable, lo que impidió calcular el rendimiento relativo en todos los casos. Además, el nivel de referencia es una aproximación al rendimiento habitual, no una medida perfecta del estado real del atleta en el momento de la competición.

7.5. Trabajo futuro

A partir de las limitaciones detectadas, se proponen varias líneas de trabajo futuro.

La primera línea sería ampliar el dataset con más competiciones, más atletas y más intentos. Un mayor volumen de datos permitiría entrenar modelos más estables, reservar un conjunto de test independiente y evaluar si los patrones observados se mantienen en otros contextos competitivos.

La segunda línea sería incorporar competiciones con distintas condiciones de grabación. Esto permitiría comprobar la robustez del pipeline ante cambios de cámara, iluminación, instalación, encuadre o nivel deportivo. También ayudaría a evaluar si el sistema puede generalizarse más allá de una única competición.

La tercera línea sería utilizar varias cámaras o sistemas de reconstrucción tridimensional. Una segunda cámara permitiría reducir las limitaciones de la perspectiva lateral y capturar mejor movimientos fuera del plano. Esto sería especialmente útil para analizar la fase aérea, la caída y la posición exacta del cuerpo en momentos donde la visión 2D resulta insuficiente.

La cuarta línea sería explorar modelos de estimación de pose más específicos

para deporte, como sistemas entrenados o ajustados sobre imágenes de salto de longitud. Herramientas como DeepLabCut podrían permitir un análisis más preciso si se dispone de suficientes imágenes etiquetadas. Sin embargo, esto exigiría una fase adicional de anotación manual y validación.

La quinta línea sería mejorar la detección automática de apoyos y batida. Aunque el sistema desarrollado permitió obtener variables útiles, la detección de apoyos sigue siendo una fase sensible del pipeline. Futuras versiones podrían combinar la estimación de pose con técnicas de seguimiento del pie, segmentación de imagen o detección específica de contacto con el suelo.

La sexta línea sería incorporar un análisis más detallado de la fase aérea y de la caída, siempre que se disponga de datos visuales más adecuados. Esta ampliación permitiría estudiar aspectos que en este trabajo quedaron fuera por prudencia metodológica, como la posición del cuerpo en vuelo, la coordinación segmentaria antes de la caída o la técnica de aterrizaje.

La séptima línea sería validar el sistema con apoyo experto. La revisión de entrenadores, biomecánicos o especialistas en salto de longitud podría ayudar a interpretar los errores del modelo, clasificar cualitativamente los intentos y comprobar si las variables más importantes tienen sentido desde la experiencia técnica.

La octava línea sería desarrollar una herramienta visual de apoyo al análisis técnico. A partir del pipeline construido, podría plantearse una interfaz que permitiera cargar un vídeo, visualizar la pose estimada, revisar apoyos detectados, observar variables extraídas y comparar el intento con referencias previas. Esta herramienta no tendría que sustituir al entrenador, sino servir como apoyo para revisar patrones técnicos de forma más objetiva.

7.6. Conclusión final

Este Trabajo Fin de Grado demuestra que es posible utilizar técnicas de visión por computador y aprendizaje automático para construir un análisis exploratorio del salto de longitud a partir de vídeo real de competición. A pesar de las limitaciones del material disponible, el pipeline desarrollado permitió extraer variables biomecánicas, construir un dataset propio y evaluar distintas tareas de clasificación y regresión.

Los resultados muestran que las variables temporales y espaciales de la aproximación final son especialmente útiles para clasificar saltos válidos y nulos, mientras que las variables de velocidad aportan información relevante para estimar el rendimiento relativo respecto al nivel individual del atleta. La predicción de la marca absoluta resulta más limitada, lo que confirma que el rendimiento final depende de factores que van más allá de las variables extraídas desde vídeo.

La aportación más relevante del trabajo no reside únicamente en las métricas obtenidas, sino en haber diseñado un proceso completo, trazable y técnicamente interpretable. El estudio demuestra que, incluso con una muestra reducida y vídeos no grabados en laboratorio, es posible obtener información útil para el análisis deportivo. Al mismo tiempo, los resultados muestran con claridad las limitaciones del enfoque y la necesidad de seguir avanzando hacia sistemas más robustos, con más datos, mejores condiciones de captura y validación externa.

En definitiva, el trabajo constituye una primera aproximación sólida al uso de visión por computador y aprendizaje automático en el análisis del salto de longitud. Sus resultados no deben interpretarse como una solución definitiva, sino como una base metodológica sobre la que pueden construirse investigaciones futuras más amplias y precisas.

8 Análisis de Impacto

En este capítulo se analiza el impacto potencial del trabajo desarrollado desde una perspectiva deportiva, tecnológica, académica y social. Dado que se trata de un Trabajo Fin de Grado de carácter exploratorio, el impacto del proyecto no debe entenderse como el de una herramienta profesional cerrada, sino como el de una metodología inicial para estudiar el salto de longitud a partir de vídeo real de competición, visión por computador y aprendizaje automático.

El trabajo no pretende sustituir a los sistemas biomecánicos profesionales ni a la observación experta de entrenadores y especialistas. Su aportación principal consiste en demostrar que es posible transformar material audiovisual no estructurado en variables técnicas analizables, y utilizar dichas variables para estudiar la validez del intento y el rendimiento alcanzado.

8.1 Impacto deportivo

Desde el punto de vista deportivo, el trabajo permite aproximarse de forma cuantitativa a elementos técnicos relevantes del salto de longitud, como la carrera de aproximación, la llegada a la tabla, la organización de los últimos apoyos, la velocidad de entrada y la batida. Estas variables pueden aportar información complementaria a la observación visual tradicional, especialmente en el análisis de diferencias entre saltos válidos y nulos.

Además, la incorporación de la variable marca_vs_nivel_cm permite interpretar el rendimiento no solo en función de la marca absoluta, sino también en relación con el nivel previo de cada atleta. Esto resulta útil porque una misma distancia puede tener significados distintos según el deportista. De este modo, el trabajo propone una forma más contextualizada de analizar el rendimiento individual.

No obstante, los resultados deben interpretarse con prudencia. El sistema no alcanza un nivel suficiente para ser utilizado de forma automática en competición, pero sí muestra que las variables extraídas del vídeo pueden contener información útil para el análisis técnico del salto.

8.2 Impacto tecnológico

Desde el punto de vista tecnológico, el trabajo demuestra la viabilidad de construir un flujo completo de procesamiento desde vídeos reales hasta una base de datos estructurada. Este proceso incluye la organización del material, la asociación con resultados oficiales, la estimación de pose, la detección de eventos, la extracción de variables, el control de calidad y la aplicación de modelos de aprendizaje automático.

La principal aportación tecnológica está en trabajar con material real de competición, no con un dataset ya preparado. Esto implica enfrentarse a problemas como oclusiones, errores de detección, presencia de otras personas en la escena o pérdida de puntos corporales. Por ello, el trabajo no solo aplica herramientas de inteligencia artificial, sino que también desarrolla criterios para revisar, filtrar y validar las variables obtenidas.

El uso de herramientas accesibles como MediaPipe Pose y scikit-learn muestra que es posible construir una primera aproximación funcional sin necesidad de equipamiento biomecánico avanzado. Aun así, el proyecto también evidencia que estas tecnologías requieren control metodológico y una interpretación

crítica de sus resultados.

8.3 Impacto académico y formativo

El trabajo tiene un impacto académico porque integra distintas fases propias de un proyecto real de ciencia de datos: construcción del conjunto de datos, extracción de variables, limpieza, análisis exploratorio, modelado, evaluación e interpretación de resultados.

Una de sus principales aportaciones formativas es que no parte de datos ideales, sino de vídeos reales de competición. Esto obliga a tomar decisiones metodológicas, controlar errores, tratar valores ausentes y justificar qué variables pueden utilizarse con suficiente fiabilidad. En este sentido, el proyecto muestra que el rendimiento de un modelo no depende únicamente del algoritmo empleado, sino también de la calidad del dato y de la coherencia del proceso previo.

Además, el TFG combina conocimientos de biomecánica deportiva, visión por computador, programación y aprendizaje automático, lo que refuerza su carácter interdisciplinar.

8.4 Impacto económico y accesibilidad

El análisis biomecánico avanzado suele requerir equipamiento especializado y recursos técnicos que no siempre están disponibles en clubes, centros de tecnificación o contextos formativos. Frente a ello, el enfoque desarrollado en este trabajo explora una alternativa más accesible basada en vídeo lateral y herramientas de software abiertas.

Aunque esta aproximación no alcanza la precisión de un laboratorio, puede servir como punto de partida para análisis exploratorios o para futuras herramientas de apoyo técnico de menor coste. Su aplicación práctica requeriría mejoras y validación adicional, pero el trabajo muestra una posible vía para acercar el análisis objetivo del movimiento a entornos con menos recursos.

8.5 Relación con los Objetivos de Desarrollo Sostenible

El trabajo puede relacionarse de forma indirecta con varios Objetivos de Desarrollo Sostenible, aunque su contribución debe interpretarse de manera proporcional al alcance académico del proyecto.

En primer lugar, se vincula con el ODS 3, Salud y bienestar, al contribuir al desarrollo de herramientas que pueden mejorar el análisis técnico y favorecer una práctica deportiva más informada. En el caso del salto de longitud, analizar la carrera de aproximación, la batida y la organización de los apoyos puede aportar información útil para optimizar la técnica y promover una práctica más segura.

En segundo lugar, se relaciona con el ODS 4, Educación de calidad, por su valor formativo en el uso aplicado de la inteligencia artificial y la ciencia de datos. El proyecto permite aprender mediante un caso real, combinando programación, análisis de datos, visión por computador, biomecánica y evaluación crítica de modelos.

También se conecta con el ODS 9, Industria, innovación e infraestructura, al explorar una solución tecnológica innovadora aplicada al análisis del rendimiento deportivo. Aunque el sistema es exploratorio, muestra una línea de

desarrollo que podría evolucionar hacia herramientas más completas de análisis técnico.

Por último, puede vincularse de forma indirecta con el ODS 10, Reducción de las desigualdades, en la medida en que explora una aproximación más accesible al análisis deportivo. El uso de vídeo y herramientas abiertas podría contribuir a reducir la brecha tecnológica entre entornos con alta disponibilidad de recursos y contextos deportivos con menos medios.

9 Bibliografía

[1] «Book of Rules | Official Documents». Accedido: 25 de junio de 2026. [En línea]. Disponible en: https://worldathletics.org/about-iaaf/documents/book-of-rules

[2] J. G. Hay, «The biomechanics of the long jump», *Exerc. Sport Sci. Rev.*, vol. 14, pp. 401-446, 1986.

[3] J. G. Hay, J. A. Miller, y R. W. Canterna, «The techniques of elite male long jumpers», *J. Biomech.*, vol. 19, n.º 10, pp. 855-866, 1986, doi: 10.1016/0021-9290(86)90136-3.

[4] L. Bridgett y N. Linthorne, «Changes in long jump take-off technique with increasing run-up speed», *J. Sports Sci.*, vol. 24, pp. 889-97, sep. 2006, doi: 10.1080/02640410500298040.

[5] N. P. Linthorne, M. S. Guzman, y L. A. Bridgett, «Optimum take-off angle in the long jump», *J. Sports Sci.*, vol. 23, n.º 7, pp. 703-712, jul. 2005, doi: 10.1080/02640410400022011.

[6] J. G. Hay y H. Nohara, «Techniques used by elite long jumpers in preparation for takeoff», *J. Biomech.*, vol. 23, n.º 3, pp. 229-239, 1990, doi: 10.1016/0021-9290(90)90014-t.

[7] D. Lee, J. Lishman, y J. Thomson, «Regulation of gait in long jumping», *J. Exp. Psychol. Hum. Percept. Perform.*, vol. 8, pp. 448-459, jun. 1982, doi: 10.1037/0096-1523.8.3.448.

[8] M. A. Scott, F. X. Li, y K. Davids, «Expertise and the regulation of gait in the approach phase of the long jump», *J. Sports Sci.*, vol. 15, n.º 6, pp. 597-605, dic. 1997, doi: 10.1080/026404197367038.

[9] H. Makaruk, M. Starzak, y J. Sadowski, «Does step length adjustment determine take-off accuracy and approach run velocity in long and triple jumps?», *Hum. Mov.*, vol. 16, n.º 3, pp. 124-129, mar. 2018, doi: 10.1515/humo-2015-0038.

[10] «Innovations | World Athletics». Accedido: 18 de abril de 2026. [En línea]. Disponible en: https://worldathletics.org/competitions/innovations

[11] «Long jump trial planned to eliminate foul jumps», *Reuters*, 20 de febrero de 2024. Accedido: 25 de junio de 2026. [En línea]. Disponible en: https://www.reuters.com/sports/athletics/long-jump-trial-planned-eliminate-foul-jumps-2024-02-20/

[12] C. P. Hensley, D. Kontos, C. Feldman, Q. E. Wafford, A. Wright, y A. H. Chang, «Reliability and validity of 2-dimensional video analysis for a running task: A systematic review», *Phys. Ther. Sport Off. J. Assoc. Chart. Physiother. Sports Med.*, vol. 58, pp. 16-33, nov. 2022, doi: 10.1016/j.ptsp.2022.08.001.

[13] G. Leporace *et al.*, «Validity and reliability of two-dimensional video-based assessment to measure joint angles during running: A systematic review and meta-analysis», *J. Biomech.*, vol. 157, p. 111747, ago. 2023, doi: 10.1016/j.jbiomech.2023.111747.

[14] A. Badiola-Bengoa y A. Mendez-Zorrilla, «A Systematic Review of the Application of Camera-Based Human Pose Estimation in the Field of Sport and Physical Exercise», *Sensors*, vol. 21, n.º 18, p. 5996, ene. 2021, doi: 10.3390/s21185996.

[15] C. Aulton, L. Wakili, B. W. Strafford, K. Davids, y C.-Y. Chiu, «The Application of Deep Learning Human Pose Estimation in Sport: A Systematic Review», *Sports Med. - Open*, vol. 11, n.º 1, p. 155, dic. 2025, doi: 10.1186/s40798-025-00953-3.

[16] M. Souaifi *et al.*, «Artificial Intelligence in Sports Biomechanics: A Scoping Review on Wearable Technology, Motion Analysis, and Injury Prevention», *Bioengineering*, vol. 12, n.º 8, p. 887, ago. 2025, doi: 10.3390/bioengineering12080887.

[17] M. Uçar, M. O. İNcetaş, I. Bayraktar, y M. ÇiLli, «Using Machine Learning Algorithms for Jumping Distance Prediction of Male Long Jumpers», *J. Intell. Syst. Theory Appl.*, vol. 5, n.º 2, pp. 145-152, sep. 2022, doi: 10.38016/jista.1078474.

[18] T. Kamnardsiri, W. Janchaia, P. Khuwuthyakorn, P. Suwansrikham, J. Klaphajoneb, y P. Suriyachanc, «Knowledge-Based System Framework for Training Long Jump Athletes Using Action Recognition», *J. Adv. Inf. Technol.*, pp. 182-193, nov. 2015, doi: 10.12720/jait.6.4.182-193.

[19] A. Lees, N. Fowler, y D. Derby, «A biomechanical analysis of the last stride, touch-down and take-off characteristics of the women's long jump», *J. Sports Sci.*, vol. 11, n.º 4, pp. 303-314, ago. 1993, doi: 10.1080/02640419308730000.

[20] H. Makaruk, M. Starzak, y J. L. López, «The role of a check-mark in step length adjustment in long jump», *J. Hum. Sport Exerc.*, vol. 10, n.º 3, 2015, doi: 10.14198/jhse.2015.103.01.
[21] C. McCosker, I. Renshaw, D. Greenwood, K. Davids, y E. Gosden, «How performance analysis of elite long jumping can inform representative training design through identification of key constraints on competitive behaviours», *Eur. J. Sport Sci.*, vol. 19, n.º 7, pp. 913-921, ago. 2019, doi: 10.1080/17461391.2018.1564797.
[22] V. Panoutsakopoulos, A. Theodorou, M. C. Kotzamanidou, y I. Kollias, «Biomechanical analysis of the 2017 European indoor champion in the women's long jump: case report», *Exerc. Qual. Life*, vol. 12, pp. 5-13, jun. 2020, doi: 10.31382/eqol.200601.
[23] M. Zhuang, «Sports Video Structure Analysis and Feature Extraction in Long Jump Video», *Int. J. Multimed. Ubiquitous Eng.*, vol. 11, pp. 83-92, sep. 2016, doi: 10.14257/ijmue.2016.11.9.09.
[24] «Frontiers | Feasibility of OpenPose markerless motion analysis in a real athletics competition». Accedido: 19 de abril de 2026. [En línea]. Disponible en: https://www.frontiersin.org/journals/sports-and-active-living/articles/10.3389/fspor.2023.1298003/full
[25] T. Baumgartner, B. Paassen, y S. Klatt, «Extracting spatial knowledge from track and field broadcasts for monocular 3D human pose estimation», *Sci. Rep.*, vol. 13, n.º 1, p. 14031, ago. 2023, doi: 10.1038/s41598-023-41142-0.
[26] K. Ludwig, J. Lorenz, R. Schön, y R. Lienhart, «All Keypoints You Need: Detecting Arbitrary Keypoints on the Body of Triple, High, and Long Jump Athletes», presentado en Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023, pp. 5179-5187. Accedido: 19 de abril de 2026. [En línea]. Disponible en: https://openaccess.thecvf.com/content/CVPR2023W/CVSports/html/Ludwig_All_Keypoints_You_Need_Detecting_Arbitrary_Keypoints_on_the_Body_CVPRW_2023_paper.html
[27] S. Béres, Z. Csende, A. Lees, y J. Tihanyi, «Prediction of jumping distance using a short approach model», *Kinesiology*, vol. 46., n.º 1., pp. 88-96, jun. 2014.
[28] Q. Gan, S. Clémençon, M. A. El-Yacoubi, S. M. Nguyen, E. Fenaux, y O. Jelassi, «Feature Impact Analysis on Top Long-Jump Performances with Quantile Random Forest and Explainable AI Techniques», 13 de agosto de 2025, *arXiv*: arXiv:2508.09810. doi: 10.48550/arXiv.2508.09810.
[29] A. Shah y D. Prajapati, «Recent Advances in Computer Vision and Machine Learning for Athletic Performance in Jump Events», *Augment. Hum. Res.*, vol. 10, n.º 1, p. 12, oct. 2025, doi: 10.1007/s41133-025-00087-x.
[30] Q. Gan, «Sports Motion Analysis : From Competition Videos to Data-Driven Interpretations», Theses, Institut Polytechnique de Paris, 2025. doi: 10.70675/5ae10807zc807z4f8dzb4d3z832fd95de4cb.
[31] B. De Lazzari, G. Mascia, G. Vannozzi, y V. Camomilla, «Estimating the Standing Long Jump Length from Smartphone Inertial Sensors through Machine Learning Algorithms», *Bioengineering*, vol. 10, n.º 5, p. 546, may 2023, doi: 10.3390/bioengineering10050546.
[32] «PeerJ Applications and limitations of current markerless motion capture methods for clinical gait biomechanics». Accedido: 19 de abril de 2026. [En línea]. Disponible en: https://peerj.com/articles/12995/
[33] C. Lugaresi *et al.*, «MediaPipe: A Framework for Building Perception Pipelines», 14 de junio de 2019, *arXiv*: arXiv:1906.08172. doi: 10.48550/arXiv.1906.08172.
[34] «Human Pose Estimation Based Biomechanical Feature Extraction for Long Jumps | IEEE Conference Publication | IEEE Xplore». Accedido: 27 de junio de 2026. [En línea]. Disponible en: https://ieeexplore.ieee.org/document/10613530
[35] Y. Fang, Q. Gan, y S. M. Nguyen, «Computer vision-based foot contact detection for long jump using a monocular normal-speed camera», Nida Meddouri and Albrecht Zimmermann and Clément Iphar and Aurélie Leborgne and Loïc Salmon, mayo de 2025. Accedido: 27 de junio de 2026. [En línea]. Disponible en: https://hal.science/hal-05090038
[36] C. Cortes y V. Vapnik, «Support-vector networks», *Mach. Learn.*, vol. 20, n.º 3, pp. 273-297, sep. 1995, doi: 10.1007/BF00994018.
[37] L. Breiman, «Random Forests», *Mach. Learn.*, vol. 45, n.º 1, pp. 5-32, oct. 2001, doi: 10.1023/A:1010933404324.

[38] J. H. Friedman, «Greedy function approximation: A gradient boosting machine.», *Ann. Stat.*, vol. 29, n.º 5, pp. 1189-1232, oct. 2001, doi: 10.1214/aos/1013203451.
[39] F. Pedregosa *et al.*, «Scikit-learn: Machine Learning in Python», 5 de junio de 2018, *arXiv*: arXiv:1201.0490. doi: 10.48550/arXiv.1201.0490.
[40] «DummyRegressor», scikit-learn. Accedido: 26 de junio de 2026. [En línea]. Disponible en: https://scikit-learn/stable/modules/generated/sklearn.dummy.DummyRegressor.html
[41] «Ridge Regression: Biased Estimation for Nonorthogonal Problems: Technometrics: Vol 12, No 1». Accedido: 26 de junio de 2026. [En línea]. Disponible en: https://www.tandfonline.com/doi/abs/10.1080/00401706.1970.10488634
[42] «Regularization and Variable Selection Via the Elastic Net | Journal of the Royal Statistical Society Series B: Statistical Methodology | Oxford Academic». Accedido: 26 de junio de 2026. [En línea]. Disponible en: https://academic.oup.com/jrsssb/article/67/2/301/7109482

Anexos

Apéndice A

Diccionario de variables biomecánicas del modelo

La Tabla A.1 recoge las 64 variables biomecánicas consideradas en el paquete completo de modelado. Para cada variable se indica su categoría, el paquete o paquetes de variables en los que se utilizó y una interpretación técnica breve.

Tabla A.1. Diccionario de variables biomecánicas utilizadas en los modelos.

Nº	Variable	Categoría	Paquete(s) de modelado	Descripción / interpretación técnica
1,000	apoyo_m1_distancia_a_tabla_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Distancia horizontal, en metros, entre el último apoyo previo a la batida y la tabla de batida.
2,000	apoyo_m2_distancia_a_tabla_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Distancia horizontal, en metros, entre el segundo apoyo previo a la batida y la tabla de batida.
3,000	apoyo_m3_distancia_a_tabla_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Distancia horizontal, en metros, entre el tercer apoyo previo a la batida y la tabla de batida.
4,000	apoyo_m4_distancia_a_tabla_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Distancia horizontal, en metros, entre el cuarto apoyo previo a la batida y la tabla de batida.
5,000	apoyo_m1_longitud_hasta_siguiente_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Longitud horizontal, en metros, desde el último apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
6,000	apoyo_m2_longitud_hasta_siguiente_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Longitud horizontal, en metros, desde el segundo apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
7,000	apoyo_m3_longitud_hasta_siguiente_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Longitud horizontal, en metros, desde el tercer apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
8,000	apoyo_m4_longitud_hasta_siguiente_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Longitud horizontal, en metros, desde el cuarto apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
9,000	apoyo_m1_tiempo_hasta_siguiente_s	Temporal	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Tiempo, en segundos, transcurrido desde el último apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
10	apoyo_m2_tiempo_hasta_siguiente_s	Temporal	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Tiempo, en segundos, transcurrido desde el segundo apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
11	apoyo_m3_tiempo_hasta_siguiente_s	Temporal	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Tiempo, en segundos, transcurrido desde el tercer apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
12	apoyo_m4_tiempo_hasta_siguiente_s	Temporal	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Tiempo, en segundos, transcurrido desde el cuarto apoyo previo a la batida hasta el siguiente evento de apoyo/batida.
13	apoyo_m1_velocidad_paso_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media del tramo asociado al último apoyo previo a la batida, calculada a partir de distancia y tiempo.

Nº	Variable	Categoría	Paquete(s) de modelado	Descripción / interpretación técnica
14	apoyo_m2_velocidad_paso_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media del tramo asociado al segundo apoyo previo a la batida, calculada a partir de distancia y tiempo.
15	apoyo_m3_velocidad_paso_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media del tramo asociado al tercer apoyo previo a la batida, calculada a partir de distancia y tiempo.
16	apoyo_m4_velocidad_paso_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media del tramo asociado al cuarto apoyo previo a la batida, calculada a partir de distancia y tiempo.
17	apoyo_m1_angulo_rodilla_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna de apoyo en el último apoyo previo a la batida.
18	apoyo_m2_angulo_rodilla_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna de apoyo en el segundo apoyo previo a la batida.
19	apoyo_m3_angulo_rodilla_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna de apoyo en el tercer apoyo previo a la batida.
20	apoyo_m4_angulo_rodilla_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna de apoyo en el cuarto apoyo previo a la batida.
21	batida_angulo_rodilla_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna de apoyo en el instante de batida.
22	apoyo_m1_angulo_cadera_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna de apoyo en el último apoyo previo a la batida.
23	apoyo_m2_angulo_cadera_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna de apoyo en el segundo apoyo previo a la batida.
24	apoyo_m3_angulo_cadera_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna de apoyo en el tercer apoyo previo a la batida.
25	apoyo_m4_angulo_cadera_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna de apoyo en el cuarto apoyo previo a la batida.
26	batida_angulo_cadera_apoyo	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna de apoyo en el instante de batida.
27	apoyo_m1_angulo_rodilla_aire	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna libre o de aire en el último apoyo previo a la batida.
28	apoyo_m2_angulo_rodilla_aire	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna libre o de aire en el segundo apoyo previo a la batida.
29	apoyo_m3_angulo_rodilla_aire	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna libre o de aire en el tercer apoyo previo a la batida.
30	apoyo_m4_angulo_rodilla_aire	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna libre o de aire en el cuarto apoyo previo a la batida.
31	batida_angulo_rodilla_aire	Angular	Angulares; Todas biomecánicas	Ángulo de rodilla de la pierna libre o de aire en el instante de batida.
32	apoyo_m1_angulo_cadera_aire	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna libre o de aire en el último apoyo previo a la batida.
33	apoyo_m2_angulo_cadera_aire	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna libre o de aire en el segundo apoyo previo a la batida.
34	apoyo_m3_angulo_cadera_aire	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna libre o de aire en el tercer apoyo previo a la batida.
35	apoyo_m4_angulo_cadera_aire	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna libre o de aire en el cuarto apoyo previo a la batida.
36	batida_angulo_cadera_aire	Angular	Angulares; Todas biomecánicas	Ángulo de cadera de la pierna libre o de aire en el instante de batida.
37	apoyo_m1_dif_rodilla_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de rodilla de la pierna de apoyo y la pierna libre en el último apoyo previo a la batida.
38	apoyo_m2_dif_rodilla_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de rodilla de la pierna de apoyo y la pierna libre en el segundo apoyo previo a la batida.
39	apoyo_m3_dif_rodilla_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de rodilla de la pierna de apoyo y la pierna libre en el tercer apoyo previo a la batida.

Nº	Variable	Categoría	Paquete(s) de modelado	Descripción / interpretación técnica
40	apoyo_m4_dif_rodilla_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de rodilla de la pierna de apoyo y la pierna libre en el cuarto apoyo previo a la batida.
41	batida_dif_rodilla_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de rodilla de la pierna de apoyo y la pierna libre en batida.
42	apoyo_m1_dif_cadera_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de cadera de la pierna de apoyo y la pierna libre en el último apoyo previo a la batida.
43	apoyo_m2_dif_cadera_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de cadera de la pierna de apoyo y la pierna libre en el segundo apoyo previo a la batida.
44	apoyo_m3_dif_cadera_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de cadera de la pierna de apoyo y la pierna libre en el tercer apoyo previo a la batida.
45	apoyo_m4_dif_cadera_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de cadera de la pierna de apoyo y la pierna libre en el cuarto apoyo previo a la batida.
46	batida_dif_cadera_apoyo_aire	Angular	Angulares; Todas biomecánicas	Diferencia entre el ángulo de cadera de la pierna de apoyo y la pierna libre en batida.
47	apoyo_m1_inclinacion_tronco	Angular	Angulares; Todas biomecánicas	Inclinación del tronco estimada en el último apoyo previo a la batida.
48	apoyo_m2_inclinacion_tronco	Angular	Angulares; Todas biomecánicas	Inclinación del tronco estimada en el segundo apoyo previo a la batida.
49	apoyo_m3_inclinacion_tronco	Angular	Angulares; Todas biomecánicas	Inclinación del tronco estimada en el tercer apoyo previo a la batida.
50	apoyo_m4_inclinacion_tronco	Angular	Angulares; Todas biomecánicas	Inclinación del tronco estimada en el cuarto apoyo previo a la batida.
51	batida_inclinacion_tronco	Angular	Angulares; Todas biomecánicas	Inclinación del tronco estimada en el instante de batida.
52	velocidad_entrada_ultimo_tramo_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad de entrada estimada en el último tramo previo a la batida.
53	velocidad_entrada_media_2tramos_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media de entrada calculada sobre los dos últimos tramos previos a la batida.
54	velocidad_entrada_media_3tramos_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media de entrada calculada sobre los tres últimos tramos previos a la batida.
55	velocidad_entrada_principal_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Variable resumen de velocidad de entrada seleccionada como referencia principal.
56	velocidad_entrada_directa_apoyo1_batida_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad directa entre el último apoyo previo y la batida.
57	time_batida_velocidad_s	Temporal	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Tiempo de referencia asociado al cálculo de la velocidad de entrada hasta la batida.
58	delta_t_velocidad_media_s	Temporal	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Intervalo temporal entre la batida y el frame postbatida usado para calcular velocidad media.
59	delta_x_m	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Desplazamiento horizontal de la cadera entre batida y frame postbatida común.
60	delta_y_m_vertical_positiva_arriba	Espacial	Temporales/espaciales; Velocidades + temporales/espaciales; Todas biomecánicas	Desplazamiento vertical de la cadera entre batida y frame postbatida común, con sentido positivo hacia arriba.
61	velocidad_media_horizontal_signed_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media horizontal postbatida con signo, calculada a partir del desplazamiento de la cadera.
62	velocidad_media_horizontal_abs_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media horizontal postbatida en valor absoluto.
63	velocidad_media_vertical_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media vertical postbatida de la cadera.

Nº	Variable	Categoría	Paquete(s) de modelado	Descripción / interpretación técnica
64	velocidad_media_resultante_m_s	Velocidad	Velocidades; Velocidades + temporales/espaciales; Todas biomecánicas	Velocidad media resultante postbatida combinando componentes horizontal y vertical.

Apéndice B

Resultados y tratamiento de valores extremos

Las siguientes tablas resumen la revisión de valores extremos realizada sobre el rendimiento relativo y sobre variables biomecánicas críticas. El objetivo de estas tablas es dejar trazabilidad de qué casos fueron identificados, cómo se trataron y qué efecto tuvo el análisis de sensibilidad sobre los resultados del modelo.

Tabla B.1. Criterios de detección de valores extremos en la variable marca_vs_nivel_cm.

N saltos regresión completo	Q1	Q3	IQR	Límite inferior IQR	Límite superior IQR	Mediana	MAD	N outliers IQR	N outliers MAD	N extremos finales	N saltos sin extremos
39	-37,500	0,670	38,170	-94,750	57,920	-11,330	15,670	3,000	3,000	3,000	36

Tabla B.2. Valores extremos detectados en la variable marca_vs_nivel_cm.

Vídeo	Atleta	Resultado original (m)	Marca (m)	Nivel referencia (m)	marca_vs_nivel_cm	z robusto	Outlier IQR	Outlier MAD
Longi_MASC_057	JUAN FRANCISCO TRUJILLO DIAZ	5,820	5,820	7,580	-176	-7,090	Sí	Sí
Longi_MASC_028	SERGIO COELLO BERRECO	6,610	6,610	7,670	-106,330	-4,090	Sí	Sí
Longi_MASC_024	IVAN VERDUGO GUERRA	6,450	6,450	7,440	-99	-3,770	Sí	Sí

Tabla B.3. Outliers críticos convertidos a NaN en variables biomecánicas.

Estos valores se trataron como críticos dentro de las variables predictoras y se convirtieron a valores ausentes para ser imputados posteriormente dentro del pipeline de modelado.

Dataset	Vídeo	Variable	Valor original	z robusto	|z robusto|	Gravedad	Método outlier	Tratamiento
eventos detallado	Longi_MASC_038	apoyo_m2_longitud_hasta_siguiente_m	4,950	11,140	11,140	Critico	IQR+MAD	Convertido a NaN
eventos detallado	Longi_MASC_022	apoyo_m2_velocidad_paso_m_s	4,800	-9,590	9,590	Critico	IQR+MAD	Convertido a NaN
eventos detallado	Longi_MASC_038	apoyo_m4_longitud_hasta_siguiente_m	0,890	-8,720	8,720	Critico	IQR+MAD	Convertido a NaN
eventos detallado	Longi_MASC_038	apoyo_m2_distancia_a_tabla_m	7,460	8,660	8,660	Critico	IQR+MAD	Convertido a NaN
eventos detallado	Longi_MASC_022	apoyo_m2_longitud_hasta_siguiente_m	0,900	-8,130	8,130	Critico	IQR+MAD	Convertido a NaN
vel. salida frame común	Longi_MASC_007	delta_x_m	0,140	-22,180	22,180	Critico	IQR+MAD	Convertido a NaN
vel. salida frame común	Longi_MASC_007	velocidad_media_resultante_m_s	0,830	-20,440	20,440	Critico	IQR+MAD	Convertido a NaN
vel. salida frame común	Longi_MASC_007	velocidad_media_horizontal_abs_m_s	0,400	-19,490	19,490	Critico	IQR+MAD	Convertido a NaN
vel. salida frame común	Longi_MASC_007	velocidad_media_horizontal_signed_m_s	0,400	-19,490	19,490	Critico	IQR+MAD	Convertido a NaN

Tabla B.4. Comparación del rendimiento del modelo con el dataset completo y sin valores extremos.

Escenario	Nº saltos	Mejor paquete	Mejor modelo	MAE (cm)	RMSE (cm)	R^2
Dataset completo	39	Velocidades	SVR	23,510	34,930	0,180
Sin valores extremos	36	Temporales/espaciales	Random Forest	16,710	21,650	0,160

Apéndice C

Reproducibilidad y disponibilidad

El código fuente completo del sistema está disponible públicamente en https://github.com/laurachapado/TFG-analisis-biomecanico-salto-longitud, e incluye los elementos de código correspondientes al procesamiento de los vídeos, la extracción de variables, el análisis exploratorio de los datos y los modelos desarrollados a lo largo de este trabajo. Es posible que sea complementado en el futuro mediante ampliaciones, mejoras del sistema y desarrollo de líneas futuras.

Los vídeos utilizados en este trabajo pertenecen a la Real Federación Española de Atletismo (RFEA) y no se distribuyen públicamente; el repositorio expone únicamente el código desarrollado. El acceso al material audiovisual necesario para la reproducibilidad completa de los experimentos deberá solicitarse, en su caso, a la Real Federación Española de Atletismo.

Apéndice D

Declaración Responsable sobre el uso de la IA

Durante la realización de este trabajo se han empleado herramientas de inteligencia artificial generativa como apoyo en distintas fases del proyecto. En concreto, se utilizaron para asistir en tareas de investigación preliminar, para apoyar el desarrollo de algunos componentes del código y para ayudar en la revisión y redacción de la memoria. En todos los casos se emplearon como una ayuda puntual y supervisada: la definición del problema, las decisiones de diseño, la implementación del sistema, el análisis de los resultados y las conclusiones son obra propia del autor, que ha revisado, validado y asume la responsabilidad de la totalidad del contenido presentado en este documento.